Bài giảng 1: Giới thiệu về Dữ liệu địa chất

TS. Tô Đức Khánh

Khoa Toán-Tin Học, Trường Đại Học Khoa Học Tự Nhiên
Đại Học Quốc Gia Tp. HCM

Học phần: Khoa học dữ liệu (cho địa chất)

Nội dung buổi học

1 Giới thiệu

2 Dữ liệu địa chất

3 Tính chất của dữ liệu địa chất

4 Giá trị điển hình của dữ liệu

1 Giới thiệu

2 Dữ liệu địa chất

3 Tính chất của dữ liệu địa chất

4 Giá trị điển hình của dữ liệu

Thông tin của môn học

Giảng viên:

TS. Tô Đức Khánh (tôi)
Bộ môn Xác suất-Thống kê, khoa Toán-Tin học
Trường Đại Học Khoa Học Tự Nhiên, Tp. HCM
e-mail: tdkhanh@hcmus.edu.vn
Phòng F012, Trường Đại Học Khoa Học Tự Nhiên, 227 Nguyễn Văn Cừ, Phường Chợ Quán, Tp. Hồ Chí Minh.

Thông tin của môn học

Nội dung của môn học trong 11 tuần bao gồm:

- Khám phá và tổng hợp dữ liệu địa chất.
- Trực quan hóa dữ liệu địa chất (1 chiều và nhiều chiều).
- Phân cụm đối tượng trong dữ liệu địa chất.
- Tổng hợp dữ liệu không gian.
- Giới thiệu thống kê địa chất (phương pháp kriging, variogram).

Thực hành với ngôn ngữ Python, với các thư viện: `pandas`, `numpy`.

Thông tin của môn học

Cấu trúc điểm:

- Điểm quá trình thực hành: 20%
- Điểm thi giữa kỳ: 20%
- Điểm thi cuối kỳ: 60%

Nhóm:
Sinh viên được chia thành các nhóm nhỏ, mỗi nhóm gồm từ 3-4 sinh viên.

Hình thức thi

- Thi giữa kỳ: viết.
- Thi cuối kỳ: viết và thực hành.

Chú ý: Sinh viên cần phải tham gia ít nhất 70% số tiết học.

Tài liệu học tập và tài liệu tham khảo

Slide bài giảng được cập nhật tại trang của môn học.

Các tài liệu tham khảo

- Wang, L., Yin, D. Z., & Caers, J. (2023). Data science for the geosciences. Cambridge University Press.
- VanderPlas, J. (2016). Python data science handbook: Essential tools for working with data. O'Reilly Media, Inc.
- Shi, G. (2013). Data mining and knowledge discovery for geoscientists. Elsevier.

Khoa học dữ liệu

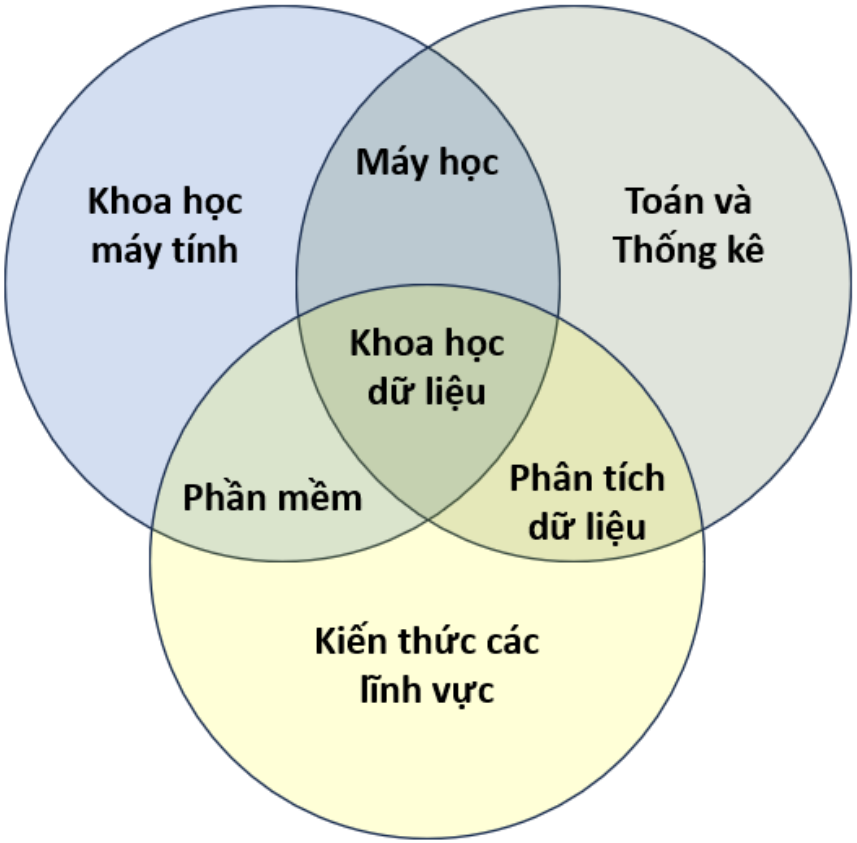

Xử lý dữ liệu?

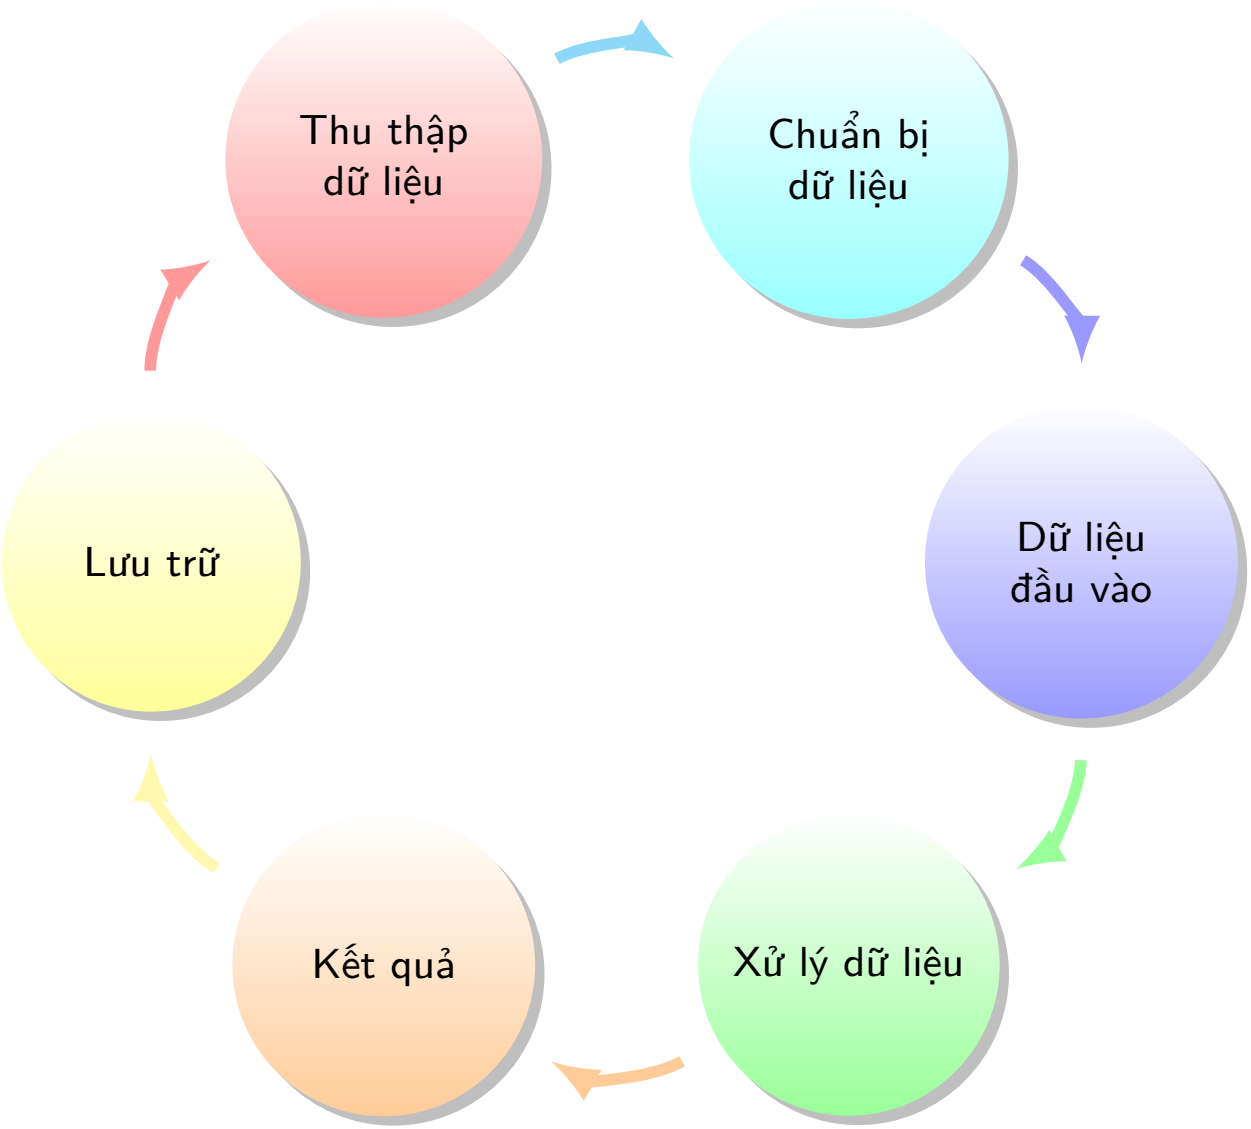
Thu thập dữ liệu
Chuẩn bị dữ liệu
Dữ liệu đầu vào
Xử lý dữ liệu
Kết quả
Lưu trữ

Xử lý dữ liệu?

Thu thập dữ liệu

Dữ liệu thô có thể bao gồm:

- số liệu tiền tệ,
- cookie trang web,
- báo cáo lãi/lỗ của công ty,
- hành vi của người dùng, v.v.

Dữ liệu thô phải được thu thập từ các nguồn được xác định và chính xác để những phát hiện tiếp theo có giá trị và có thể sử dụng được.

Chuẩn bị dữ liệu

Dữ liệu thô được kiểm tra:

- lỗi,
- trùng lặp,
- tính toán sai,
- thiếu dữ liệu,

và chuyển thành dạng phù hợp để phân tích và xử lý tiếp theo.

Xử lý dữ liệu?

Dữ liệu đầu vào

Dữ liệu thô được chuyển đổi thành dạng máy có thể đọc được và đưa vào bộ xử lý.

Xử lý dữ liệu

Áp dụng

- mô hình thống kê;
- thuật toán máy hoc;
- thuật toán học sâu.

để xử lý dữ liệu nhằm thu được kết quả cho các nhiệm vụ mong muốn.

Xử lý dữ liệu?

Kết quả

Dữ liệu cuối cùng được truyền và hiển thị cho người dùng ở dạng có thể đọc được:

- biểu đồ;
- bảng;
- video;
- âm thanh;
- tài liệu.

Đầu ra này có thể được lưu trữ và xử lý thêm trong chu trình xử lý dữ liệu tiếp theo.

Lưu trữ

Bước cuối cùng của chu trình xử lý dữ liệu là lưu trữ, nơi dữ liệu và siêu dữ liệu được lưu trữ để sử dụng tiếp:

- excel file;
- sql;
- text file, ...

Công việc của Data scientists

- Lập kế hoạch phân tích dựa trên vấn đề/câu hỏi được đặt ra
- Thuật toán, mô hình thống kê và mô hình máy học
- Chuẩn bị dữ liệu và làm sạch dữ liệu
- Phân tích, miêu tả kết quả, và kết luận

Statistical learning vs Machine learning

Thống kê (**Statistics**) là một ngành khoa học của việc:

- **thu thập** dữ liệu
- **biểu diễn** dữ liệu
- **phân tích** dữ liệu
- **giải thích** kết quả

nhằm tìm ra các bằng chứng để cung cố hoặc bác bỏ các giả thuyết khoa học hoặc câu hỏi nghiên cứu.

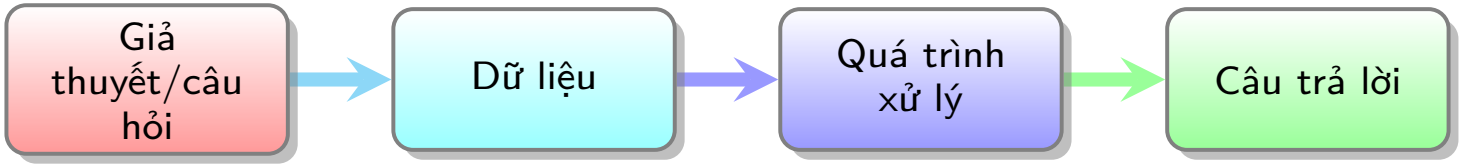

Statistical learning vs Machine learning

Statistical learning/**Machine learning** là sự áp dụng của các phương pháp thống kê (chủ yếu là hồi quy) để tạo ra sự tiên đoán về các dữ liệu chưa nhìn thấy.

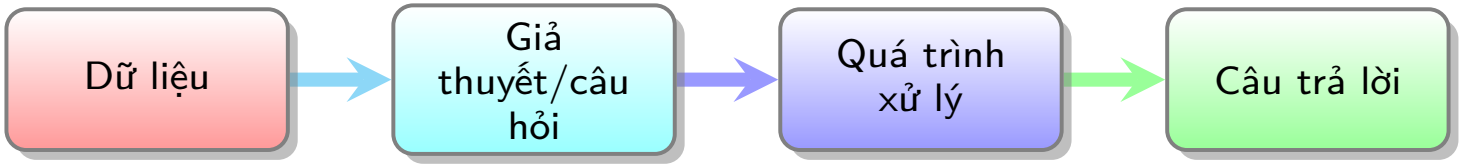

Statistical learning vs Machine learning

Statistical learning tập trung vào phát triển và phân tích các mô hình có thể đưa ra dự đoán hoặc suy luận dựa trên dữ liệu:

- so sánh;
- mối tương quan;
- sự ảnh hưởng.

Ví dụ:

- .... thêm ví dụ trong địa thống kê

Statistical learning hoạt động dựa trên các giả định cho dữ liệu:

- phân phối chuẩn;
- độc lập của các quan sát;
- đồng nhất phương sai.

Statistical learning vs Machine learning

Machine learning tập trung vào việc trích xuất kiến thức từ dữ liệu, bao gồm:

- các kỹ thuật hình thành khái niệm;
- phát hiện mẫu;
- các phương pháp lựa chọn tính năng tự động

Machine learning không phụ thuộc vào các giả định và trong hầu hết các trường hợp đều bỏ qua chúng.

Các mô hình machine learning được thiết kế để đưa ra dự đoán chính xác nhất có thể.

Statistical learning vs Machine learning

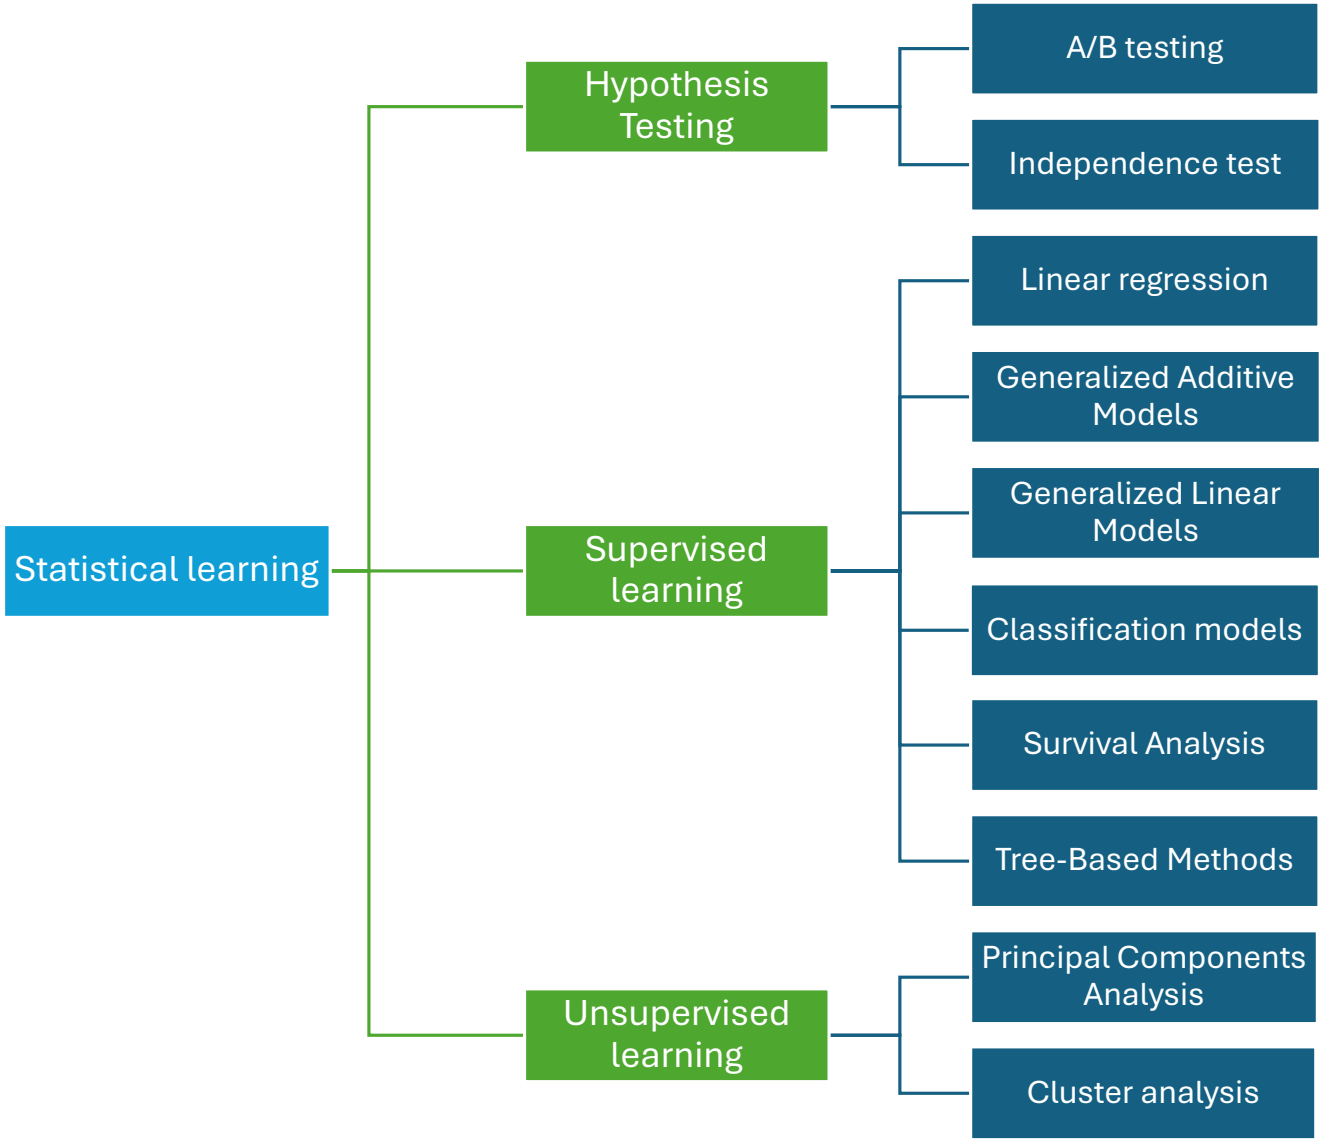

1 Giới thiệu

2 Dữ liệu địa chất

3 Tính chất của dữ liệu địa chất

4 Giá trị điển hình của dữ liệu

Dữ liệu?

Dữ liệu

Dữ liệu là một hoặc nhiều thông tin mô tả **tính chất của các đối tượng nghiên cứu**.

Dữ liệu có thể tới từ nhiều nguồn:

- cảm biến (sensor);
- sự kiện;
- văn bản (text);
- hình ảnh (images);
- âm thanh;
- video.

Dữ liệu?

Dữ liệu

Dữ liệu là một hoặc nhiều thông tin mô tả **tính chất của các đối tượng nghiên cứu**.

Dữ liệu có thể tới từ nhiều nguồn:

- cảm biến (sensor);
- sự kiện;
- văn bản (text);
- hình ảnh (images);
- âm thanh;
- video.

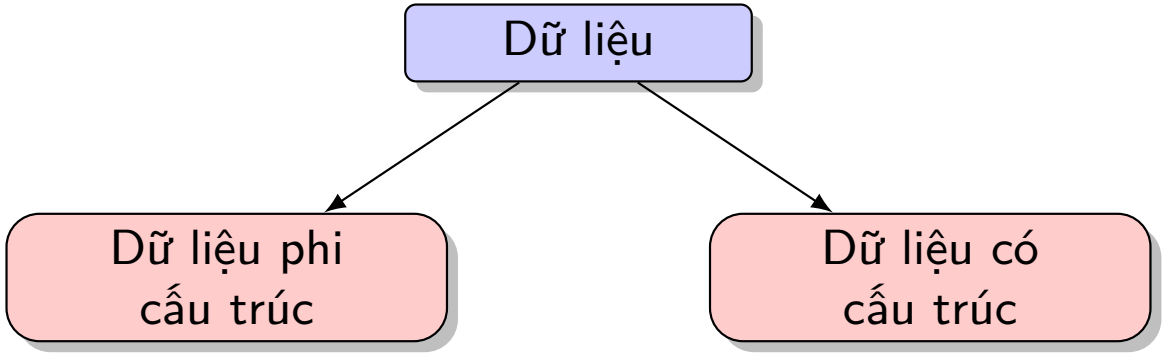

Dữ liệu có cấu trúc - Structured data

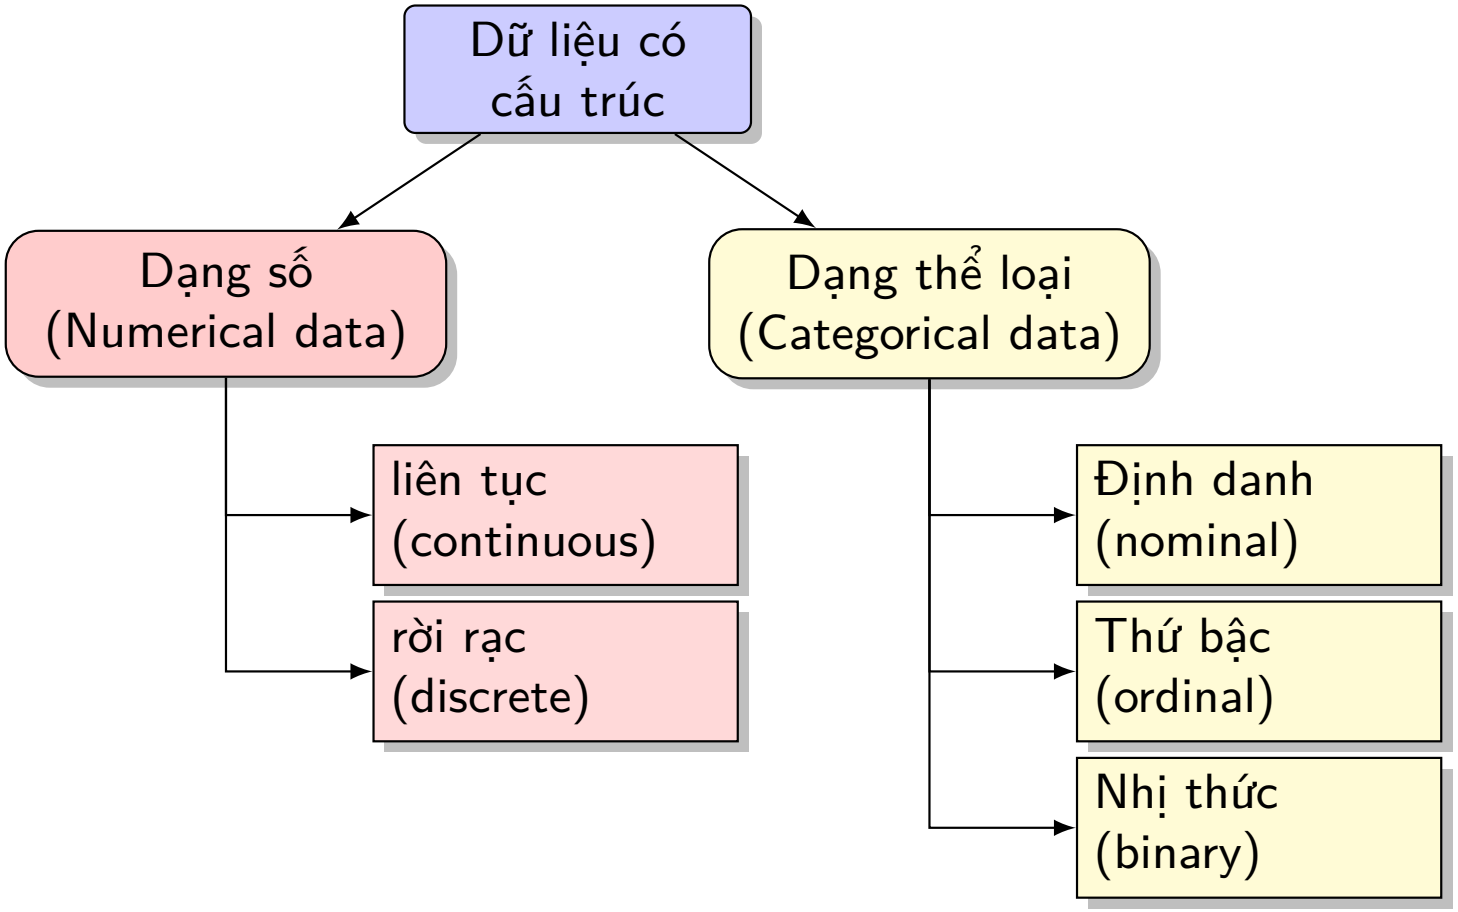

Dữ liệu có cấu trúc - Structured data

Dữ liệu dạng số (*numerical data* hay *quantitative data*) là dữ liệu được cấu trúc với giá trị là số:

- liên tục (*continuous*);
- rời rạc hay số đếm (*discrete*),

ghi lại/biểu diễn số lượng của một đối đối tượng nào đó.

Dữ liệu dạng phân loại (*categorical data* hay *qualitative data*) là dữ liệu được cấu trúc với giá trị là các thể loại khác nhau của người hoặc vật. Thông thường ta có hai dạng phổ biến sau:

- biến định danh (*nominal*)
- biến thứ bậc (*ordinal*)

Đặc biệt, đối với dữ liệu định danh, ta có:

- dữ liệu nhị định danh hay dữ liệu nhị phân (*binary data*), khi biến có 2 giá trị;
- dữ liệu đa định danh hay dữ liệu đa thức (*nominal multinomial data* hoặc *multinomial data*).

Dữ liệu có cấu trúc - Structured data

Đối với dự liệu địa chất, ta cũng có thể chia nhỏ các dữ liệu số liên tục thành các lớp nhỏ hơn:

- Các đại lượng Descartes (Descartes quantities) có thể có bất kỳ giá trị thập phân nào, bao gồm cả giá trị dương và âm.

  Ví dụ: cường độ động đất; điện thế tự phát giữa các tầng địa chất; hoặc độ pH của dung dịch nước.

- Các đại lượng Jeffreys (Jeffreys quantities) chỉ có thể có giá trị dương.

  Ví dụ: khối lượng, thể tích, mật độ, tốc độ hoặc tỷ lệ nồng độ hóa học.

- Tỷ lệ là các đại lượng bị giới hạn trong một khoảng hữu hạn từ 0 đến 1 (hoặc từ 0 đến 100%).

  Ví dụ: nồng độ hóa học; độ xốp; và tỷ lệ thể tích hoặc diện tích.

Rectangular Data

Rectangular Data

Rectangular Data có hình dạng giống như hình chữ nhật, tức là một ma trận hai chiều với các hàng (row) biểu thị các đối tượng (trường hợp) và các cột (column) biểu thị các đặc tính (feature) hay biến (variable).

Ví dụ: dữ liệu phân tích mẫu địa chất lưu vực sông.

id	lithology	age	springs	pH	Ca/Mg	vegetation
1	basalt	Cz	0	6.2	0.35	5.8
2	granite	Mz	1	4.4	11.00	28
3	basalt	Mz	0	5.6	6.00	12
4	sandstone	Cz	6	5.2	1.80	27
⋮	⋮	⋮	⋮	⋮	⋮	⋮
19	granite	Mz	0	4.6	2.20	74
20	basalt	Cz	1	5.6	7.70	84

Rectangular Data

Các thành phần của rectangular data:

- feature: một cột trong bảng dữ liệu thường ám chỉ tới đặc tính (feature) của đối tượng,

  đồng nghĩa với attribute, input, predictor, variable;
- outcome: là một đặc tính của đối tượng, được sử dụng như là kết quả của sự tiên đoán, hay phân loại,

  đồng nghĩa với dependent variable, response, target, output;
- records: một dòng của bảng dữ liệu thường ám chỉ tới một ghi chép của một đối tượng;

  đồng nghĩa với case, example, instance, observation, pattern, sample.
- data frame: bảng dữ liệu tổng hợp nhiều cột và dòng, biểu diễn ghi chép các đặc tính khác nhau của nhiều đối tượng;

  một bảng dữ liệu có thể chứa hỗn hợp các dạng dữ liệu có cấu trúc.

Rectangular Data

Tuy nhiên, dữ liệu mà ta làm việc, không phải lúc nào cũng ở sẵn dạng rectangular data.

- dữ liệu phi cấu trúc: phải được xử lý và thao tác để có thể biểu diễn dưới dạng tập hợp các tính năng;
- dữ liệu trong cơ sở dữ liệu phải được trích xuất và đưa vào một bảng duy nhất cho hầu hết các nhiệm vụ phân tích và lập mô hình dữ liệu.

Ví dụ: dữ liệu phân tích địa chất lưu vực sông

Hai mươi lưu vực sông đã được phân tích cho sáu loại đặc tính khác nhau.

id	lithology	age	springs	pH	Ca/Mg	vegetation
1	basalt	Cz	0	6.2	0.35	5.8
2	granite	Mz	1	4.4	11.00	28
3	basalt	Mz	0	5.6	6.00	12
4	sandstone	Cz	6	5.2	1.80	27
5	shale	pC	3	4.5	2.30	40
⋮	⋮	⋮	⋮	⋮	⋮	⋮
19	granite	Mz	0	4.6	2.20	74
20	basalt	Cz	1	5.6	7.70	84

Ví dụ: dữ liệu phân tích địa chất lưu vực sông

- `lithology`: thành phần đá gốc ⇒ biến định danh;
- `age`: tuổi địa tầng của nó (trong đó 'Cz' là kỷ Tân sinh, 'Mz' là kỷ Trung sinh, 'Pz' là kỷ Cổ sinh, và 'pC' là kỷ Tiền Cambri) ⇒ biến thứ bậc;
- `springs`: số lượng suối tự nhiên trong các lưu vực ⇒ biến số rời rạc (số đếm);
- `pH`: độ pH của nước sông ⇒ biến số liên tục (Jeffreys);
- `Ca/Mg`: tỷ lệ Ca/Mg ⇒ biến số liên tục tỷ lệ;
- `vegetation`: tỷ lệ diện tích lưu vực được bao phủ bởi thảm thực vật ⇒ biến số liên tục tỷ lệ.

Dữ liệu phi cấu trúc - Unstructured data

Dữ liệu phi cấu trúc là những dữ liệu được thu thập không có dạng số hoặc dạng thể loại:

- hình ảnh - images: là tập hợp các pixel với mỗi pixel chứa thông tin màu RGB (đỏ - red, xanh lá - green, xanh dương - blue);
- văn bản - text: là chuỗi các từ và ký tự không phải từ, thường được sắp xếp theo các phần, phần phụ, v.v;

Để áp dụng các mô hình của statistical learning, dữ liệu phi cấu trúc phải được xử lý và thao tác thành dạng có cấu trúc.

Ví dụ dữ liệu phi cấu trúc

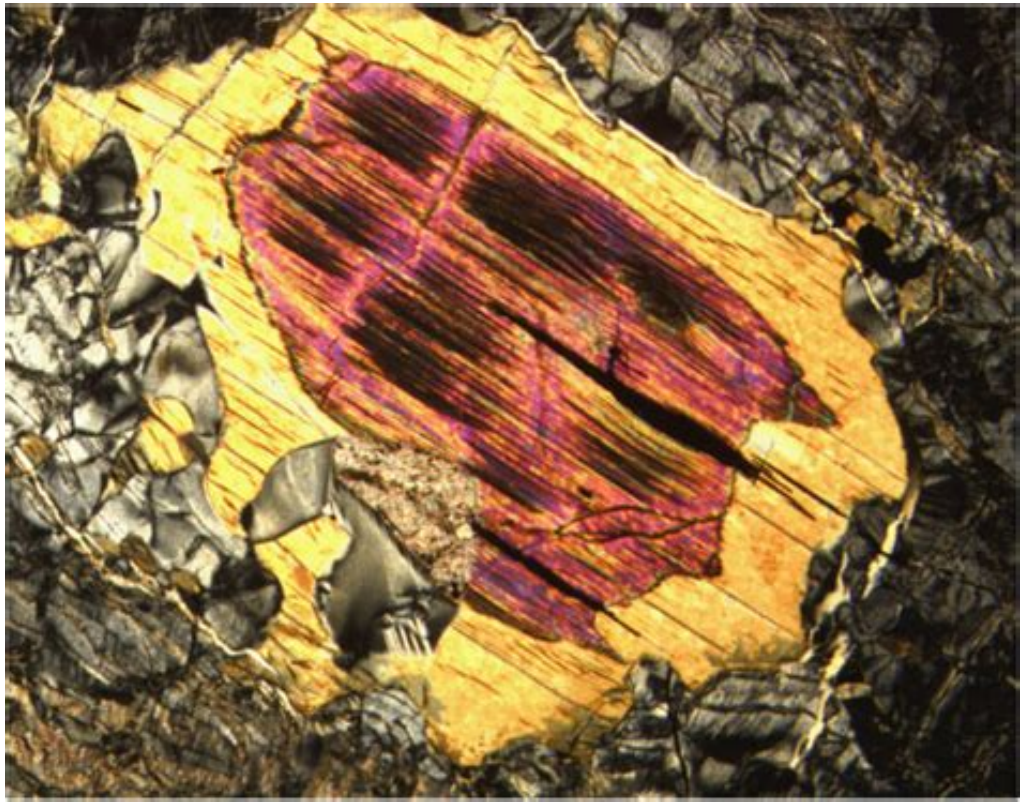

Ảnh lát mỏng khoáng vật dưới kính hiển vi phân cực, cho thấy

- cấu trúc tinh thể
- giao diện giữa các khoáng vật khác nhau
- màu sắc quang học đặc trưng

Ví dụ dữ liệu phi cấu trúc

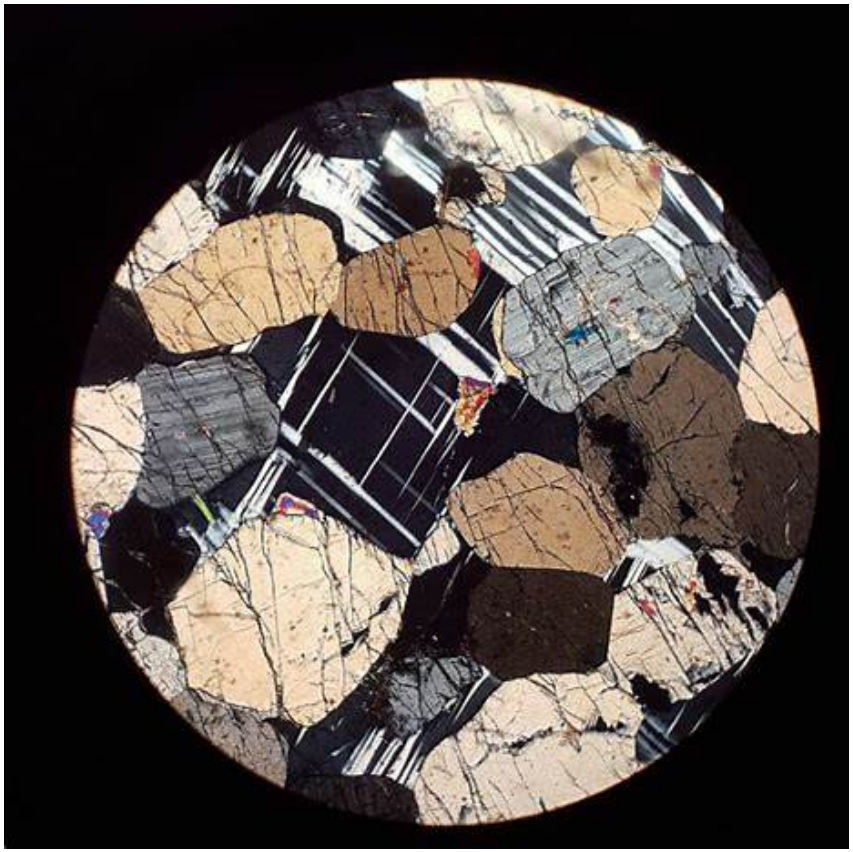

Mẫu lõi khoan được xử lý, lát mỏng rồi chụp ảnh vi mô (core thin section), cho thấy:

- chi tiết cấu trúc trong lõi
- các khe nứt, vân, sự phân bố khoáng vật, v.v.

Non-rectangular Data

Một số dạng dữ liệu sau không phải rectangular data:

- dữ liệu dạng danh sách: trong đó, mỗi danh sách là một rectangular data (cross-sectional data, panel data);
- dữ liệu chuỗi thời gian (time series data): ghi lại các phép đo liên tiếp của cùng một biến (feature);
- dữ liệu không gian (spatial data): được sử dụng trong phân tích bản đồ và vị trí;
- dữ liệu địa chấn (seismic traces & volumes): dạng chuỗi tín hiệu (time series) với độ dài khác nhau;
- dữ liệu đồ thị hoặc mạng lưới (graph, network data): được sử dụng để thể hiện các mối quan hệ vật lý, xã hội và trừu tượng.

1 Giới thiệu

2 Dữ liệu địa chất

3 Tính chất của dữ liệu địa chất

4 Giá trị điển hình của dữ liệu

Phụ thuộc vị trí

Dữ liệu địa chất thường có tính chất phụ thuộc vị trí (spatial dependence hay spatial autocorrelation).

Ví dụ:

- Hàm lượng khoáng sản trong một mỏ quặng:

  ($\star$) những điểm **gần nhau** trong không gian có giá trị % khoáng sản **tương tự nhau** (cùng cao hoặc cùng thấp);

  ($\star$) những điểm **cách xa** nhau thì giá trị % khoáng sản có thể **khác biệt nhiều** hơn.
- Độ thấm (permeability) của tầng đá chứa dầu khí: các vị trí lân cận thường có độ thấm tương tự do cấu trúc trầm tích.
- Độ dày tầng trầm tích (sediment thickness): thay đổi dần dần theo không gian, không ngẫu nhiên rời rạc.

Phụ thuộc vị trí

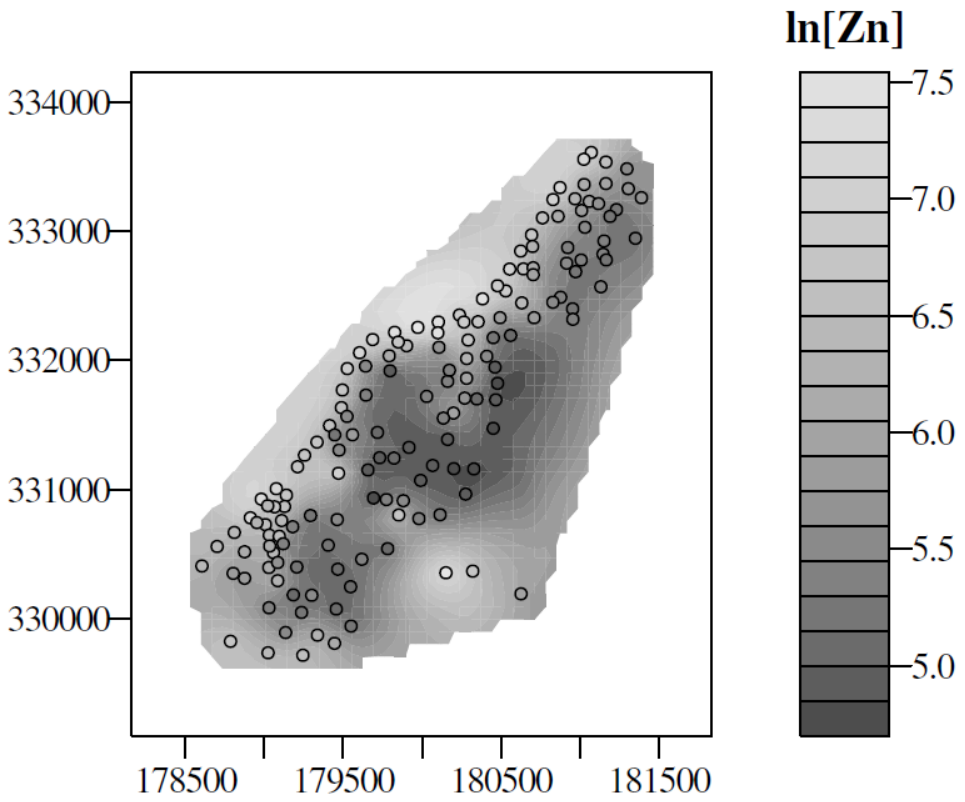

- Các điểm được tham dò về mức độ tập trung kẽm (Zn) biểu diễn trên bản đồ 2 chiều.
- Các điểm gần nhau có mức độ tập trung tương đồng nhau.

Sự thiếu hụt dữ liệu

Trong khoa học địa chất, sự thiếu hụt dữ liệu (missing data hay data gaps) là tình huống rất phổ biến do điều kiện thu thập khó khăn.

Ví dụ:

- Lõi khoan (core samples) bị mất đoạn: một số đoạn lõi có thể bị vỡ, rỗng hoặc không thu hồi được ⇒ dữ liệu địa chất bị khuyết ở các độ sâu đó.
- Đo đạc địa hóa (geochemical sampling) thưa hoặc mất mẫu: một số mẫu đất/đá bị hỏng, nhiễm bẩn hoặc không thể thu thập tại địa điểm nguy hiểm ⇒ dataset còn thiếu giá trị.
- Bản đồ địa chất số (geological mapping): có những khu vực chưa được khảo sát hoặc khảo sát không đầy đủ ⇒ polygon bản đồ không khép kín, hoặc có ô trống.
- Dữ liệu giếng khoan dầu khí: không phải giếng nào cũng được đo đầy đủ tất cả các log (gamma ray, resistivity, density, sonic, v.v.) ⇒ dẫn đến nhiều cột dữ liệu bị khuyết trong hồ sơ.
- Dữ liệu địa chấn (seismic survey) có khoảng trống: do điều kiện địa hình (núi cao, sông, hồ, khu dân cư), không thể đặt máy thu tại một số vị trí ⇒ bản đồ địa chấn có vùng trắng (no data zone).

Sự thiếu hụt dữ liệu

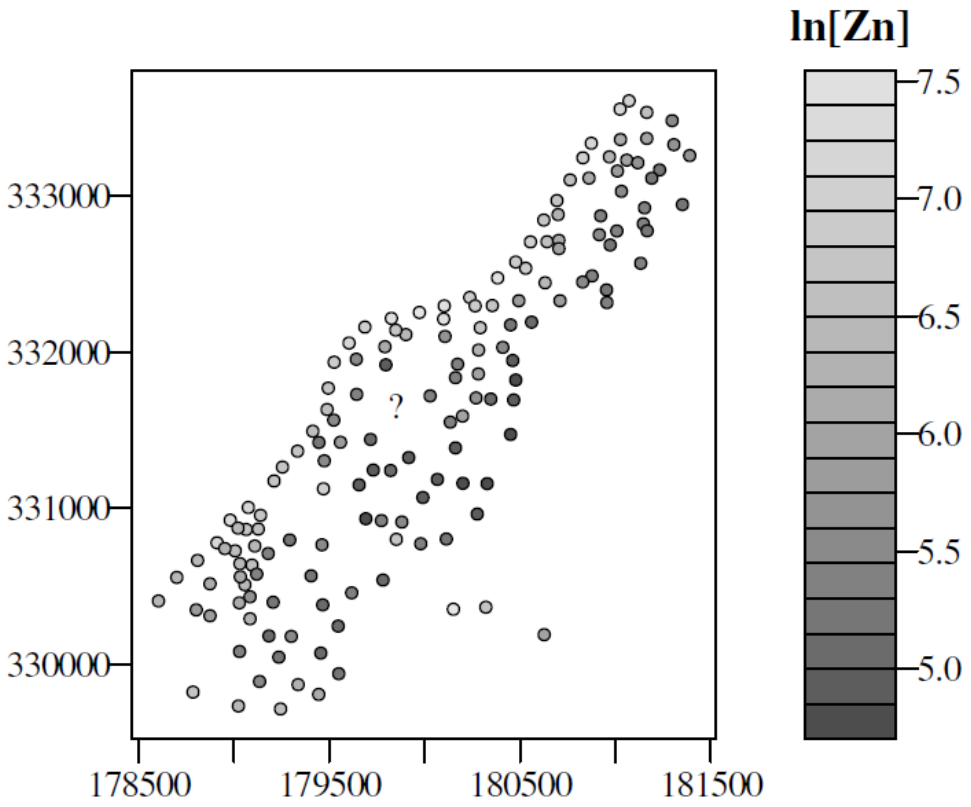

- Các điểm được tham dò về mức độ tập trung kẽm (Zn) biểu diễn trên bản đồ 2 chiều.
- Điểm ? (tọa độ $x = 179850, y = 331650$) đã không được đo đạc.

Tính tuần tự

Trong địa chất, tính tuần tự (sequential/ordered nature) của dữ liệu thể hiện rất rõ, vì nhiều loại dữ liệu được thu thập theo trình tự không gian hoặc thời gian:

- độ cao
- độ sâu

Ví dụ: dữ liệu về nghiên cứu về lở đất tại khu vực Himalayas.

id	landslide	elevation	aspect	slope	wetness	ndvi	ndwi	curvature
1	0	5242	335	14	0.3204	−0.0132	0.6061	0
2	0	5718	8	21	0.3768	−0.0480	0.8178	−186
3	0	6008	85	12	0.3769	−0.0252	0.5968	−539
4	0	5759	181	15	0.3769	−0.0321	0.7233	−19
5	0	5491	191	14	0.3769	−0.0298	0.8082	52
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
698	1	1190	227	2	−0.1551	0.4379	0.1676	15
1203	1	3272	173	20	0.0912	0.3783	0.0317	323
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Sự biến đổi không dừng

Trong địa chất, sự biến đổi không dừng (**non-stationarity**) có nghĩa là đặc tính thống kê của dữ liệu:

- trung bình
- phương sai
- phân bố

thay đổi theo vị trí hoặc theo độ sâu/thời gian.

Ví dụ: dữ liệu về tia gamma (gamma-ray) theo độ sâu của các giếng dầu tại Permian Basin, West Texas [1].

id	depth below sea level (m)	gamma ray
0	−728.624	26.364
1	−728.472	25.606
2	−728.320	22.576
3	−728.167	20.606
4	−728.015	20.455
⋮	⋮	⋮
7	−727.558	21.061
8	−727.405	21.97

[1] https://github.com/zsylvester/chronolog_data

Compositional data

Trong địa chất, dữ liệu thành phần (compositional data) xuất hiện rất thường xuyên, bởi vì nhiều biến số là tỷ lệ hoặc phần trăm và tổng cộng luôn bằng 100% (hoặc 1).

Ví dụ: dữ liệu về % thành phần hóa học trong dung nham Skye lavas.

id	A ($Na_2O + K_2O$)	F (Fe_2O_3)	M (MgO)
S1	52	42	6
S2	52	44	4
S3	47	48	5
S4	45	49	6
⋮	⋮	⋮	⋮
S22	14	47	39
S23	24	56	20

Giá trị cực đoan

Trong dữ liệu địa chất, **extreme values** (giá trị cực đoan) ám chỉ những điểm đo có giá trị lớn (hoặc rất nhỏ) so với phần lớn dữ liệu.

Những giá trị này có thể phản ánh dị thường địa chất thực sự, ví dụ:

- thân quặng kim loại;
- đới khoáng hóa mạnh.

Ví dụ: dữ liệu về thành phần địa hóa của các loại đá [2]

id	rock name	SiO_2	K_2On
S1	Basalt	47.77	0.62
S2	Basalt	47.94	0.96
S3	Basalt	51.50	0.33
S4	Aplite	**76.54**	**5.43**
⋮	⋮	⋮	⋮
S22	Aplite	**76.25**	**7.08**
S23	Rhyolite tuff	**74.07**	**9.58**

[2] https://www.kaggle.com/datasets/cristianminas/geochemical-variations-in-igneous-rocks-mining

1 Giới thiệu

2 Dữ liệu địa chất

3 Tính chất của dữ liệu địa chất

4 Giá trị điển hình của dữ liệu

Các đặc trưng của dữ liệu

Dữ liệu của một biến ngẫu nhiên được đặc trưng bởi ba yếu tố chính:

- giá trị trung tâm - central tendency,
- độ biến động - variability,
- độ lệch - sknewness,
- phân phối dữ liệu.

Cụ thể

giá trị trung tâm cung cấp ước tính về nơi chứa hầu hết dữ liệu

giá trị biến động đo lường xem các giá trị dữ liệu được phân cụm chặt chẽ hay dàn trải.

giá trị độ lệch đo lường xem các giá trị dữ liệu cho thấy thiên hướng đối xứng (thường là qua trung bình) hay là tập trung lệch về một bên.

phân phối dữ liệu cung cấp cái nhìn tổng quát về sự phân bố của dữ liệu (tập trung dày ở một vùng cụ thể, dàn trải trên vùng nào đó).

Giá trị trung tâm - Location

Có nhiều định nghĩa giá trị trung tâm khác nhau:

- trung bình cộng - mean (average)
- trung vị - median
- mode

Trung bình cộng - mean

Trung bình cộng - mean (average) là ước lượng cơ bản cho giá trị trung tâm của dữ liệu:

$$\text{mean} = \overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i,$$

với n là số lượng dữ liệu được quan sát.

Giá trị trung tâm - Location

Trung vị - median

Trung vị - median là một giá trị của dữ liệu, sao cho chia dữ liệu thành hai nửa đều nhau, khi dữ liệu được sắp xếp theo thứ tự tăng dần. Trung vị của một bộ dữ liệu là nghiệm của:

$$\text{median} = \arg\min_{x} \sum_{i=1}^{n} |x - x_i|$$

Mode

Mode là một giá trị của dữ liệu mà có tần số xuất hiện nhiều nhất. Để tìm mode, ta thường ước lượng hàm mật độ xác suất của dữ liệu, sau đó xác định mode như là điểm cực trị của hàm này. (sẽ học ở bài sau). Trong dữ liệu, có thể

- không có mode,
- có 1 mode,
- có nhiều mode.

Giá trị trung tâm - Location

Ví dụ: Xét dữ liệu về độ pH của 20 mẫu quan trắc tại 20 lưu vực sông

6.2	4.4	5.6	5.2	4.5	5.4	4.8	5.9	3.8	4.0
5.0	4.1	5.2	5.5	5.3	4.6	5.7	4.6	4.6	5.6

Ta dễ dàng tính được:

- trung bình lượng pH của 20 mẫu là 5.00
- trung vị được xác định bởi

  3.8 4.0 4.1 4.4 4.5 4.6 4.6 4.6 4.8 5.0 5.2 5.2 5.3 5.4 5.5 5.6 5.6 5.7 5.9 6.2

  do đó trung vị là $(5.0 + 5.2)/2 = 5.1$.
- đối với mode ta sẽ cần thực hiện ước lượng hàm mật độ của dữ liệu, sau đó tìm giá trị cực đại của hàm mật độ này, từ đó suy ra mode. (sẽ học trong bài sau).

Độ biến động - Variability

Độ biến động của dữ liệu được miêu tả thông qua các số đo:

- phương sai - variance
- độ lệch chuẩn - standard deviation
- trung bình độ lệch tuyệt đối - mean absolute deviation
- trung vị độ lệch tuyệt đối - median absolute deviation (MAD)
- khoảng biến động - range
- phân vị
- khoảng tứ phân vị - interquartile range (IQR)

Độ biến động - Variability

Phương sai, độ lệch chuẩn

Phương sai và độ lệch chuẩn (variance, standard deviation) là hai đại lượng đo độ biến động của dữ liệu xung quanh giá trị trung bình.

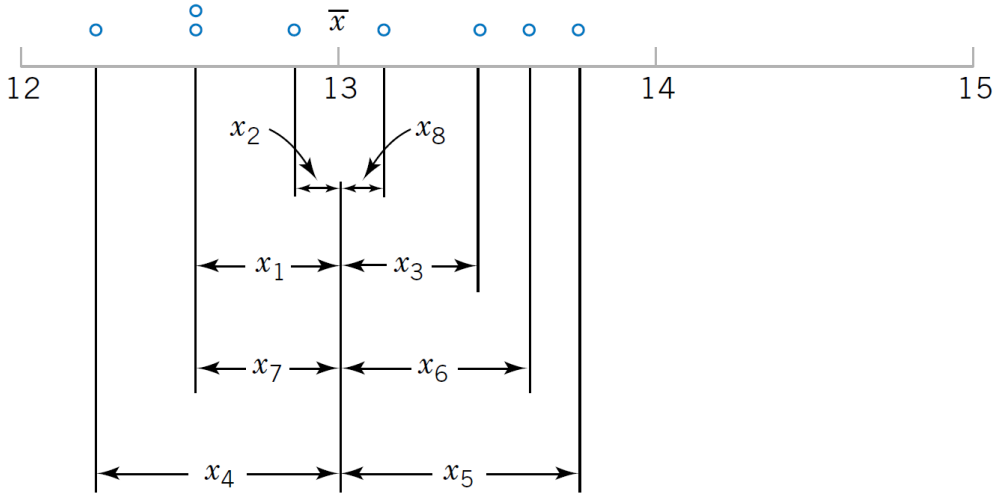

Phương sai được ký hiệu là s^2 và được xác định bởi:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2,$$

Độ lệch chuẩn, được ký hiệu là s và được xác định bởi: $s = \sqrt{s^2}$.

Độ biến động - Variability

Trung bình độ lệch tuyệt đối

Trung bình độ lệch tuyệt đối (mean absolute deviation) là đại lượng biểu thị độ biến động của dữ liệu xung quanh giá trị trung bình thông qua trung bình khoảng cách Euclidean:

$$\text{mean absolute deviation} = \frac{1}{n}\sum_{i=1}^{n}|x_i - \overline{x}|,$$

- Độ lệch chuẩn dễ diễn giải hơn nhiều so với phương sai vì nó có cùng tỷ lệ với dữ liệu gốc.
- Giá trị của phương sai, độ lệch chuẩn, trung bình độ lệch tuyệt đối càng nhỏ thì dữ liệu càng ít biến động so với trung bình.

Độ biến động - Variability

Trung vị độ lệch tuyệt đối - median absolute deviation (MAD)

Trung vị độ lệch tuyệt đối - MAD là thước đo độ biến thiên dữ liệu xung quanh điểm trung vị:

$$\text{MAD} = \text{median}(|x_1 - m|, |x_2 - m|, \ldots, |x_n - m|),$$

với m là trung vị.

Khoảng tứ phân vị - interquartile range

Khoảng tứ phân vị - interquartile range là khoảng cách giữa phân vị thứ nhất (25% dữ liệu) và phân vị thứ ba (75% dữ liệu).

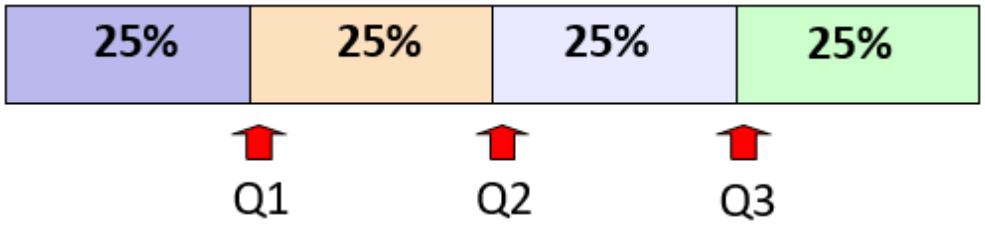

Độ biến động - Variability

Ví dụ: Xét dữ liệu về độ pH của 20 mẫu quan trắc tại 20 lưu vực sông

6.2	4.4	5.6	5.2	4.5	5.4	4.8	5.9	3.8	4.0
5.0	4.1	5.2	5.5	5.3	4.6	5.7	4.6	4.6	5.6

Ta dễ dàng tính được:

- độ lệch chuẩn $s = \sqrt{8.42/19} = 0.67$
- MAD $= 0.5$
- IQR $= 1$

Độ lệch

Độ lệch của dữ liêu được tính theo công thức

$$\mathrm{skew}(x) = \frac{1}{ns^3} \sum_{i=1}^{n} (x_i - \overline{x})^3 ,$$

trong đó, s là độ lệch chuẩn và $\overline{x}$ là trung bình của dữ liệu.

Nếu

- $\mathrm{skew}(x) = 0$: dữ liệu có tính đối xứng,
- $\mathrm{skew}(x) > 0$: dữ liệu có tính lệch sang bên phải,
- $\mathrm{skew}(x) < 0$: dữ liệu có tính lệch sang bên trái.

Giá trị ngoại lai - Outliers

Outliers - Extreme values

Giá trị ngoại lai (outliers/extreme values) là bất kỳ giá trị nào khác rất xa so với các giá trị còn lại trong tập dữ liệu.

129, 1.65, 132, 133, 137, 138, 1308, 140, 140, 141, 143, 143, 1405

Giá trị ngoại lai - Outliers

Outliers - Extreme values

Giá trị ngoại lai (outliers/extreme values) là bất kỳ giá trị nào khác rất xa so với các giá trị còn lại trong tập dữ liệu.

129, 1.65, 132, 133, 137, 138, 1308, 140, 140, 141, 143, 143, 1405

Giá trị ngoại lai có thể là:

- một quan sát hiếm khi xảy ra: lượng mưa lớn đột ngột, số lượng lớn khác hàng trong một giờ;
- kết quả của lỗi dữ liệu: đơn vị không đồng nhất giữa các giá trị, sai sót trong đo lường hoặc ghi chép.

Giá trị ngoại lai - Outliers

Outliers - Extreme values

Giá trị ngoại lai (outliers/extreme values) là bất kỳ giá trị nào khác rất xa so với các giá trị còn lại trong tập dữ liệu.

129, 1.65, 132, 133, 137, 138, 1308, 140, 140, 141, 143, 143, 1405

Giá trị ngoại lai có thể là:

- một quan sát hiếm khi xảy ra: lượng mưa lớn đột ngột, số lượng lớn khác hàng trong một giờ;
- kết quả của lỗi dữ liệu: đơn vị không đồng nhất giữa các giá trị, sai sót trong đo lường hoặc ghi chép.

Nhận xét:

- các giá trị ngoại lai có ảnh hưởng xấu tới ước lượng của trung bình và phương sai cũng như độ lệch chuẩn;
- các ước lượng: median, MAD là các ước lượng "robust" với outliers (tức là ít bị ảnh hưởng bởi outliers).

Giá trị ngoại lai - Outliers

Để nhận dạng được sự hiện diện của outliers trong dữ liệu, ta có thể dùng:

- khoảng tứ phân vị - IQR, cụ thể, các điểm dữ liệu nằm ngoài khoảng

$$[Q_1 - 1.5 \times IQR, Q_3 + 1.5 \times IQR]$$

  thì được coi là outliers trong dữ liệu;

- median và MAD, cụ thể, ta xét khoảng

$$[\text{median} - 3 \times MAD, \text{median} + 3 \times MAD]$$

  nếu các điểm dữ liệu không nằm trong khoảng này, thì được coi là outliers. Cách xét này được gọi là bộ lọc Hampel - Hampel filter.