Bài giảng 02: Kỹ thuật trực quan hóa dữ liệu một chiều

TS. Tô Đức Khánh[1]

[1] *Khoa Toán-Tin học, Trường Đại học Khoa học tự nhiên, ĐHQG-HCM*

Ngày 11 tháng 10 năm 2025

Mục lục

1 Khám phá quy luật phân bố dữ liệu **2**

1.1 Dữ liệu và biến ngẫu nhiên 2

1.2 Phân phối thực nghiệm của dữ liệu 2

2 Phân bố dữ liệu và biểu đồ cơ bản **5**

2.1 Biểu đồ tần số 5

2.2 Biểu đồ mật độ 7

2.3 Biểu đồ hộp 10

3 Chuyển đổi dữ liệu **12**

3.1 Vấn đề với dữ liệu có giá trị giới hạn 12

3.2 Hàm mật độ cho phép đổi biến 14

4 Các biểu đồ đặc biệt **15**

4.1 Biểu đồ tam phân 16

4.2 Biểu đồ hoa hồng 18

1 Khám phá quy luật phân bố dữ liệu

1.1 Dữ liệu và biến ngẫu nhiên

Định nghĩa 1.1. Biến ngẫu nhiên là kết quả của một phép đo (hoặc ghi nhận tính chất) của một đối tượng được lựa chọn ngẫu nhiên. Giá trị của biến ngẫu nhiên là một số bất kỳ trong tập số thực $\mathbb{R}$.

Định nghĩa 1.2. Dữ liệu hay cụ thể hơn là giá trị ghi nhận (đo đạc) được của một biến (tính chất) của đối tượng chính là giá trị quan sát thực tế của một biến ngẫu nhiên.

Do đó, một biến trong dữ liệu chính là phiên bản **thực nghiệm** một biến ngẫu nhiên, và nó sẽ thường hưởng các tính chất và đại lượng thống kê của biến ngẫu nhiên tương ứng, cụ thể là phân phối xác suất.

1.2 Phân phối thực nghiệm của dữ liệu

Cho biến ngẫu nhiên Y, tuân theo phân phối $F_Y(y)$, các đại lượng (tham số) thường dùng để miêu tả đặc tính của phân phối lý thuyết (hay phân phối quần thể) là giá trị kỳ vọng (trung bình) $\mathbb{E}(Y) \equiv \mu_X$ và phương sai $\mathbb{V}\mathrm{ar}(Y) = \sigma_Y^2$. Các giá trị này thường chỉ biết ở dạng lý thuyết (giả định hay coi như là không biết giá trị chính xác), do đó, về mặt áp dụng cho dữ liệu thực tế, ta cần phải ước lượng chúng.

Nhắc lại rằng một mẫu được lấy ngẫu nhiên (dữ liệu) là một tập hợp các đơn vị thống kê nhỏ hơn (nhưng hy vọng mang tính đại diện) từ một quần thể được sử dụng để xác định sự thật về quần thể đó. Do đó, phân phối lý thuyết của quần thể hay Y sẽ được đại diện bởi phân phối của mẫu (distribution of sample) - cái thường được biểu diễn bởi histogram.

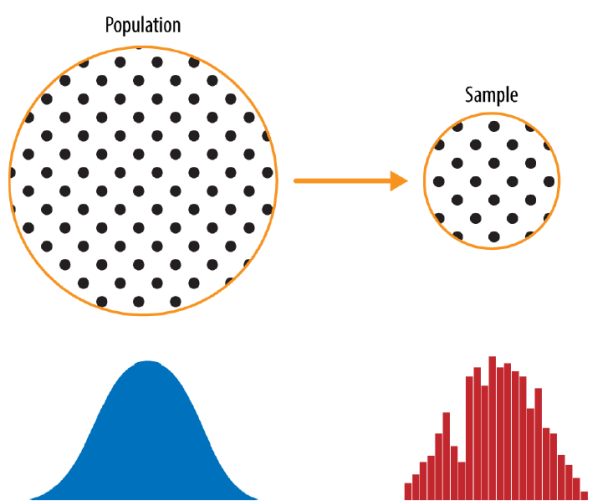

Hình 1 – *Phân phối quần thể Y và phân phối của mẫu.*

Trong thống kê ứng dụng trong khoa học dữ liệu, các ước lượng được xây dựng dựa trên phân phối của mẫu, mà cụ thể ta có định nghĩa của phân phối tích lũy thực nghiệm (empirical cumulative distribution function - ecdf). Với một mẫu ngẫu nhiên, độc lập và cùng phân phối (i.i.d - identical and independent distributed), $Y_1, \ldots, Y_n$ của Y, hàm phân phối tích lũy (cumulative distribution function) được định nghĩa là $F_Y(y) = \Pr(Y \leq y)$, và hàm phân phối thực nghiệm của Y được xác định bởi

$$\widehat{F}_n(y) = \frac{1}{n} \sum_{i=1}^{n} \mathrm{I}\left(Y_i \leq y\right), \tag{1.1}$$

là một ước lượng của F_Y, với $\mathrm{I}(\cdot)$ là hàm chỉ (indicator function) và được định nghĩa bởi $\mathrm{I}\left(y \leq a\right) = 1$ nếu $y \leq a$ hoặc 0 nếu ngược lại.

Phân vị thứ p (p-th quantile) hay $100p$ percentile là điểm được xác định thông qua hàm phân vị $Q(p) = F^{-1}(p)$, với F là hàm phân phối tích lũy lý thuyết. Khi áp dụng với dữ liệu, ta sử dụng hàm phân phối tích lũy thực nghiệm $\widehat{F}_n$, khi đó phân vị thực nghiệm $Q_n(p)$ xác định bởi

$$Q_n(p) = \inf\left\{y \in \mathbb{R} : p \leq \widehat{F}_n(y)\right\}.$$

Một số trường hợp đặc biệt, $p = 0.25$ ta có phân vị thứ nhất $Q_1 = Q_n(0.25)$, với $p = 0.5$ thì $Q_n(0.5) = Q_2$ tức là trung vị (median), cuối cùng $p = 0.75$, ta có phân vị thứ ba, $Q_3 = Q_n(0.75)$.

id	lithology	age	springs	pH	Ca/Mg	vegetation
1	basalt	Cz	0	6.2	0.35	5.8
2	granite	Mz	1	4.4	11.00	28
3	basalt	Mz	0	5.6	6.00	12
4	sandstone	Cz	6	5.2	1.80	27
5	shale	pC	3	4.5	2.30	40
6	basalt	Mz	1	5.4	0.59	12
7	shale	Pz	2	4.8	8.40	3.8
8	basalt	Pz	0	5.9	2.90	6.3
9	shale	Mz	1	3.8	5.90	17
10	shale	Mz	2	4.0	2.10	16
11	sandstone	Pz	4	5.0	1.20	95
12	shale	pC	2	4.1	2.10	94
13	sandstone	Mz	4	5.2	1.10	92
14	basalt	Cz	1	5.5	1.60	88
15	sandstone	Pz	4	5.3	0.90	88
16	granite	Pz	0	4.6	1.70	70
17	basalt	Mz	0	5.7	3.40	92
18	shale	Pz	1	4.6	0.53	72
19	granite	Mz	0	4.6	2.20	74
20	basalt	Cz	1	5.6	7.70	84

Bảng 1 – *Dữ liệu phân tích mẫu địa chất tại 20 lưu vực sông.*

Ví dụ 1.1. Xét bộ dữ liệu phân tích mẫu địa chất lưu vực sông được tổng hợp trong Bảng 1. Trong đó, ta quan tâm tới biến `pH` của các mẫu vật, dữ liệu này được biểu diễn trong Hình 2(a) theo thứ

tự tăng dần trên trục số. Phân phối xác suất tích lũy thực nghiệm cho dữ liệu của biến `pH` được xác định theo biểu thức (1.1) với $n = 20$ và y là các điểm dữ liệu (không trùng lặp). Kết quả được biểu diễn như trong Hình 2(b), trong đó, các vạch ngang ám chỉ rằng xác suất tích lũy không thay đổi trong các đoạn không có dữ liệu quan sát. Điều này làm rõ thêm đặc tính không liên tục của hàm phân phối tích lũy thực nghiệm.

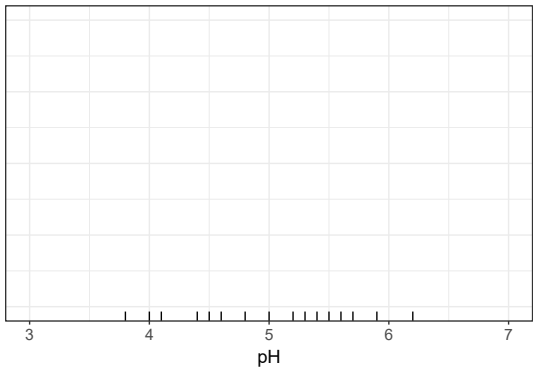

(a)

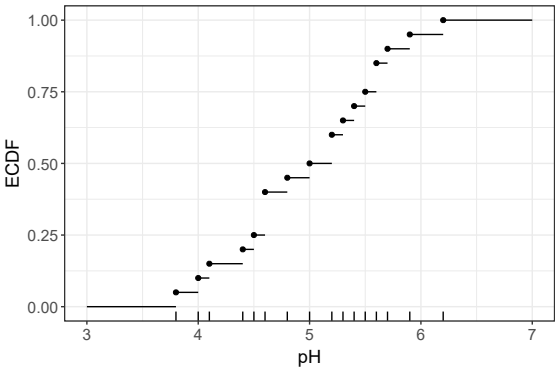

(b)

Hình 2 – *Biểu diễn dữ liệu sau khi sắp xếp theo thứ tự tăng dần, hình (a). Biểu diễn của phân phối thực nghiệm của* `pH` *xác định tại các điểm dữ liệu quan sát.*

Dáng điệu của phân phối tích lũy thực nghiệm trong Hình 2(b) phản ánh sự tập trung của pH trong khoảng 4.5 tới 5.5, tương ứng với sự tăng lên nhanh chóng của xác suất tích lũy thực nghiệm. Thêm vào đó, từ phân phối tích lũy thực nghiệm trong Hình 2(b), ta tính được các phân vị $Q(0.25) = 4.5$, $Q(0.5) = 5$ và $Q(0.75) = 5.5$, và do đó, khoảng tứ phân vị $\text{IQR} = 1$. ■

Ví dụ 1.2. Xét bộ dữ liệu về thời gian chờ giữa các lần phun trào (`waiting`, đơn vị phút) và thời gian phun trào (`eruptions`, đơn vị giây) của mạch nước phun Old Faithful ở Công viên quốc gia Yellowstone, Wyoming, Hoa Kỳ. Có tổng cộng 272 quan sát được thực hiện.

id	eruptions	waiting
1	3.600	79
2	1.800	54
⋮	⋮	⋮
271	1.817	46
272	4.467	74

Bảng 2 – *Một phần dữ liệu quan sát của thời gian chờ giữa các lần phun trào và thời gian phun trào của mạch nước phun Old Faithful ở Công viên quốc gia Yellowstone, Wyoming, Hoa Kỳ.*

Phân phối xác suất tích lũy thực nghiệm cho dữ liệu của biến `waiting` được xác định theo biểu thức (1.1) với $n = 272$ và y là các điểm dữ liệu (không trùng lặp). Kết quả được biểu diễn như trong Hình 3. Dáng điệu của phân phối tích lũy thực nghiệm trong Hình 3 phản ánh hai khoảng tập trung dữ liệu, tương ứng với hai vùng thay đổi của phân phối tích lũy. Phần thứ nhất là từ 45 phút tới 60 phút, và vùng thứ hai là từ 75 phút cho tới 90 phút.

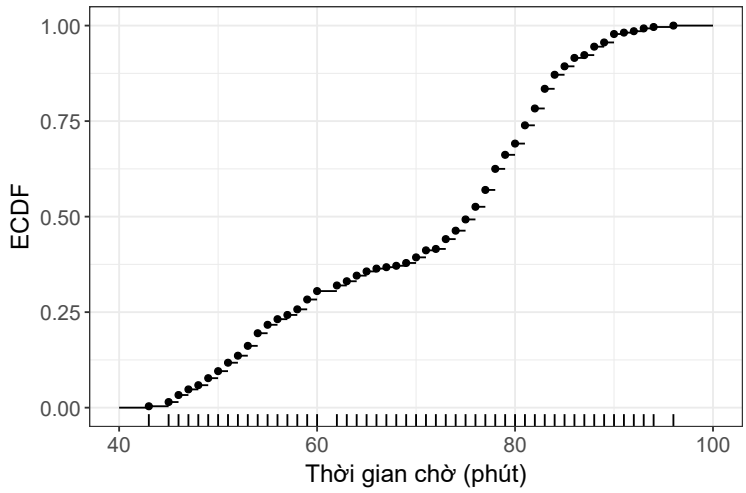

Hình 3 – *Biểu diễn của phân phối thực nghiệm của* `waiting` *xác định tại các điểm dữ liệu quan sát.*

■

Qua hai ví dụ này, ta có thể sử dụng biểu đồ phân phối tích lũy thực nghiệm để hình dung ra khu vực tập trung nhiều dữ liệu thông qua sự thay đổi nhanh hay chậm của xác suất tích lũy. Tuy nhiên, để có cái nhìn trực tiếp hơn cho sự phân bố của dữ liệu, ta có thể sử dụng các biểu đồ tần số hay biểu đồ mật độ. Các biểu đồ này được trình bày ở phần sau.

2 Phân bố dữ liệu và biểu đồ cơ bản

Để trực quan dữ liệu nhằm biểu đạt dược phân bố của dữ liệu ta sử dụng một số biểu đồ cơ bản: (i) biểu đồ tần số (histogram); (ii) biểu đồ mật độ (density); (iii) biểu đồ hộp (boxplot).

2.1 Biểu đồ tần số

Biểu đồ tần số (histogram) được xác định dựa trên quy trình xử lý dữ liệu như sau:

(1) sắp xếp dữ liệu tăng dần

(2) chia dữ liệu thành m khoảng có cùng độ rộng (bandwidth), có dạng $[a_i, b_i)$

(3) đếm số điểm dữ liệu xuất hiện trong mỗi khoảng và vẽ 1 cột có chiều rộng bằng với chiều rộng của khoảng và chiều cao bằng với số lượng dữ liệu trong khoảng.

Quy trình này được biểu diễn minh họa trong Hình 4, cho dữ liệu độ pH trong 20 mẫu lấy từ 20 lưu vực sông (xem Ví dụ 1.1).

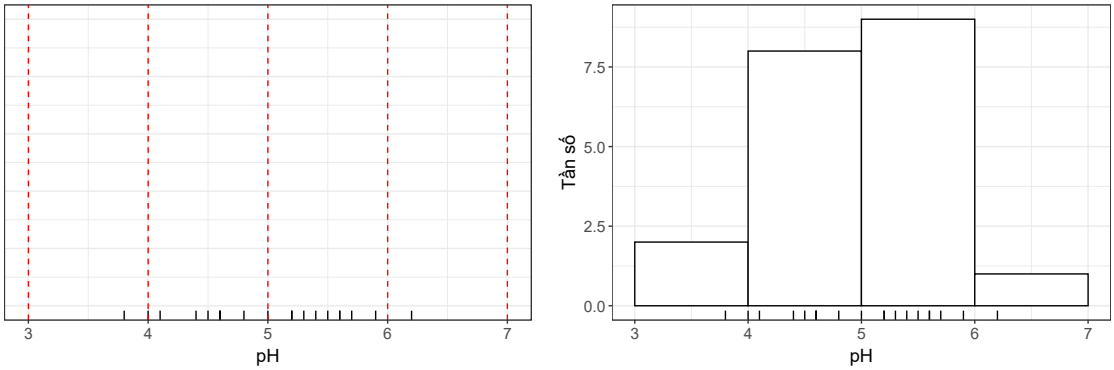

(a) (b)

Hình 4 – *Quy trình các bước xử lý dữ liệu vào tạo biểu đồ tần số cho dữ liệu độ pH tại 20 lưu vực sông. Hình (a) tạo các khoảng cách đều, với độ rộng 1 đơn vị, hình (b) các thanh tần số được xác định chiều cao theo số điểm dữ liệu xuất hiện trong một khoảng.*

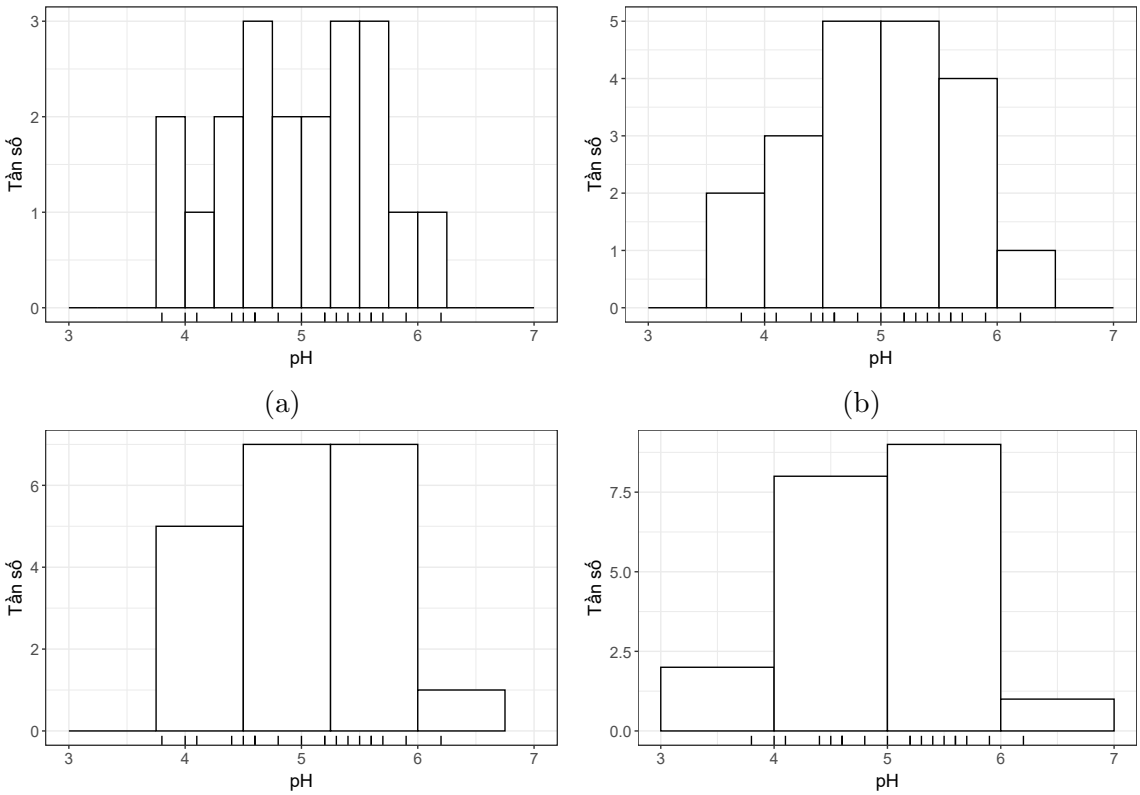

(a) (b)

(c) (d)

Hình 5 – *Biểu đồ tần số tương ứng với các cách chọn độ rộng khác nhau: hình (a) 0.25, hình (b) 0.5, hình (c) 0.75 và hình (d) 1.*

Việc lựa chọn độ rộng cho khoảng hay số khoảng sẽ ảnh hưởng trực tiếp tới hình dạng của phân phối được hiển thị bởi biểu đồ tần số. Một số khoảng nhỏ (hay độ rộng lớn) sẽ không thể hiện được sự phân bổ của dữ liệu, trong khi với số khoảng lớn (hay độ rộng nhỏ) biểu đồ tần số sẽ biểu diễn quá chi tiết cho sự phân bổ của dữ liệu, xem chi tiết trong Hình 5. Thông thường, ta có thể chọn số khoảng từ 10 tới 15, tùy vào độ lớn của vùng dữ liệu (sự khác biệt giữa giá trị nhỏ nhất và lớn nhất của dữ liệu).

2.2 Biểu đồ mật độ

Hàm mật độ xác suất của biến ngẫu nhiên ngoài công dụng trong việc xác định xác suất tích lũy, thì nó cũng biểu diễn sự phân bố của giá trị lý thuyết của biến ngẫu nhiên, trong đó, vùng có giá trị mật độ xác suất cao nhất thì tương ứng với vùng có khả cao có thể quan sát được giá trị của biến ngẫu nhiên.

Trong phần trước, ta đã được giới thiệu tới hàm phân phối tích lũy thực nghiệm, từ hàm này, ta hoàn toàn có thể xác định được hàm mật độ xác suất cho dữ liệu. Nhắc lại rằng, hàm mật độ xác suất lý thuyết của một biến ngẫu nhiên liên tục Y, được ký hiệu là $f(y)$ và được xác định bởi $f(y) = \dfrac{\mathrm{d}}{\mathrm{d}\,y}F(y)$, tức là đạo hàm của hàm phân phối tích lũy lý thuyết $F(y)$. Hàm mật độ xác suất có tính chất:

(i) $f(y) \geq 0$,

(ii) $\displaystyle\int_{-\infty}^{+\infty} f(y)\mathrm{d}\,y = 1.$

Giá trị lớn của $f(y)$ ám chỉ rằng mật độ của giá trị của biến ngẫu nhiên Y xung quanh điểm y là "dày đặc", trong khi các giá trị nhỏ thì tương ứng với sự phân bố "thưa thớt" giá trị.

Đối với dữ liệu, ta có hàm phân phối tích lũy thực nghiệm $\widehat{F}_n(y)$, tuy nhiên theo biểu thức (1.1), hàm này là không liên tục, do đó ta cần áp dụng xấp xỉ sai phân trung tâm (central difference approximation) với bước nhảy $h > 0$, khi này, ta có

$$\begin{aligned}\widehat{f}_n(y) &= \frac{\widehat{F}_n(y+h/2) - \widehat{F}_n(y-h/2)}{h} \\ &= \frac{1}{nh}\sum_{i=1}^{n} \mathrm{I}\left(\frac{|Y_i - y|}{h} \leq \frac{1}{2}\right). \end{aligned} \tag{2.1}$$

Ước lượng này được gọi là ước lượng mật độ tần số thực nghiệm (the histogram estimator) được đề xuất và nghiên cứu các tính chất thống kê bởi Freedman and Diaconis (1981). Tham số h được gọi là "độ rộng" (bandwidth). Ta dễ dàng kiểm chứng được hai tính chất (i) và (ii) cho $\widehat{f}_n(y)$ (xem thêm trong phụ lục ...).

Không giống như hàm phân phối tích lũy thực nghiệm, hàm mật độ tần số thực nghiệm bị ảnh hưởng bởi việc lựa chọn độ rộng h. Khi h càng nhỏ ($h \to 0$) thì hàm mật độ tần số thực nghiệm sẽ càng gấp khúc, trong khi giá trị lớn của h tạo ra ước lượng mật độ có vẻ trơn, tuy nhiên, nếu h

quá lớn thì tính chính xác của ước lượng không còn được đảm bảo. Freedman and Diaconis (1981) đề xuất một cách chọn h "tối ưu" là $h_{\text{opt,FD}} = 2\text{IQR}n^{-1/3}$.

Ví dụ 2.1. Ta xét lại bộ dữ liệu về các đặc tính của 20 mẫu lấy từ 20 lưu vực sông, trong Ví dụ 1.1. Hình 6 biểu diễn ước lượng mật độ tần số thực nghiệm cho dữ liệu đô pH của các lưu vực, tương ứng với bốn cách chọn h, lần lượt là $h = 0.25, 0.5, 0.75$ và $h_{\text{opt,FD}} \approx 0.7$. ■

Một trong những điểm hạn chế của phương pháp này là đường mật độ bị gấp khúc, không trơn gây mất tính thẩm mỹ. Hơn nữa, $\widehat{f}_n(y)$ là không liên tục, sẽ gây khó khăn cho các tính toán yêu cầu tính liên tục của ước lượng. Để khắc phục điều này, ta có thể thay thế hàm $\mathrm{I}\left(\dfrac{|Y_i - y|}{h} \leq \dfrac{1}{2}\right)$ bằng một hàm dương, trơn, liên tục, khả vi và quan trọng nhất là phải tạo ra ước lượng mật độ thỏa tính chất của hàm mật độ xác suất.

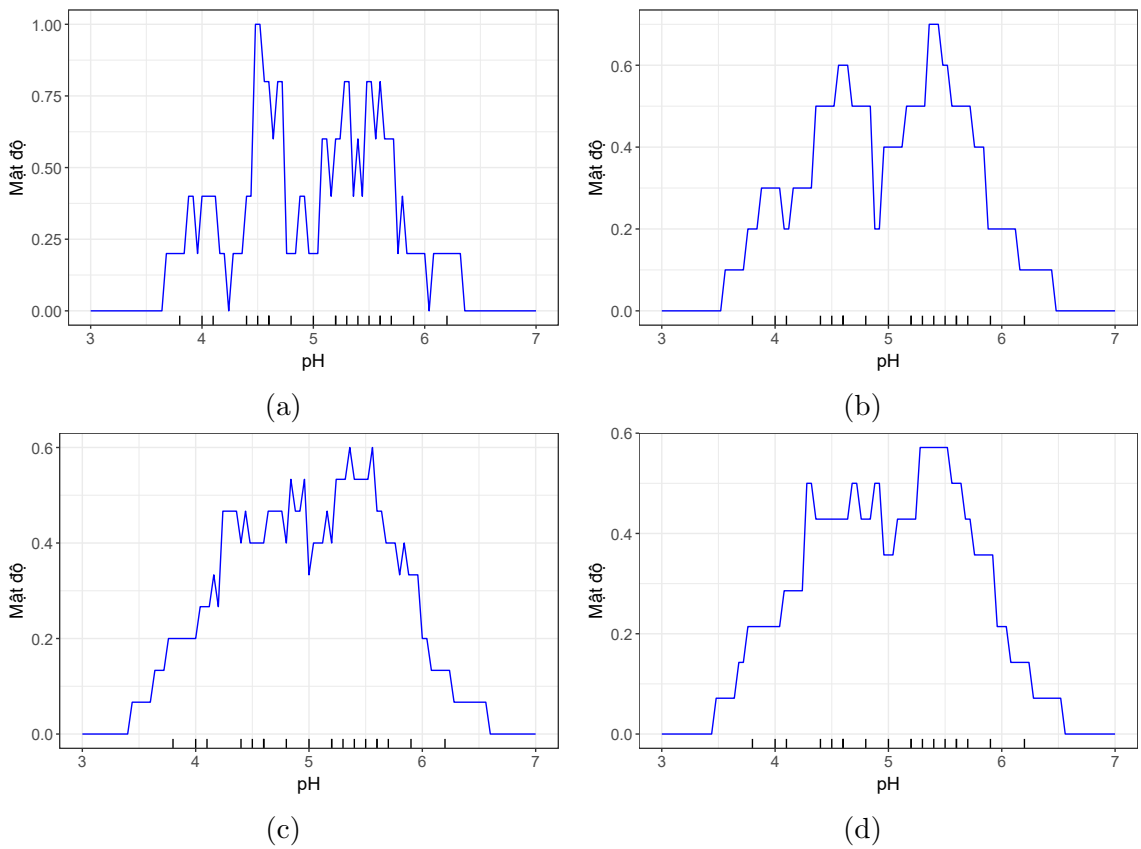

Hình 6 – *Ước lượng mật độ tần số thực nghiệm cho dữ liệu đô pH tại 20 lưu vực sông, tương ứng các trường hợp khác nhau của h. Hình (a) $h = 0.25$, hình (b) $h = 0.5$, hình (c) $h = 0.75$ và hình (d) h được chọn theo lựa chọn tối ưu $h_{\text{opt,FD}} \approx 0.7$.*

Xét hàm $k(u)$ sao cho thỏa các tính chất sau:

(i) $k(u) \geq 0$,

(ii) $k(u) = k(-u)$ (tính đối xứng),

(iii) $\displaystyle\int_{-\infty}^{+\infty} k(u)\mathrm{d}\,u = 1,$

(iv) $\displaystyle\int_{-\infty}^{+\infty} uk(u)\mathrm{d}\,u = 0.$

Hàm $k(u)$ như vậy được gọi là một hàm Kernel (hay hàm nhân). Ví dụ, $k(u) = 1$ nếu $|u| \leq 1/2$, chính là hàm $\mathrm{I}(|u| \leq 1/2)$. Khi đó, ước lượng hàm mật độ thực nghiệm trong (2.1) là một dạng đặc biệt của ước lượng hàm mật độ kernel (Kernel density estimation - KDE):

$$\widehat{f}_{K,n}(y) = \frac{1}{nh}\sum_{i=1}^{n} k\left(\frac{Y_i - y}{h}\right). \tag{2.2}$$

Ta dễ dàng kiểm chứng được $\widehat{f}_{K,n}(y)$ thỏa các tính chất của hàm mật độ xác suất $f(y)$. Có nhiều cách chọn hàm Kernel $k(u)$, tuy nhiên, hai cách chọn thông dụng nhất là:

- Gaussian kernel tức là $k(u) = \dfrac{1}{\sqrt{2\pi}}\exp\left(-\dfrac{u^2}{2}\right)$ với $u \in \mathbb{R}$, trong đó, $\exp(u)$ là hàm e^u,
- Epanechnikov kernel tức là $k(u) = 0.75(1 - u^2)$ với $|u| \leq 1$,

xem thêm các hàm Kernel khác trong phụ lục. Việc lựa chọn hàm Kernel không ảnh hưởng quá lớn tới kết quả của $\widehat{f}_{K,n}(y)$, tuy nhiên, giá trị độ rộng h khác nhau sẽ làm cho hình dạng của $\widehat{f}_{K,n}(y)$ thay đổi nhiều. Tính chất này là tương tự với ước lượng mật độ thực nghiệm. Một cách chọn h_{opt} cho ước lượng Kernel do Silverman (1986) đề xuất là

$$h_{opt,\mathrm{S}} = 0.9 \times \min\{s, \mathrm{IQR}/1.34\}\, n^{-1/5},$$

trong đó s là độ lệch chuẩn của dữ liệu. Chú ý rằng, cách chọn này tương ứng với hàm Gaussian kernel.

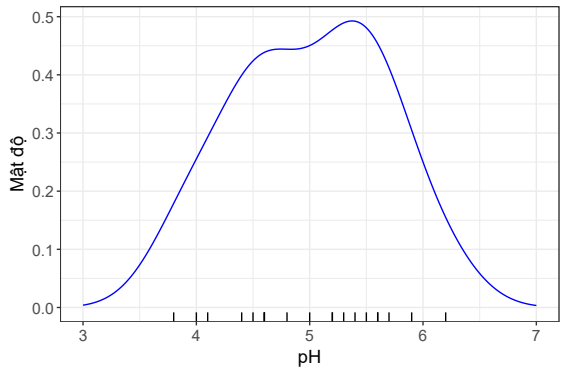

Hình 7 – *Ước lượng mật độ kernel cho dữ liệu độ pH tại 20 lưu vực sông với h được chọn theo lựa chọn tối ưu* $h_{\mathrm{opt,S}} \approx 0.33$ *và Gaussian kernel.*

Hình 7 và 8 biểu diễn ước lượng mật độ kernel cho độ pH của 20 mẫu tại 20 lưu vực sông và thời gian chờ phun trào (`waiting`) của mạch nước phun Old Faithful ở Công viên quốc gia Yellowston, Hoa Kỳ. Kết quả cho thấy ước lượng mật độ kernel là trơn, thể hiện rõ các đỉnh cũng như sự mật độ phân bố của dữ liệu.

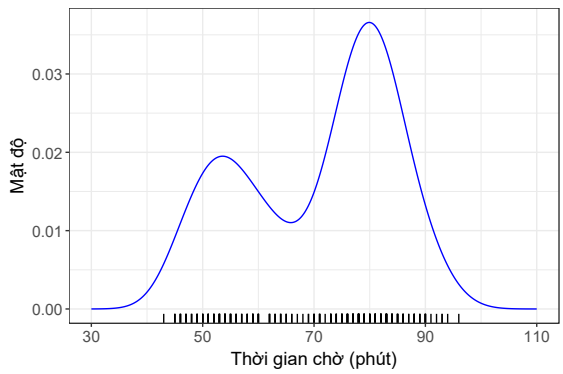

Hình 8 – *Ước lượng mật độ kernel cho dữ liệu về thời gian chờ phun trào (`waiting`) của mạch nước phun Old Faithful ở Công viên quốc gia Yellowston, Hoa Kỳ, với h được chọn theo lựa chọn tối ưu* $h_{\text{opt,S}} \approx 3.99$ *và Gaussian kernel.*

2.3 Biểu đồ hộp

Biểu đồ hộp (boxplot) là biểu đồ dùng để hiển thị các phân vị của dữ liệu, và xác định dựa trên quy trình như sau:

(1) sắp xếp dữ liệu tăng dần;

(2) xác định phân phối tích lũy thực nghiệm $\widehat{F}_n(y_i)$ tại điểm dữ liệu quan sát;

(3) xác định các điểm phân vị $Q_n(0.25)$, $Q_n(0.5)$ và $Q_n(0.75)$;

(4) tính giá trị khoảng tứ phân vị (Interquartile Range - IQR), $\text{IQR} = Q_n(0.75) - Q_n(0.25)$;

(5) xác định điểm giới hạn dưới

$$L = \max\left\{y_{(1)}, Q_n(0.25) - 1.5 \times \text{IQR}\right\},$$

và điểm giới hạn trên

$$U = \min\left\{y_{(n)}, Q_n(0.75) + 1.5 \times \text{IQR}\right\},$$

trong đó, $y_{(1)}$ và $y_{(n)}$ là giá trị nhỏ nhất và giá trị lớn nhất của dữ liệu

(6) vẽ hộp hình chữ nhật với cạnh giới hạn là $Q_n(0.25)$ và $Q_n(0.75)$ với $Q_n(0.5)$ nằm giữa, tạo đường nối từ cạnh $Q_n(0.25)$ tới L và từ $Q_n(0.75)$ tới U; biểu diễn các điểm dữ liệu nằm ngoài giới hạn L và U, những điểm này được xác định như là các giá trị ngoại lai (hay giá trị cực đoan) của dữ liệu.

Ví dụ 2.2. Xét lại dữ liệu độ pH của 20 mẫu đất tại 20 lưu vực sông trong Ví dụ 1.1. Ta xác định được các giá trị phân vị lần lượt là: $Q_1 = Q_n(0.25) = 4.55$, $Q_2 = Q_n(0.5) = 5.10$ và $Q_3 = Q_n(0.75) = 5.55$. Do đó $\text{IQR} = 1$, từ đây ta suy ra điểm giới hạn dưới và điểm giới hạn trên lần lượt là 3.8 và 6.2. Các điểm này hình thành nên biểu đồ boxplot như trong Hình 9. Ta nhận thấy rằng, dữ liệu có tính đối xứng qua median, đồng thời, ta không nhận thấy các mẫu quan sát có giá trị ngoại lai sao với các mẫu còn lại. ■

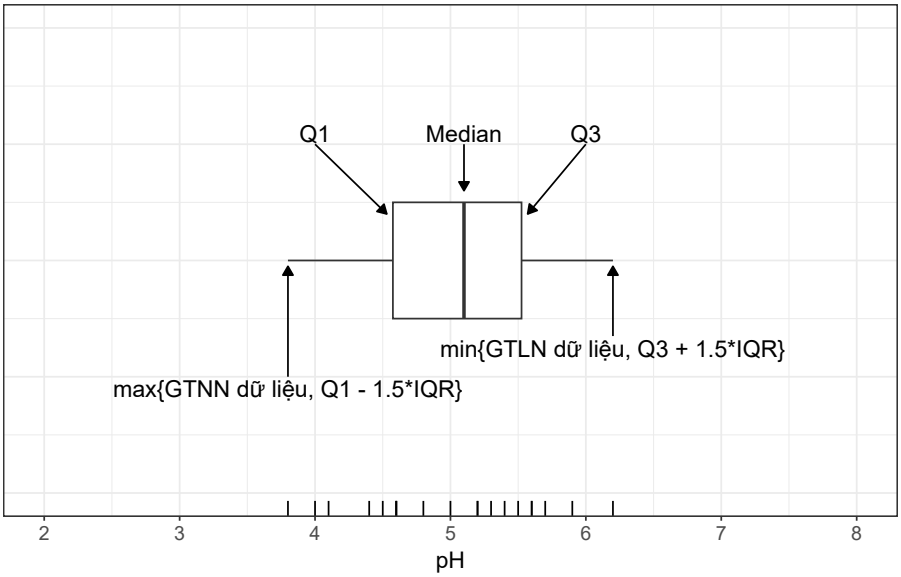

Hình 9 – *Biểu đồ boxplot cho dữ liệu về độ pH của 20 mẫu đất tại 20 lưu vực sông. Các ký hiệu tương ứng cho các điểm $Q_1 = Q_n(0.25)$, $Q_2 = Q_n(0.5)$, $Q_3 = Q_n(0.75)$, điểm giới hạn trên và điểm giới hạn dưới.*

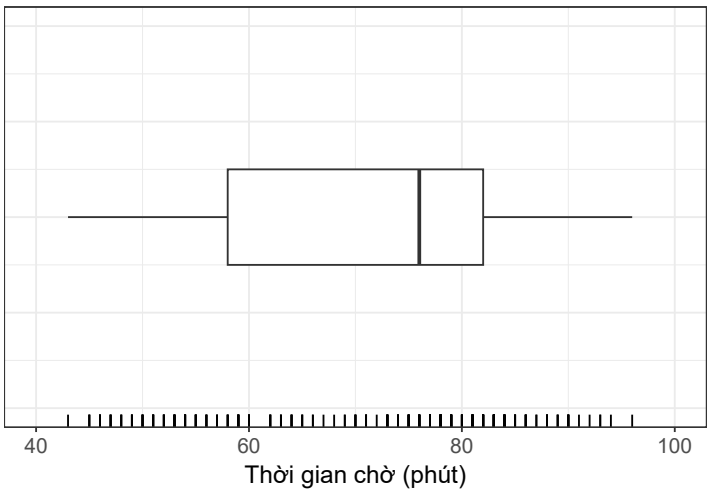

Hình 10 – *Biểu đồ boxplot cho dữ liệu về thời gian chờ phun trào (`waiting`) của mạch nước phun Old Faithful ở Công viên quốc gia Yellowston, Hoa Kỳ.*

Ví dụ 2.3. Xét lại dữ liệu về thời gian chờ phun trào (`waiting`) của mạch nước phun Old Faithful ở Công viên quốc gia Yellowston, Hoa Kỳ, được trình bày trong Ví dụ 1.2. Ta xác định được các giá trị phân vị lần lượt là: $Q_1 = Q_n(0.25) = 58$, $Q_2 = Q_n(0.5) = 76$ và $Q_3 = Q_n(0.75) = 82$. Do đó IQR $= 24$, từ đây ta suy ra điểm giới hạn dưới và điểm giới hạn trên lần lượt là 43 và 96. Các điểm này hình thành nên biểu đồ boxplot như trong Hình 10.

Ta nhận thấy rằng, dữ liệu không có tính đối xứng qua median, cụ thể có 25% giá trị tập trung trong 1 khoảng ngắn (độ dài là 6 đơn vị) từ trung vị Q_2 tới phân vị thứ 3 Q_3, trong khi 25% giá trị tập trung trong 1 khoảng dài (độ dài là 18 đơn vị) từ phân vị thứ 1 Q_1 tới trung vị Q_2, tức là mật độ phân bố dữ liệu từ Q_1 tới Q_2 là thưa thớt hơn so với từ Q_2 tới Q_3, hay nói các khác, dữ liệu tập trung nhiều dày hơn ở bên phải của median; đồng thời, ta không nhận thấy các mẫu quan sát có giá trị ngoại lai sao với các mẫu còn lại. ■

Một trong những hạn chế của boxplot, đó là nó không cung cấp được thông tin rằng mật độ của dữ liệu có thể có bao nhiêu mode (đỉnh). Chẳng hạn với dữ liệu `waiting` trong về thời gian chờ phun trào của mạch nước phun Old Faithful, theo Hình 8, ta thấy rằng mật độ có hai đỉnh, tuy nhiên, nếu nhìn vào biểu đồ boxplot trong Hình 10, ta không nhận ra được điều này. Do đó, ta thường kết hợp sử dụng biểu đồ mật độ xác suất và biểu đồ boxplot với nhau nhằm có cái nhìn tổng quát nhất về phân phối của dữ liệu.

3 Chuyển đổi dữ liệu

3.1 Vấn đề với dữ liệu có giá trị giới hạn

Đối với dữ liệu địa chất, như đã giới thiệu trong bài 1, ta có 3 loại cho dữ liệu số: (i) đại lượng Descartes (Cartesian quantities) tức là số thực; (ii) đại lượng Jeffreys (Jeffreys quantities) tức là các số thuộc $(0, +\infty)$; (iii) tỷ lệ (Proportions) tức là các số thuộc $(0, 1)$. Đối với các dữ liệu dạng số thực, việc biểu diễn hàm mật độ kernel là không gặp vấn đề, tuy nhiên với các giá trị dạng Jeffreys và tỷ lệ, thì biểu đồ hàm mật độ kernel sẽ biểu diễn cả phần nằm ngoài miền xác định.

Ví dụ 3.1. Xét lại dữ liệu của 20 mẫu đất tại 20 lưu vực sông trong Ví dụ 1.1. Ta quan tâm tới tỷ số hàm lượng Ca/Mg trong đất (`Ca/Mg`), giá trị quan sát được là một đại lượng dương, với giá trị nhỏ nhất là 0.35 và giá trị lớn nhất là 11.00. Hình 11 biểu diễn mật độ dữ liệu được ước lượng bởi phương pháp kernel với Gaussian kernel cùng độ rộng tối ưu. Ta có thể thấy rằng vùng biểu diễn dữ liệu bị mở rộng chứa cả các giá trị âm và mật độ cho vùng này là tương đối lớn, điều này ám chỉ rằng tỷ số hàm lượng Ca/Mg trong đất có thể có cả số âm, một điều không thể. ■

Ví dụ 3.2. Xét lại dữ liệu của 20 mẫu đất tại 20 lưu vực sông trong Ví dụ 1.1. Ta quan tâm tới tỷ lệ phủ của thảm thực vật (`vegetation`), giá trị quan sát được là một đại lượng tỷ lệ %, với giá trị nhỏ nhất là 3.8% và giá trị lớn nhất là 95%. Hình 12 biểu diễn mật độ dữ liệu được ước lượng bởi phương pháp kernel với Gaussian kernel cùng độ rộng tối ưu. Ta có thể thấy rằng vùng biểu diễn dữ liệu bị mở rộng chứa cả các giá trị bé hơn 0% và lớn hơn 100%, đồng thời mật độ cho các vùng này là tương đối lớn, điều này ám chỉ rằng tỷ lệ phần trăm độ phủ của thảm thực vật có thể có cả số âm hoặc lớn hơn 100%, một điều không thể. ■

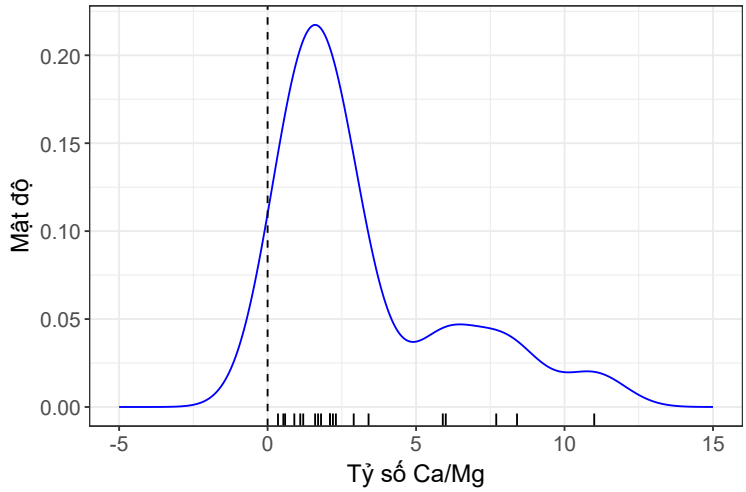

Hình 11 – *Mật độ dữ liệu về tỷ số hàm lượng Ca/Mg trong 20 mẫu đất, ước lượng bởi phương pháp kernel với Gaussian kernel cùng độ rộng tối ưu.*

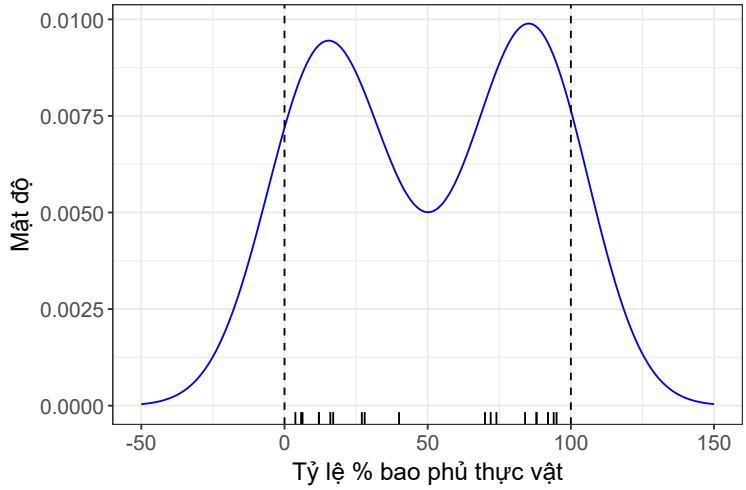

Hình 12 – *Mật độ dữ liệu về tỷ lệ phủ của thảm thực vật (`vegetation`) của 20 mẫu đất, ước lượng bởi phương pháp kernel với Gaussian kernel cùng độ rộng tối ưu.*

Vấn đề này thường phát sinh do ước lượng mật độ kernel thực hiện cho dữ liệu là đại lượng Descartes, do đó, phương pháp này sẽ xét toàn bộ vùng giá trị của y từ $-\infty$ tới $+\infty$ để ước lượng $\widehat{f}_{K,n}(y)$. Để khắc phục điều này, ta có thể áp dụng các chuyển đổi dữ liệu từ 1 vùng bị giới hạn về miền số thực $(-\infty, +\infty)$, sau đó, áp dụng ước lượng mật độ kernel cho dữ liệu đã chuyển đổi, cuối cùng áp dụng công thức mật độ cho dữ liệu ban đầu thông qua công thức hàm mật độ của phép đổi biến. Chi tiết được trình bày trong phần sau.

3.2 Hàm mật độ cho phép đổi biến

Gọi Y là biến ngẫu nhiên sao cho miền xác định $\mathcal{Y}$ của nó là bị chặn, chẳng hạn, $(0, +\infty)$ hoặc $(0, 1)$. Xét một hàm đơn điệu $g(\cdot)$ từ $\mathcal{Y}$ vào trong $\mathbb{R}$ sao cho tồn tại hàm ngược $g^{-1}(\cdot)$, $g(\cdot)$ và $g^{-1}(\cdot)$ là khả vi (tức là tồn tại đạo hàm). Đặt $X = g(Y)$, và $f_X(x)$ là hàm mật độ xác suất của X. Khi đó, hàm mật độ xác suất của $Y = g^{-1}(X)$ được xác định bởi

$$f_Y(y) = f_X(g(y)) \left| \frac{\mathrm{d}}{\mathrm{d}\, y} g(y) \right|. \tag{3.1}$$

Áp dụng cho ước lượng mật độ kernel, ta có ước lượng mật độ kernel của Y được xác định bởi ước lượng mật độ kernel của X:

$$\widehat{f}_{K,n,Y}(y) = \widehat{f}_{K,n,X}(g(y)) \left| \frac{\mathrm{d}}{\mathrm{d}\, y} g(y) \right|. \tag{3.2}$$

Ví dụ, với $Y \in (0; +\infty)$ tức là đại lượng Jeffreys, phép biến đổi $g(y) = \log(y)$ sẽ cho giá trị thuộc $(-\infty, +\infty)$, biến đổi này còn được gọi là biến đổi log - *log transformation*. Khi đó, với $X = \log(Y)$ thì ta có $Y = g^{-1}(X) = \exp(X)$. Áp dụng biểu thức (3.1) ta thu được hàm mật độ xác suất cho Y là:

$$f_Y(y) = f_X\left(\log(y)\right) \frac{1}{y},$$

với $y \in (0, +\infty)$. Dẫn tới ước lượng mật độ kernel của Y là

$$\widehat{f}_{K,n,Y}(y) = \widehat{f}_{K,n,X}\left(\log(y)\right) \frac{1}{y}. \tag{3.3}$$

Khi $Y \in (0, 1)$ tức là Y là tỷ lệ, phép biến đổi $g(y) = \log\left(\dfrac{y}{1-y}\right)$ sẽ cho giá trị thuộc $(-\infty, +\infty)$, biến đổi này còn được gọi là biến đổi logistic - *logistic transformation* (hay logit). Khi đó, với $X = \log\left(\dfrac{Y}{1-Y}\right)$ thì ta có $Y = g^{-1}(X) = \dfrac{\exp(X)}{1+\exp(X)}$. Áp dụng biểu thức (3.1) ta thu được hàm mật độ xác suất cho Y là:

$$f_Y(y) = f_X\left(\log\left(\frac{y}{1-y}\right)\right) \frac{1}{y(1-y)},$$

với $y \in (0, 1)$. Dẫn tới ước lượng mật độ kernel của Y là

$$\widehat{f}_{K,n,Y}(y) = \widehat{f}_{K,n,X}\left(\log\left(\frac{y}{1-y}\right)\right) \frac{1}{y(1-y)}. \tag{3.4}$$

Ta áp dụng các kết quả này cho các ví dụ trên.

Ví dụ 3.3. Xét lại dữ liệu về tỷ số hàm lượng Ca/Mg trong đất (`Ca/Mg`) của 20 mẫu đất tại 20 lưu vực sông trong Ví dụ 1.1. Giá trị của tỷ số là đại lượng Jeffreys, nên ta áp dụng biến đổi log, tức là log(Ca/Mg). Khi đó, ước lượng mật độ kernel của dữ liệu biến đổi được xác định bởi Gaussian kernel và độ rộng tối ưu như trong Hình 13 (a). Sau đó, áp dụng biểu thức (3.3), ta thu được ước lượng mật độ kernel cho tỷ số hàm lượng Ca/Mg như trong Hình 13 (b). Ta nhận thấy rằng mật độ kernel sau biến đổi dữ liệu có hình dạng phù hợp hơn với dữ liệu thực tế, đồng thời đảm bảo miền xác định theo bản chất vốn có của dữ liệu, tức là $(0, +\infty)$. ■

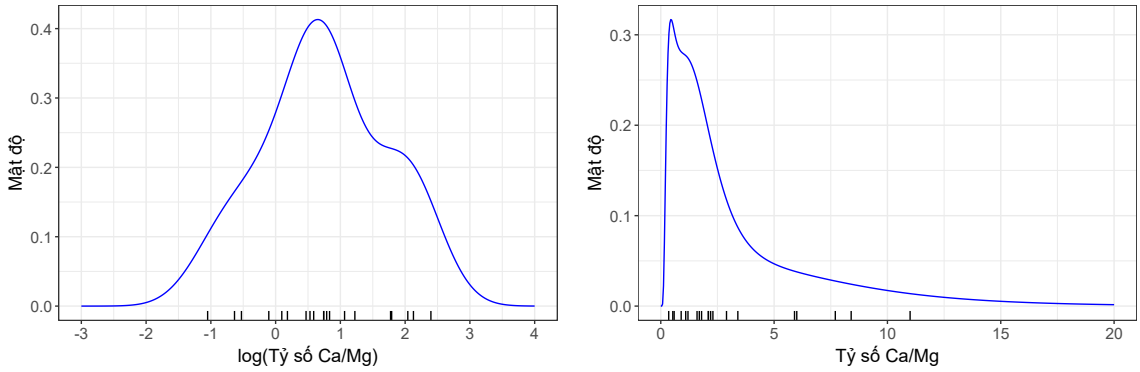

(a) (b)

Hình 13 – *Hình (a): mật độ cho dữ liệu về tỷ số hàm lượng Ca/Mg trong 20 mẫu đất sau khi biến đổi log, ước lượng bởi phương pháp kernel với Gaussian kernel cùng độ rộng tối ưu. Hình (b): mật độ cho dữ liệu về tỷ số hàm lượng Ca/Mg trong 20 mẫu đất áp dụng công thức biến đổi (3.3).*

Ví dụ 3.4. Xét lại dữ liệu về tỷ lệ phủ của thảm thực vật (`vegetation`) của 20 mẫu đất tại 20 lưu vực sông trong Ví dụ 1.1. Giá trị quan sát được là một đại lượng tỷ lệ %, do đó, ta thực hiện chia dữ liệu này cho 100, để có miền giá trị là $(0, 1)$. Tiếp theo, ta áp dụng biến đổi logistic, tức là $\log\left(\frac{\texttt{vegetation}/100}{1-\texttt{vegetation}/100}\right)$. Khi đó, ước lượng mật độ kernel của dữ liệu biến đổi được xác định bởi Gaussian kernel và độ rộng tối ưu như trong Hình 14 (a). Sau đó, áp dụng biểu thức (3.4), ta thu được ước lượng mật độ kernel cho tỷ lệ phủ của thảm thực vật (`vegetation`) như trong Hình 14 (b). Ta nhận thấy rằng mật độ kernel sau biến đổi dữ liệu có hình dạng phù hợp hơn với dữ liệu thực tế, đồng thời đảm bảo miền xác định theo bản chất vốn có của dữ liệu, tức là từ 0% đến 100%. ■

4 Các biểu đồ đặc biệt

Trong các phần trước, chúng ta đã làm quen với các biểu đồ trực quan cơ bản để hiểu và biểu diễn được dữ liệu với các thông tin quan trọng về hình thái, xu hướng và mật độ phân bố của dữ liệu địa chất thông dụng. Tuy nhiên, trong lĩnh vực khoa học địa chất, hay khoa học trái đất, ta còn có các loại dữ liệu đặc hữu như: dự liệu thành phần (compositional data) và dữ liệu có hướng (directional data). Để trực quan được các loại dữ liệu này, chúng ta cần các loại biểu đồ đặc biệt nhằm làm nổi bật các tính chất đặc trưng cũng như phân bố của dữ liệu.

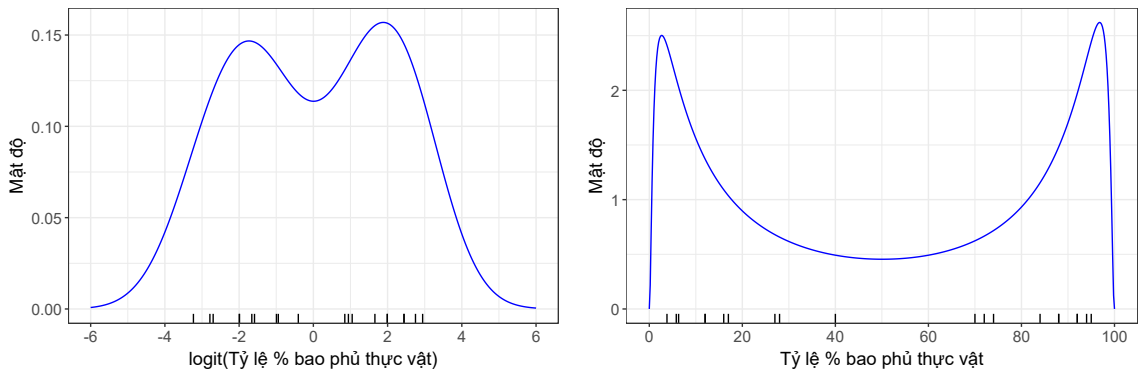

(a) (b)

Hình 14 – *Hình (a): mật độ cho dữ liệu về tỷ số hàm lượng Ca/Mg trong 20 mẫu đất sau khi biến đổi log, ước lượng bởi phương pháp kernel với Gaussian kernel cùng độ rộng tối ưu. Hình (b): mật độ cho dữ liệu về tỷ số hàm lượng Ca/Mg trong 20 mẫu đất áp dụng công thức biến đổi (3.3).*

4.1 Biểu đồ tam phân

Biểu đồ tam phân (Ternary diagram) một dạng biểu đồ có khung là tam giác đều dùng để biểu diễn dữ liệu thành phần gồm **ba** thành phần sao cho tổng tỷ lệ của ba thành phần này luôn bằng 1 (hay 100%).

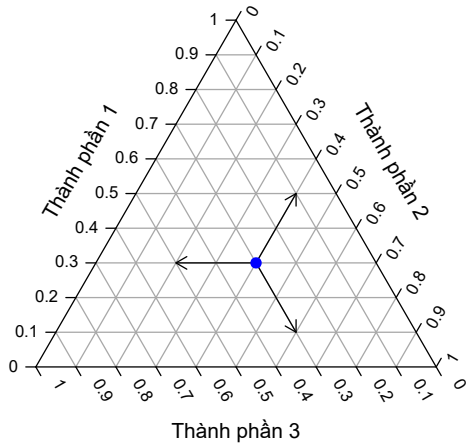

Hình 15 – *Biểu đồ tam phân cho dữ liệu 3 thành phần. Điểm màu xanh biểu diễn giá trị của dữ liệu tỷ lệ của 3 thành phần là* $(0.3, 0.4, 0.3)$ *lần lượt của thành phần 1, thành phần 2 và thành phần 3.*

Mỗi cạnh của tam giác đều luôn biểu diễn tỷ lệ cho 1 thành phần, có giới hạn từ 0 tới 1, xem Hình 15. Trong đó, thứ tự của các thành phần trong các trục lần lượt từ trái qua phải và từ trên xuống dưới. Điểm màu xanh trong Hình 15 biểu diễn giá trị của dữ liệu tỷ lệ của 3 thành phần là $(0.3, 0.4, 0.3)$ lần lượt của thành phần 1, thành phần 2 và thành phần 3. Các mũi tên chỉ thị hướng

đối chiếu giá trị của điểm dữ liệu trên trục số. Đỉnh trên cùng tương ứng với các giá trị lớn của thành phần 1 (và giá trị nhỏ cho thành phần 2 và 3); đỉnh bên phải tương ứng với các giá trị lớn của thành phần 2 (và giá trị nhỏ cho thành phần 1 và 3); đỉnh bên trái tương ứng với các giá trị lớn của thành phần 3 (và giá trị nhỏ cho thành phần 1 và 2).

Ví dụ 4.1. A-CN-K dataset là dữ liệu về thành phần oxit chính (major oxides) của vật liệu địa chất (đá, đất, trầm tích), được chuẩn hóa theo phần trăm mol (% mol) để so sánh quá trình phong hóa hóa học. Cụ thể:

- A tương ứng Al_2O_3 (nhôm oxit);
- CN tương ứng $CaO + Na_2O$ (canxi và natri oxit, đại diện cho plagioclase feldspar)
- K tương ứng K_2O (kali oxit, đại diện cho K-feldspar hoặc mica)

Dữ liệu này thường được dùng cho các mục đích khoa học địa chất bao gồm: (1) theo dõi mức độ phong hóa hóa học (chemical weathering intensity); (ii) phân biệt các giai đoạn phong hóa của khoáng vật silicat (feldspar → kaolinite → gibbsite, ...); (iii) xác định nguồn gốc (provenance) và quá trình biến đổi trầm tích. Xét bộ dữ liệu A-CN-K của 20 mẫu trầm tích được tổng hợp trong Bảng 3. Trong đó, tổng của mỗi dòng là bằng 1.

id	Al_2O_3	$CaO + Na_2O$	K_2O
1	0.796	0.057	0.147
2	0.494	0.496	0.010
3	0.627	0.366	0.007
4	0.838	0.024	0.138
5	0.711	0.271	0.018
6	0.762	0.018	0.220
7	0.722	0.013	0.265
8	0.672	0.012	0.317
9	0.772	0.150	0.078
10	0.611	0.381	0.008
11	0.815	0.150	0.035
12	0.836	0.138	0.027
13	0.816	0.087	0.097
14	0.856	0.013	0.131
15	0.828	0.156	0.016
16	0.824	0.077	0.099
17	0.809	0.169	0.023
18	0.850	0.035	0.115
19	0.808	0.013	0.179
20	0.739	0.241	0.019

Bảng 3 – *Dữ liệu phân tích A-CN-K của 20 mẫu địa chất.*

Biểu đồ tâm phân biểu diễn sự phân bố của 3 thành phần: Al_2O_3, $CaO + Na_2O$ và K_2O như trong Hình 16. Biểu đồ tam phân cho thấy rằng tất cả 20 mẫu vật đều có tỷ lệ Al_2O_3 cao, trong

khi đó, tỷ lệ của CaO + Na_2O và K_2O đều ở mức thấp (các điểm dữ liệu tập trung gần đỉnh trên - tương ứng là của Al_2O_3), đặc biệt, có những mẫu vật có tỷ lệ của hai thành phần này ở mức rất thấp (gần như bằng 0). Điều này cho thấy tất cả các mẫu vật này đang ở mức phong hóa rất mạnh. Thêm vào đó, tỷ lệ Al_2O_3 cao ám chỉ rằng sự hiện diện của các khoáng vật của nhôm như: Kaolinite[1] và Gibbsite[2]. ■

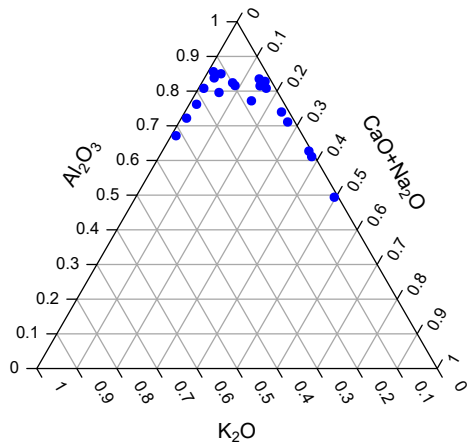

Hình 16 – *Biểu đồ tam phân cho dữ liệu 3 thành phần: Al_2O_3, CaO + Na_2O và K_2O. Điểm màu xanh biểu diễn giá trị của dữ liệu theo tỷ lệ mol.*

4.2 Biểu đồ hoa hồng

Biểu đồ hoa hồng (Rose diagram) là một công cụ cực kỳ phổ biến trong địa chất để mô tả hướng của các đặc trưng như khe nứt, lớp đá, phương trượt, hay phương vị hạt sa trầm. Nó được áp dụng cho dữ liệu có hướng (directional data), tức là các dữ liệu mô tả phương hoặc hướng của các đặc trưng trong không gian.

Biểu đồ hoa hồng là một dạng biểu đồ tròn dùng để biểu diễn phân bố hướng (orientation) của các đặc trưng trong không gian. Mỗi cánh hoa (hướng) biểu thị số lượng hoặc tần số của các quan sát có hướng tương ứng. Dữ liệu thường ở dạng góc (°), ví dụ: phương vị khe nứt, hướng dòng chảy, phương lớp đá, v.v.

Các thành phần chính của biểu đồ hoa hồng bao gồm:

- tâm biểu đồ hay điểm gốc;
- các cánh tương đương các hướng địa lý, được biểu thị theo góc của 1 cung tròn từ 0° tới 360°;
- chiều dài cánh biểu thị số lượng (hoặc phần trăm) dữ liệu được quan sát trong hướng đó.
- độ rộng của các khoảng góc (bin width) được chia theo độ, ví dụ: 10°, 15°, 20°, ...

[1] https://vi.wikipedia.org/wiki/Kaolinit
[2] https://vi.wikipedia.org/wiki/Gibbsit

Các góc trong biểu đồ hoa hồng tương ứng với các phương hướng địa lý, cụ thể, 0° (hay 360°) là phương Bắc, 90° là phương Đông, 180° là phương Nam và 270° là phương Tây; thêm vào đó, ta cũng có, 0° – 90° tương ứng Đông Bắc, 90° – 180° tương ứng Đông Nam, 180° – 270° tương ứng Tây Nam, và 270° – 360° tương ứng Tây Bắc. Càng nhiều dữ liệu tập trung ở một hướng thì biểu đồ hoa hồng càng "nở" về hướng đó.

Ví dụ 4.2. Xét dữ liệu về hướng (theo độ góc) của 30 vết rạn băng hà (glacial striation[3]) được đo đạc tại quốc đảo Madagascar.

44	51	79	65	27	31	4	355	22	352	287	7	287	339	0
276	342	355	334	296	7	17	351	349	37	339	40	324	325	334

Sử dụng biểu đồ hoa hồng, ta biểu diễn được xu hướng tập trung của dữ liệu theo phương địa lý như trong Hình 17. Kết quả cho thấy, các vết rạn băng hà tập trung theo hướng Bắc, cụ thể tần số của các vết rạn xuất hiện xung quanh hướng 0° là nhiều hơn các hướng khác, và các vết rạn xuất hiện từ Tây Bắc (276°) đến Đông Bắc (79°). ■

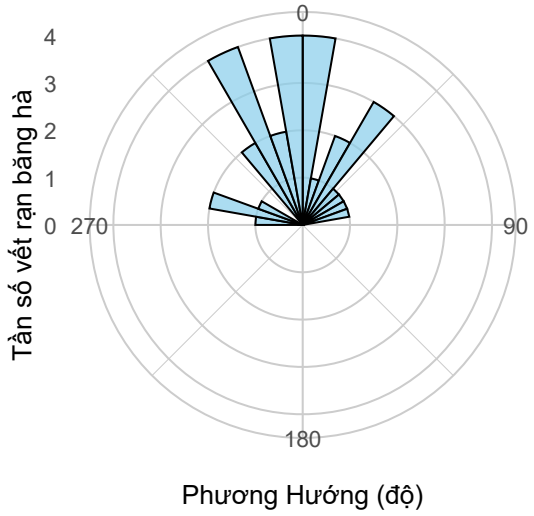

Hình 17 – *Biểu đồ hoa hồng biểu diễn phân bố vết rạn băng hà tại Madagascar theo các phương hướng địa lý.*

Tài liệu tham khảo

Freedman, D. and Diaconis, P. (1981). On the histogram as a density estimator: L_2 theory. *Zeitschrift für Wahrscheinlichkeitstheorie und verwandte Gebiete*, 57(4):453–476.

Silverman, B. W. (1986). *Density Estimation.* Chapman and Hall.

[3] https://en.wikipedia.org/wiki/Glacial_striation