Bài giảng 03: Kỹ thuật trực quan hóa dữ liệu đa chiều

TS. Tô Đức Khánh[1]

[1] *Khoa Toán-Tin học, Trường Đại học Khoa học tự nhiên, ĐHQG-HCM*

Ngày 21 tháng 12 năm 2025

Mục lục

1 Dữ liệu nhiều chiều và vector ngẫu nhiên **2**

2 Khám phá quy luật phân bố dữ liệu đa chiều **4**

2.1 Biểu đồ phân tán 4

2.2 Biểu đồ mật độ hai chiều 6

2.3 Biểu đồ tương quan 7

2.4 Biểu đồ hộp đa nhóm 11

2.5 Biểu đồ violin 12

3 Phương pháp giảm số chiều **13**

3.1 Phương pháp phân tích thành phần chính - PCA 14

3.1.1 Ma trận hiệp phương sai 14

3.1.2 Quy trình PCA 17

3.2 Biểu đồ biplot 19

1 Dữ liệu nhiều chiều và vector ngẫu nhiên

Định nghĩa 1.1. Một vector ngẫu nhiên p-chiều là kết quả của p phép đo để ghi nhận lại p tính chất khác nhau của một đối tượng được lựa chọn ngẫu nhiên. Giá trị của vector ngẫu nhiên là vector bất kỳ trong không gian $\mathbb{R}^p$. Một vector p chiều được ký hiệu là $\mathbf{X} = (X_1, \ldots, X_p)$, trong đó, X_i là một biến ngẫu nhiên đại diện cho kết quả của một phép đo của đối tượng, với $i = 1, \ldots, p$. ■

Xét về mặt giá trị số, ta cơ bản chia vectơ ngẫu nhiên thành ba loại:

- vector ngẫu nhiên **rời rạc** - tất cả các biến thành phần là rời rạc;
- vector ngẫu nhiên **liên tục** - tất cả các biến thành phần là liên tục;
- vector ngẫu nhiên **hỗn hợp** - biến thành phần là liên tục hoặc rời rạc.

Định nghĩa 1.2. Dữ liệu nhiều chiều hay cụ thể hơn là vector giá trị ghi nhận (đo đạc) được của nhiều biến (tính chất) của đối tượng chính là giá trị quan sát thực tế của một vector ngẫu nhiên.

Do đó, một vector giá trị là tập hợp của nhiều biến trong dữ liệu chính là phiên bản **thực nghiệm** một vector ngẫu nhiên.

Ví dụ 1.1. Xét bộ dữ liệu phân tích mẫu địa chất lưu vực sông được tổng hợp trong Bảng 1. Có tất cả 6 biến (tương ứng 6 tính chất) được ghi chép lại, bao gồm

- X_1: lithology - thành phần đá của nền đá bên dưới;
- X_2: age - tuổi địa tầng của nền đá bên dưới;
- X_3: springs - số lượng suối tự nhiên trong lưu vực;
- X_4: pH - độ pH của nước sông;
- X_5: Ca/Mg - tỷ lệ Calcium so với Magnesium;
- X_6: vegetation - tỷ lệ diện tích lưu vực được bao phủ bởi thảm thực vật.

Do đó, ta có thể có các vector ngẫu nhiên sau:

- $\mathbf{Y}_1 = (X_1, X_2, X_5)$ thể hiện ghi chép đồng thời cho thành phần đá (lithology) cùng với tuổi địa tầng (age) và tỷ số Ca/Mg;
- $\mathbf{Y}_2 = (X_3, X_4, X_6)$ thể hiện ghi chép đồng thời cho số lượng dòng suối, nồng độ pH và % diện tích bao phủ bởi thực vật;
- $\mathbf{Y}_3 = (X_1, X_2)$ thể hiện ghi chép đồng thời cho thành phần đá (lithology) cùng với tuổi địa tầng (age).

Theo định nghĩa này, vector $\mathbf{Y}_1$ và $\mathbf{Y}_2$ đều là các vector ngẫu nhiên hỗn hợp, trong khi, $\mathbf{Y}_3$ là vector ngẫu nhiên rời rạc. Giá trị trên 1 dòng của bảng dữ liệu tương ứng là vector giá trị của các vector ngẫu nhiên. Chẳng hạn, với quan sát thứ nhất (`id` $= 1$), ta có giá trị của vector $\mathbf{Y}_1$ là $\boldsymbol{y}_{1,1} = (\text{basalt}, \text{Cz}, 0.35)$; hay với quan sát thứ 9, $\boldsymbol{y}_{1,9} = (\text{shale}, \text{Mz}, 5.90)$; tương tự, ta cũng có vector giá trị cho $\mathbf{Y}_2$ của quan sát thứ nhất và thứ 9 là $\boldsymbol{y}_{2,1} = (0, 6.2, 5.8)$, và $\boldsymbol{y}_{2,9} = (1, 3.8, 17)$.

id	lithology	age	springs	pH	Ca/Mg	vegetation
1	basalt	Cz	0	6.2	0.35	5.8
2	granite	Mz	1	4.4	11.00	28
3	basalt	Mz	0	5.6	6.00	12
4	sandstone	Cz	6	5.2	1.80	27
5	shale	pC	3	4.5	2.30	40
6	basalt	Mz	1	5.4	0.59	12
7	shale	Pz	2	4.8	8.40	3.8
8	basalt	Pz	0	5.9	2.90	6.3
9	shale	Mz	1	3.8	5.90	17
10	shale	Mz	2	4.0	2.10	16
11	sandstone	Pz	4	5.0	1.20	95
12	shale	pC	2	4.1	2.10	94
13	sandstone	Mz	4	5.2	1.10	92
14	basalt	Cz	1	5.5	1.60	88
15	sandstone	Pz	4	5.3	0.90	88
16	granite	Pz	0	4.6	1.70	70
17	basalt	Mz	0	5.7	3.40	92
18	shale	Pz	1	4.6	0.53	72
19	granite	Mz	0	4.6	2.20	74
20	basalt	Cz	1	5.6	7.70	84

Bảng 1 – *Dữ liệu phân tích mẫu địa chất tại 20 lưu vực sông.*

■

Ví dụ 1.2. Xét bộ dữ liệu về thời gian chờ giữa các lần phun trào (`waiting`, đơn vị phút) và thời gian phun trào (`eruptions`, đơn vị giây) của mạch nước phun Old Faithful ở Công viên quốc gia Yellowstone, Wyoming, Hoa Kỳ, được cung cấp trong Bảng 2. Có tổng cộng 272 quan sát được thực hiện. Đặt X_1 là `eruptions` - thời gian phun trào; và X_2 là `waiting` - thời gian chờ giữa các lần phun trào. Ta có vector ngẫu nhiên $\mathbf{X} = (X_1, X_2)$ cung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó.

■

id	eruptions	waiting
1	3.600	79
2	1.800	54
⋮	⋮	⋮
271	1.817	46
272	4.467	74

Bảng 2 – *Một phần dữ liệu quan sát của thời gian chờ giữa các lần phun trào và thời gian phun trào của mạch nước phun Old Faithful ở Công viên quốc gia Yellowstone, Wyoming, Hoa Kỳ.*

2 Khám phá quy luật phân bố dữ liệu đa chiều

2.1 Biểu đồ phân tán

Biểu đồ phân tán là biểu đồ điểm hai chiều, trong đó trục `x` và trục `y` là tương ứng với một biến định lượng (có thể rời rạc hoặc liên tục), dữ liệu được biểu diễn bởi các điểm tương ứng theo tọa độ $(\mathtt{x}, \mathtt{y})$ của từng quan sát trong bộ dữ liệu.

Ví dụ 2.1. Xét bộ dữ liệu phân tích 20 mẫu địa chất tại 20 lưu vực sông trong Bảng 1 của Ví dụ 1.1. Ta quan tâm tới vector ngẫu nhiên $\mathbf{Y} = (X_4, X_5)$, trong đó, X_4 là biến biểu thị nồng độ pH của nước sông (`pH`), X_5 là biến biểu thị cho tỷ lệ Calcium so với Magnesium (`Ca/Mg`). Hai biến này đều là biến ngẫu nhiên dạng số (định lượng). Biểu đồ phân tán trong Hình 1. ■

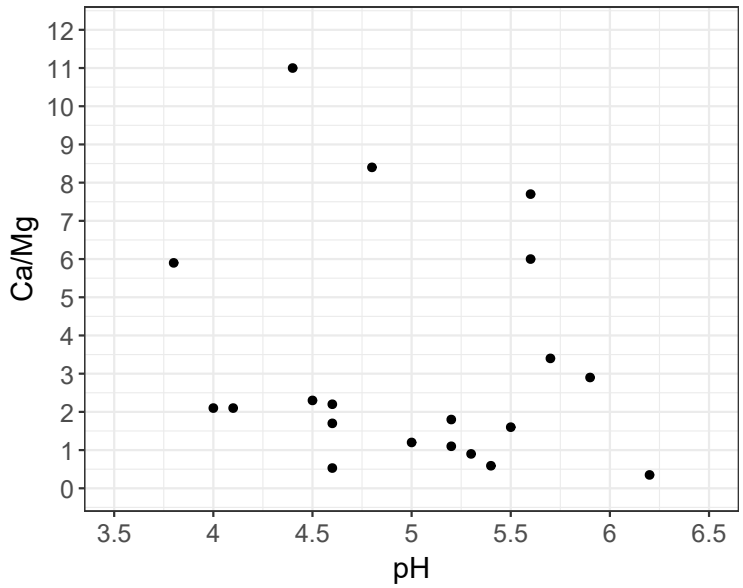

Hình 1 – *Biểu đồ phân tán cho hai biến ngẫu nhiên, `pH` biến biểu thị nồng độ pH của nước sông, `Ca/Mg` là biến biểu thị cho tỷ lệ Calcium so với Magnesium, trong dữ liệu tại Bảng 1.*

Biểu đồ phân tán thường được dùng với các mục đích:

1. xác định mối quan hệ giữa hai biến định lượng, tức là cho biết hai biến có liên hệ tuyến tính, phi tuyến hay không có mối liên hệ nào rõ ràng;
2. phát hiện xu hướng, tức là cho thấy các điểm dữ liệu có xu hướng phân bổ theo chiều tăng hoặc giảm của các trục, hoặc không có xu hướng rõ ràng (phân tán ngẫu nhiên trên biểu đồ);
3. phát hiện các giá trị cực đoan hay ngoại lai, tức là những điểm nằm tách biệt khỏi đám mây điểm chính có thể là dữ liệu bất thường hoặc sai sót đo lường;
4. đánh giá mức độ phân tán và mật độ dữ liệu, tức là quan sát xem dữ liệu tập trung ở vùng nào, có bị chệch hay phân tán rộng không, hoặc có xu hướng phân thành các cụm;
5. so sánh nhóm (khi thêm biến phân loại), tức là khi thêm màu hoặc ký hiệu khác nhau cho từng nhóm, biểu đồ giúp so sánh mối quan hệ giữa hai biến trong từng nhóm.

Ví dụ 2.2. Xét lại vector ngẫu nhiên $\mathbf{Y} = (X_4, X_5)$, trong đó, X_4 là biến biểu thị nồng độ pH của nước sông (`pH`), X_5 là biến biểu thị cho tỷ lệ Calcium so với Magnesium (`Ca/Mg`). Biểu đồ phân tán trong Hình 2 cho thấy: (i) xu hướng giảm của `Ca/Mg` khi nồng độ pH của nước sông tăng lên; (ii) tuy nhiên, có 5 điểm tách biệt với xu hướng đám đông của các điểm dữ liệu, các điểm này có thể là các điểm ngoại lai, và do đó, ta nên điều tra thêm để làm rõ sự dị biệt này. ■

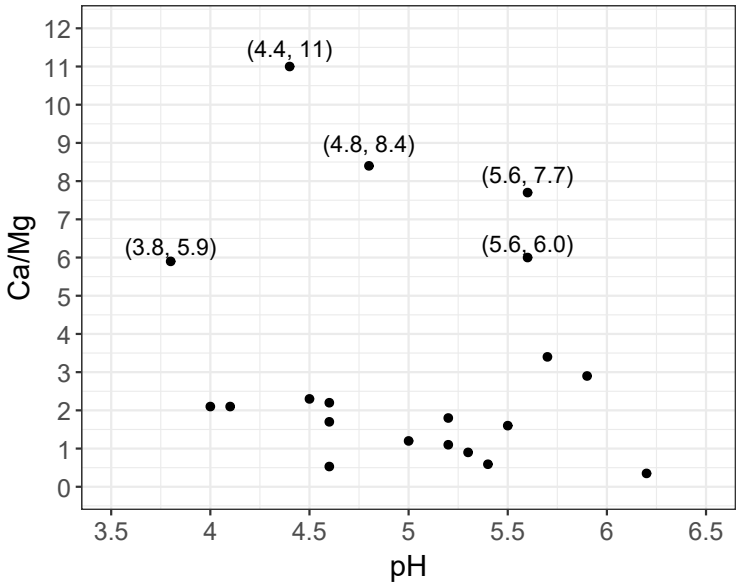

Hình 2 – *Biểu đồ phân tán cho hai biến ngẫu nhiên, `pH` biến biểu thị nồng độ pH của nước sông, `Ca/Mg` là biến biểu thị cho tỷ lệ Calcium so với Magnesium, trong dữ liệu tại Bảng 1. Các điểm được dán nhãn là các điểm có xu hướng khác biệt với phần đông dữ liệu còn lại.*

Ví dụ 2.3. Xét bộ dữ liệu về thời gian chờ giữa các lần phun trào (`waiting`, đơn vị phút) và thời gian phun trào (`eruptions`, đơn vị giây) của mạch nước phun Old Faithful được cung cấp tại Bảng 2. Ta biểu diễn sự phân tán của dữ liệu quan sát của vector ngẫu nhiên $\mathbf{X} = (X_1, X_2)$ cung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó, trong Hình 3. Qua biểu đồ ta thấy rằng dữ liệu có xung hướng phân thành hai cụm (nhóm) rõ rệt, trong đó, một nhóm mạch nước

phun có thời gian phun trào dài và thời gian chờ lâu, nhóm còn lại có xu hướng thời gian phun trào thấp và thời gian chờ ngắn. ■

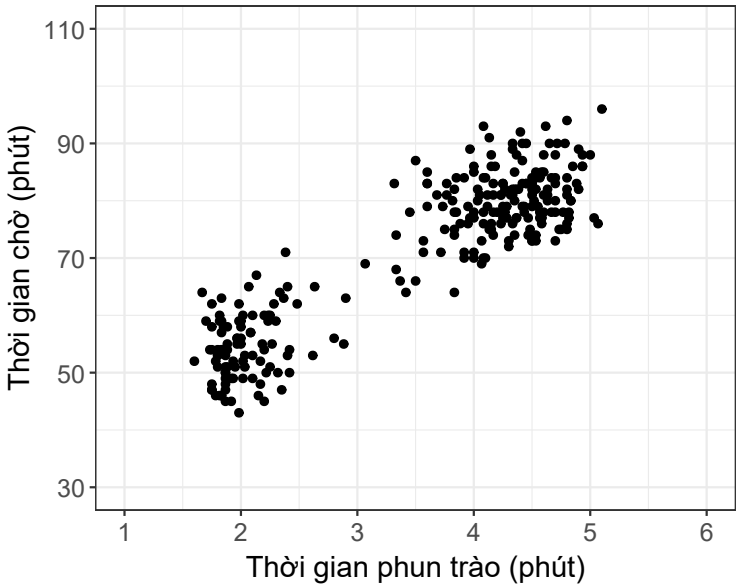

Hình 3 – *Biểu đồ phân tán cho hai biến ngẫu nhiên cung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó.*

2.2 Biểu đồ mật độ hai chiều

Ước lượng mật độ kernel có thể được mở rộng cho vector ngẫu nhiên $\mathbf{X} = (X_1, \ldots, X_d)$, với $d \geq 1$. Cụ thể, với vector dữ liệu quan sát $\mathbf{X}_i = (X_{1i}, \ldots, X_{di})$, với $i = 1, \ldots, n$, ta có ước lượng mật độ kernel được định nghĩa bởi

$$\widehat{f}_{K,n}(\boldsymbol{x}) = \frac{1}{n} \sum_{i=1}^{n} \frac{1}{h_1 \ldots h_d} k\left(\frac{X_{1i} - x_1}{h_1}, \ldots, \frac{X_{di} - x_d}{h_d}\right), \tag{2.1}$$

trong đó, $\boldsymbol{x} = (x_1, \ldots, x_d)$ là điểm trên lưới để tính ước lượng mật độ kernel; h_j là giá trị độ rộng cho từng biến X_j, với $j = 1, \ldots, d$; $k(\cdot)$ là hàm Kernel đa chiều, đi từ $\mathbb{R}^d$ vào trong $\mathbb{R}$. Một hàm kernel đa chiều có các tính chất như hàm kernel một chiều, cụ thể:

(i) $k(\boldsymbol{u}) \geq 0$,

(ii) $k(\boldsymbol{u}) = k(-\boldsymbol{u})$ (tính đối xứng),

(iii) $\displaystyle\int_{\mathbb{R}^d} k(\boldsymbol{u}) \mathrm{d}\, \boldsymbol{u} = 1$,

(iv) $\displaystyle\int_{\mathbb{R}^d} \boldsymbol{u} k(\boldsymbol{u}) \mathrm{d}\, \boldsymbol{u} = 0$.

Một dạng đơn giản của hàm kernel đa chiều là định nghĩa nó như là tích của các hàm kenrel một chiều, tương ứng với d biến X_j $(j = 1, \ldots, d)$, cụ thể

$$k\left(\frac{X_{1i} - x_1}{h_1}, \ldots, \frac{X_{di} - x_d}{h_d}\right) = k\left(\frac{X_{1i} - x_1}{h_1}\right) \ldots k\left(\frac{X_{di} - x_d}{h_d}\right).$$

Khi đó, ước lượng mật độ kernel cho vector ngẫu nhiên được viết lại là

$$\widehat{f}_{K,n}(\boldsymbol{x}) = \frac{1}{n}\sum_{i=1}^{n} \frac{1}{h_1 \ldots h_d} k\left(\frac{X_{1i} - x_1}{h_1}\right) \ldots k\left(\frac{X_{di} - x_d}{h_d}\right), \tag{2.2}$$

trong đó, $k(\cdot)$ sẽ là hàm kernel một chiều, chẳng hạn, hàm kernel Gaussian

$$k(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u}{2}\right).$$

Độ rộng h_j được xác định theo công thức được đề xuất bởi Scott (1992, p. 152)

$$h_{j,opt,\mathrm{S}} = \min\left\{s_j, \mathrm{IQR}_j/1.34\right\} n^{-1/(d+4)}, \tag{2.3}$$

trong đó, s_j và IQR_j lần lượt là độ lệch chuẩn mẫu và khoảng tứ phân vị của dữ liệu tương ứng biến X_j.

Trong trực quan dữ liệu, ta thường chỉ có thể trực quan hiệu quả với trường hợp hai chiều, $d = 2$. Khi này, ước lượng mật độ kernel cho vector ngẫu nhiên $\mathbf{X} = (X_1, X_2)$ được xác định là

$$\widehat{f}_{K,n}(\boldsymbol{x}) = \frac{1}{n}\sum_{i=1}^{n} \frac{1}{h_1 h_2} k\left(\frac{X_{1i} - x_1}{h_1}\right) k\left(\frac{X_{2i} - x_2}{h_2}\right). \tag{2.4}$$

Ta có thể biểu diễn kết quả $\widehat{f}_{K,n}(\boldsymbol{x})$ trên đồ thị ba chiều, tuy nhiên để tiện cho việc quan sát và nhận xét, ta thường trực quan kết quả này bởi các đường đồng mức của ước lượng kernel (tức là hình chiếu trên mặt phẳng Oxy).

Ví dụ 2.4. Xét bộ dữ liệu về thời gian chờ giữa các lần phun trào (`waiting`, đơn vị phút) và thời gian phun trào (`eruptions`, đơn vị giây) của mạch nước phun Old Faithful được cung cấp tại Bảng 2. Ta biểu diễn sự phân tán và ước lượng mật độ kernel của dữ liệu quan sát của vector ngẫu nhiên $\mathbf{X} = (X_1, X_2)$ cung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó, trong Hình 4. Trong ví dụ này, ta sử dụng hàm kernel Gaussian với giá trị độ rộng h_1 và h_2 được xác định qua công thức (2.3), với kết quả là $h_1 = 0.4484, h_2 = 5.3409$. ■

2.3 Biểu đồ tương quan

Trong khoa học dữ liệu, việc phân tích tương quan giữa các biến trong dữ liệu nhiều chiều có một vai trò quan trọng, nó giúp ta xác định được các xu hướng thay đổi của một cặp biến. Đối với dữ liệu đa chiều, gồm d biến định lượng, ta có $d(d+1)/2$ cặp biến cần khảo sát sự tương quan.

Định nghĩa 2.1. Sự tương quan - Correlation là một khái niệm miêu tả mối liên hệ giữa hai biến dạng số (biến định lượng). Để miêu tả mối liên hệ giữa hai biến dạng số, ta có thể dùng đồ thị phân tán (scatter plot). ■

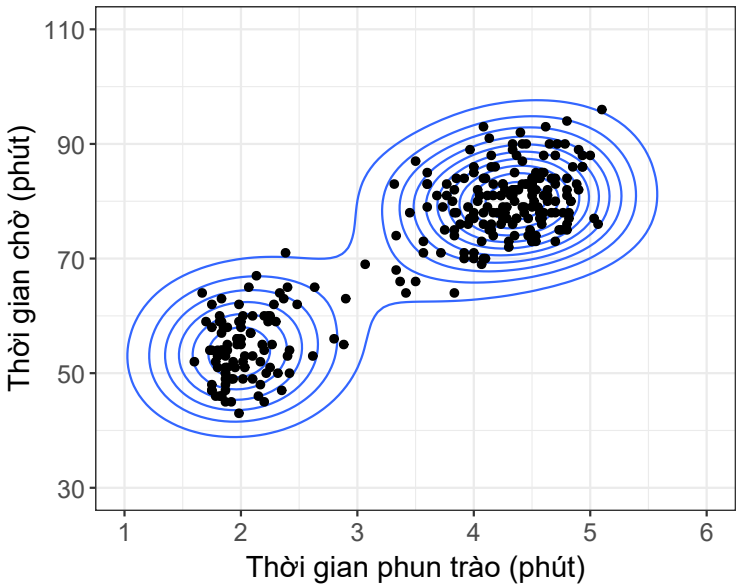

Hình 4 – *Biểu đồ phân tán cho hai biến ngẫu nhiêncung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó.*

Ta có các dạng tương quan phổ biến sau: (i) tương quan tuyến tính (hay linear correlation), xem Hình **??**; (ii) tương quan phi tuyến (hay non-linear correlation). Trong trường hợp phi tuyến, ta còn có thể chia ra thành: tương quan đơn điệu (monotone correlation), xem Hình **??**; hoặc tương quan phi đơn điệu (non-monotone correlation). Sự tương quan giữa hai biến định lượng, có thể được đo độ mạnh trong một số trường hợp cụ thể: tương quan tuyến tính và tương quan phi tuyến đơn điệu.

Định nghĩa 2.2. Hệ số tương quan (correlation coefficient) là một số biểu diễn độ mạnh/yếu trong sự liên hệ (association) của hai biến định tính, và được ký hiệu là ρ. Hệ số ρ có giá trị nằm trong $[-1, 1]$:

- nếu $-1 < \rho < 0$: tương quan giữa X và Y là tương quan nghịch, tức là X tăng thì Y có xu hướng giảm;
- nếu $0 < \rho < 1$: tương quan giữa X và Y là tương quan thuận, tức là X tăng thì Y có xu hướng tăng;
- nếu $\rho = 0$: tương quan giữa X và Y là không tồn tại;
- nếu $\rho = -1$: tương quan giữa X và Y là tương quan nghịch ngặt, tức là X tăng thì Y chắc chắn giảm;
- nếu $\rho = 1$: tương quan giữa X và Y là tương quan thuận ngặt, tức là X tăng thì Y chắc chắn tăng.

■

Trong thống kê, ta có ba hệ số tương quan được sử dụng để đo độ mạnh của sự tương quan giữa hai biến:

- hệ số tương quan tuyến tính Pearson cung cấp độ mạnh của một tương quan tuyến tính

$$\widehat{r}_{P,n} = \frac{\sum_{i=1}^{n} \left(X_i - \bar{X}\right)\left(Y_i - \bar{Y}\right)}{\sqrt{\sum_{i=1}^{n} \left(X_i - \bar{X}\right)^2}\sqrt{\sum_{i=1}^{n} \left(Y_i - \bar{Y}\right)^2}}.$$

- hệ số tương quan hạng Spearman cung cấp độ mạnh của tương quan phi tuyến đơn điệu

$$\widehat{r}_{S,n} = 1 - \frac{6}{n(n^2-1)} \sum_{i=1}^{n} \left(R_{X,i} - R_{Y,i}\right)^2,$$

  với $R_{X,i}$ và $R_{Y,i}$ là thứ hạng của X_i và Y_i trong từng bộ dữ liệu tương ứng;

- hệ số tương quan hạng Kendall's τ cung cấp độ mạnh của tương quan phi tuyến đơn điệu

$$\widehat{r}_{K,n} = \frac{1}{n(n-1)} \sum_{i=1}^{n} \sum_{j=1, j>i}^{n} \text{sign}(X_i - X_j)\text{sign}(Y_i - Y_j).$$

Để biểu diễn $d(d+1)/2$ cặp hệ số tương quan, ta sử dụng biểu đồ có tên là correlogram, trong đó, thang màu phân kỳ (diverging color scale) được sử dụng để thể hiện sự thay đổi giá trị của ước lượng hệ số tương quan:

- màu với độ sáng lớn ở trung tâm (giá trị 0);
- màu với độ đậm lớn ở hai đầu, phía dưới 0 (giá trị -1) hoặc bên trên 0 (giá trị 1);
- hai nhánh trên và dưới có màu tương phản nhau.

Để diễn giải kết quả của correlogram, ta sẽ căn cứ vào loại hệ số tương quan đã được sử dụng và màu sắc của từng ô trong biểu đồ. Ví dụ, ta sử dụng hệ số tương quan tuyến tính Pearson, và ta quan sát thấy ô tương ứng của biến X_1 và X_2 là có màu sáng đậm, thì khi đó, ta có thể đưa ra nhận xét rằng, hai biến X_1 và X_2 là có tương quan tuyến tính mạnh.

Ví dụ 2.5. A-CN-K dataset là dữ liệu về thành phần oxit chính (major oxides) của vật liệu địa chất (đá, đất, trầm tích), được chuẩn hóa theo phần trăm mol (% mol) để so sánh quá trình phong hóa hóa học. Cụ thể:

- A tương ứng Al_2O_3 (nhôm oxit);
- CN tương ứng CaO + Na_2O (canxi và natri oxit, đại diện cho plagioclase feldspar)
- K tương ứng K_2O (kali oxit, đại diện cho K-feldspar hoặc mica)

Biểu đồ phân tán (kèm với ước lượng mật độ kernel) cho ba cặp biến ngẫu nhiên lần lượt là (Al_2O_3, CaO + Na_2O), (Al_2O_3, K_2O) và (CaO + Na_2O, K_2O) được biểu diễn trong Hình 5. Biểu đồ cho thấy xung hướng chung là giá trị % của Al_2O_3 tăng lên thì % của CaO + Na_2O hoặc K_2O sẽ có xu

hướng giảm xuống. Thêm vào đó, ta nhận thấy rằng xu hướng tương quan này không hẳn là tuyến tính, nhưng có thể là đơn điệu.

Độ mạnh tương quan giữa các cặp biến được đo bởi hệ số tương quan Pearson và hệ số tương quan Spearman, kết quả được biểu diễn trong biểu đồ hai correlogram tương ứng trong Hình 6. Ta thấy rằng kết quả của hệ số tương quan Pearson và hệ số tương quan Spearman là tương đối khác nhau ở các cặp (Al_2O_3, $CaO + Na_2O$) và ($CaO + Na_2O$, K_2O). Cụ thể, đối với cặp (Al_2O_3, $CaO + Na_2O$) thì hệ số tương quan Pearson là khoảng -0.7 trong khi hệ số tương quan Spearman chỉ khoảng -0.4. Điều này có thể là do hệ số tương quan Pearson dễ bị ảnh hưởng bởi các giá trị dữ liệu lớn (xem biểu đồ trên cùng bên trái trong Hình 5), trong khi, hệ số tương quan Spearman thì ít bị ảnh hưởng hơn. Đối với cặp ($CaO + Na_2O$, K_2O), biểu đồ phân tán trong Hình 5 cho ta thấy mối tương quan phi tuyến đơn điệu, nên kết quả hệ số tương quan Pearson là thiếu chính xác trong trường hợp này.

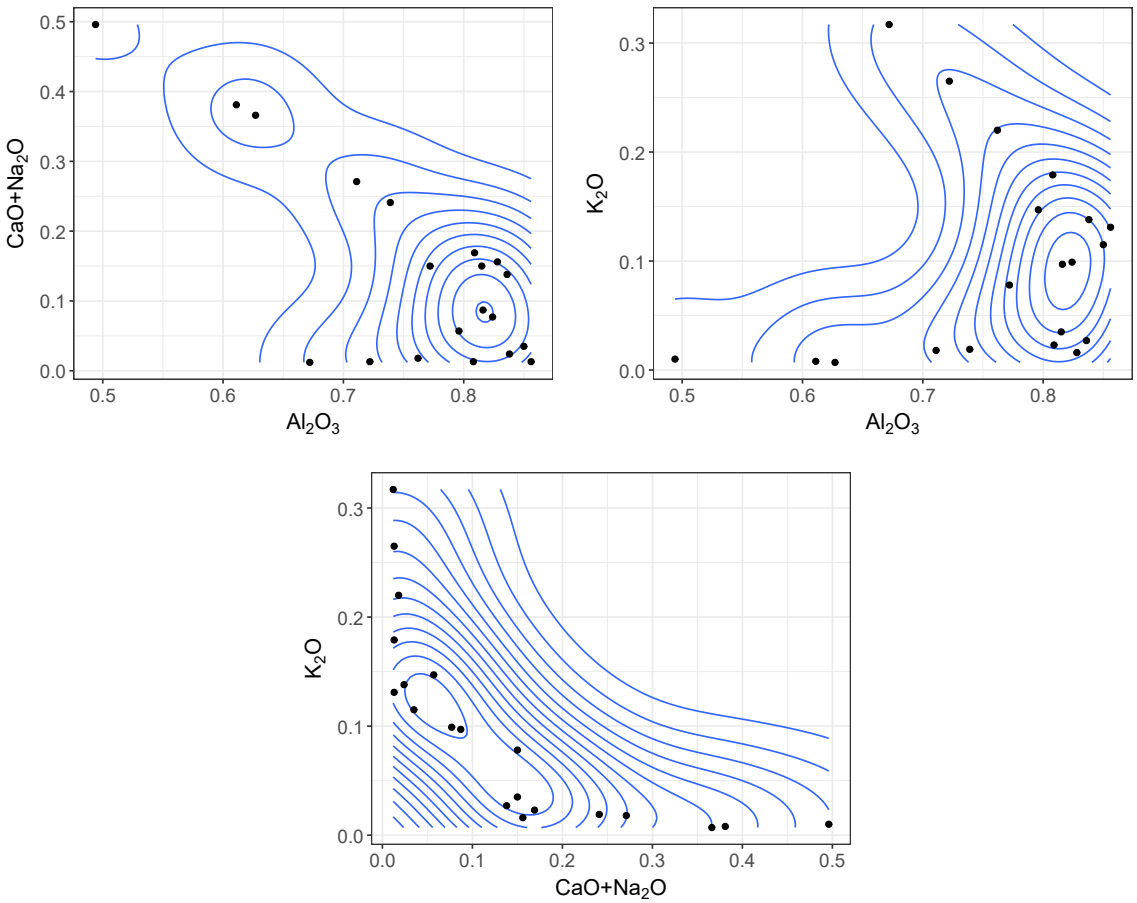

Hình 5 – *Biểu đồ tương quan Pearson cho 3 thành phần địa hóa: Al_2O_3, $CaO + Na_2O$ và K_2O.*

Như vậy, ta có thể kết luận hai ý như sau:

- Al_2O_3 và $CaO + Na_2O$ có tương quan phi tuyến đơn điệu nghịch ở mức trung bình, tức là khi hàm lượng Al_2O_3 tăng thì hàm lượng của $CaO + Na_2O$ có xu hướng giảm;

- $CaO + Na_2O$ và K_2O có tương quan phi tuyến đơn điệu nghịch ở mức mạnh, tức là khi hàm lượng $CaO + Na_2O$ tăng thì hàm lượng của K_2O luôn giảm.

■

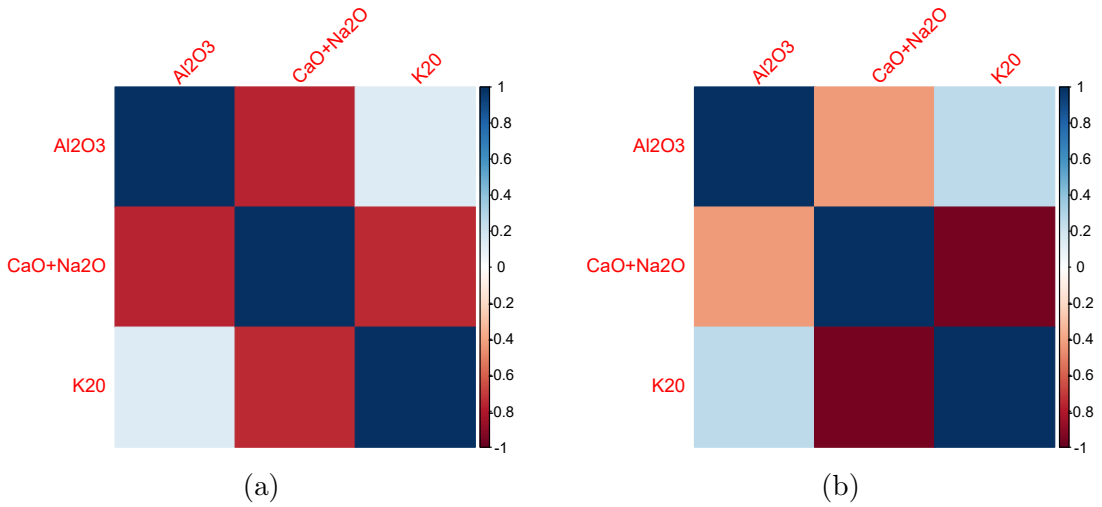

Hình 6 – *Biểu đồ tương quan Pearson (a) và Spearman (b) cho 3 thành phần địa hóa: Al_2O_3, $CaO + Na_2O$ và K_2O.*

2.4 Biểu đồ hộp đa nhóm

Biểu đồ hộp đa nhóm là phương pháp trực quan với nhiều biểu đồ hộp được xếp song song với nhau trong cùng một khung biểu đồ. Trong đó, mỗi biểu đồ hộp biểu diễn dữ liệu của 1 biến định lượng (duy nhất) nhưng theo từng nhóm được xác định theo giá trị của 1 biến định tính. Các biểu đồ hộp được sắp xếp song song với nhau nhằm giúp ta:

- so sánh sự phân bổ của dữ liệu trong các nhóm;
- xác định các giá trị ngoại lai (hay cực đoan) trong từng nhóm;
- xác định (bằng trực quan) xem liệu có hay không sự ảnh hưởng của biến định tính tới sự thay đổi (biến động) giá trị của biến định lượng. (Nếu các boxplot là nằm cùng trên một đường ngang thì sự ảnh hưởng là không tồn tại).

Ví dụ 2.6. Vermeesch (2006) đã thực hiện một nghiên cứu về thành phần địa hóa của các mẫu trầm tích basalts dưới đáy biển. Tác giả đã thu thập 646 mẫu gồm: 227 basalts vòng cung đảo (island arc basalts - IAB), 221 basalts sống núi giữa đại dương (mid oceanic ridge basalts - MORB) và 198 basalts đảo đại dương (ocean island basalts - OIB). Các thành phần địa hóa chính được đo đạc bao gồm: SiO_2, TiO_2, Al_2O_3, CaO, MgO, MnO, K_2O và Na_2O.

Biểu đồ hộp đa nhóm cho giá trị SiO_2 trong ba nhóm trầm tích basalts dưới đáy biển: IAB, MORB, OIB, được biểu diễn trong Hình 7 (a). Kết quả cho thấy lượng SiO_2 trong các nhóm trầm

tích basalts là khác nhau, cụ thể trầm tích basalts đảo đại dương (OIB) có lượng SiO_2 thấp hơn so với 2 nhóm còn lại. Thêm vào đó, ta cũng thấy rằng SiO_2 trong nhóm basalts sống núi giữa đại dương (MORB) là tập trung gần giá trị trung vị, ít phân tán hơn trong các nhóm khác. Có một xu hướng chung là SiO_2 có xu hướng giảm theo chiều IOB > MORB > OIB.

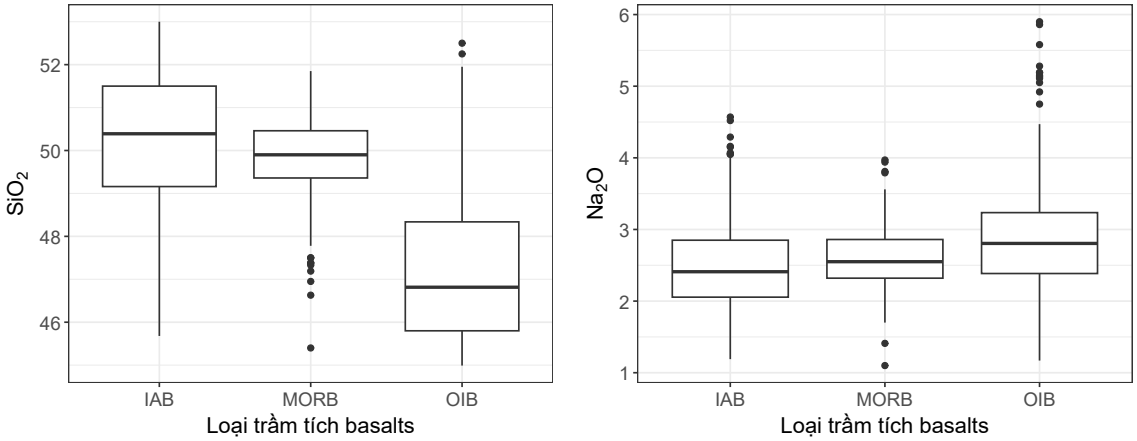

(a) (b)

Hình 7 – *Biểu đồ hộp đa nhóm cho giá trị SiO_2 (hình a) và Na_2O (hình b) trong ba nhóm trầm tích basalts dưới đáy biển: IAB, MORB, OIB.*

Có các giá trị ngoại lai trong hai nhóm trầm tích basalts: MORB và OIB. Điều này, kết hợp với việc vị trí các boxplot là không nằm trên cùng một đường ngang, ám chỉ rằng có sự ảnh hưởng của loại trầm tích basalts tới sự thay đổi (biến động) giá trị của SiO_2. Hình 7 (b) cho thấy các boxplot của Na_2O trong các nhóm trầm tích basalts là gần như nằm trên cùng một đường ngang, ám chỉ rằng sự ảnh hưởng của loại trầm tích basalts tới sự thay đổi (biến động) giá trị của Na_2O là không đáng kể, hay một cách diễn dạt khác, sự khác biệt giá trị của Na_2O giữa ba loại trầm tích basalts đáy biển là không đáng kể. ■

2.5 Biểu đồ violin

Biểu đồ hộp đa nhóm có một nhược điểm là nó không cung cấp cho ta hình thái phân phối (sự đa đỉnh) của dữ liệu. Để mô tả đặc điểm phân phối tổng quát của dữ liệu, ta có 1 biến thể của biểu đồ mật độ kernel, có tên là biểu đồ violin. Biểu đồ violin là sự kết hợp đối xứng của hai đường ước lượng mật độ kernel, xem Hình 8.

Trong một số trường hợp, ta thường kết hợp biểu đồ violin và boxplot nhằm tăng thông tin trực quan (biểu diễn giá trị ngoại lai)

Ví dụ 2.7. Xét lại dữ liệu về thành phần địa hóa của ba nhóm trầm tích basalts dưới đáy biển: IAB, MORB, OIB.

Biểu đồ violin kết hợp với boxplot cho giá trị SiO_2 và Na_2O trong ba nhóm trầm tích basalts dưới đáy biển: IAB, MORB, OIB, được biểu diễn trong Hình 9 (a) và (b). Kết quả cho hình dạng phân phối của SiO_2 trong các nhóm trầm tích basalts là khác nhau. Trong khi đó, hình dạng phân

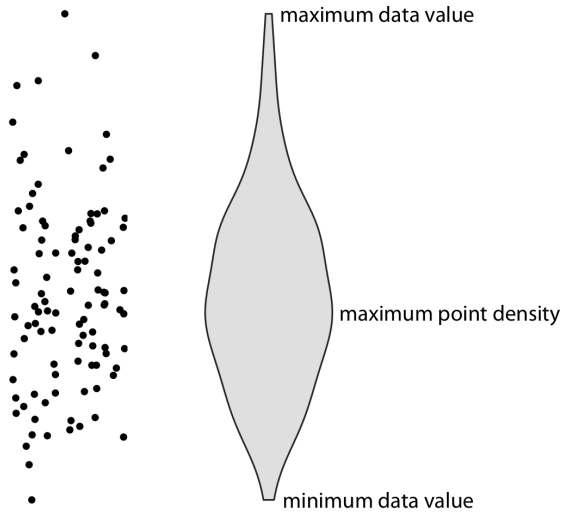

Hình 8 – *Ý tưởng của biểu đồ violin.*

phối của Na_2O là khá tương đồng nhau trong các nhóm trầm tích. Điều này khẳng định sự ảnh hưởng của loại trầm tích basalts tới sự thay đổi (biến động) giá trị của Na_2O là không đáng kể.

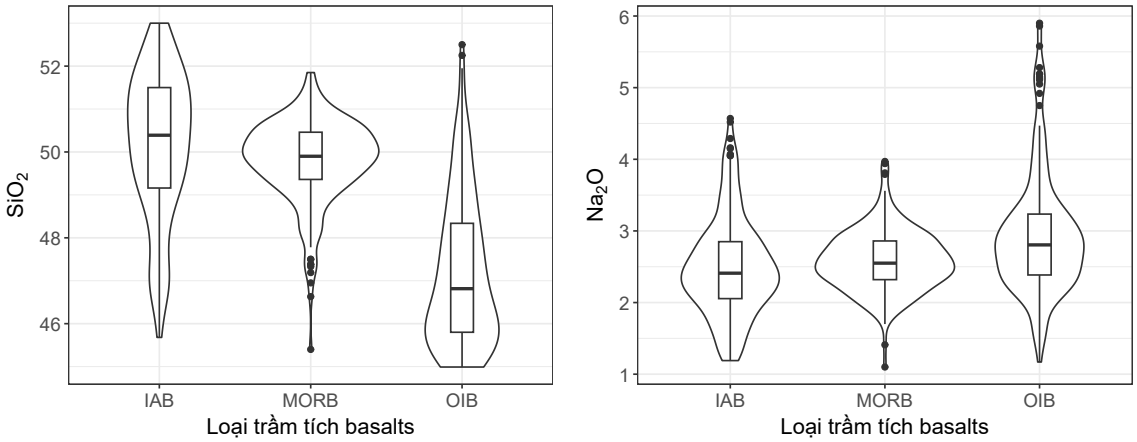

(a) (b)

Hình 9 – *Biểu đồ hộp đa nhóm cho giá trị SiO_2 (hình a) và Na_2O (hình b) trong ba nhóm trầm tích basalts dưới đáy biển: IAB, MORB, OIB.*

■

3 Phương pháp giảm số chiều

Các biểu đồ trực quan ở phần trước là rất hữu ích cho việc trực quan hóa các tập dữ liệu đơn giản một hoặc hai chiều. Tuy nhiên, nhiều tập dữ liệu Khoa học Trái đất lại trải rộng trên nhiều chiều. Ví dụ, một nhà địa hóa học có thể đã đo nồng độ của 20 nguyên tố trong 50 mẫu; hoặc một nhà cổ

sinh thái học có thể đã đếm số lượng tương đối của 15 loài tại 30 địa điểm. Phần này sẽ cung cấp một số công cụ cơ bản giúp chúng ta có thể tổng hợp và trực quan mối liên hệ giữa các biến (tính chất của đối tượng) trong bộ dữ liệu đa chiều. Các công cụ này có tên gọi chung là "các kỹ thuật giảm số chiều dữ liệu" (**Data Dimensionality Reduction Methods**), trong số này, phương pháp Phân Tích Thành Phần Chính (**Principal Component Analysis** - PCA), và phương pháp Tỷ Lệ Đa Chiều (**Multidimensional Scaling** - MDS) là hai phương pháp cơ bản và được sử dụng thông dụng trong thực tế.

3.1 Phương pháp phân tích thành phần chính - PCA

Phân tích thành phần chính (PCA) là phương pháp phân tích dữ liệu khám phá, trong đó, tập dữ liệu có số chiều cao (nhiều biến được quan sát cùng lúc) sẽ được "biến đổi" để tạo ra "phép chiếu" có số chiều thấp hơn (thường là hai) làm dữ liệu phân tích mới mà vẫn mang nhiều thông tin về sự biến động của dữ liệu gốc. Lý thuyết toán đằng sau PCA chính là phép chiếu trực giao và phân tích trị riêng (eigen decomposition) của ma trận hiệp phương sai của dữ liệu.

3.1.1 Ma trận hiệp phương sai

Giả sử ta có một bộ dữ liệu có n quan sát của p biến định lượng, được ký hiệu là $X_1, X_2, \ldots, X_p$, và các điểm dữ liệu được ký hiệu là X_{ij}, với $i = 1, \ldots, n$. Cụ thể, ta có bảng dữ liệu được biểu diễn như ma trận:

$$\mathbf{X} = \begin{pmatrix} X_{11} & X_{12} & X_{13} & \ldots & X_{1p} \\ X_{21} & X_{22} & X_{23} & \ldots & X_{2p} \\ X_{31} & X_{32} & X_{33} & \ldots & X_{3p} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ X_{n1} & X_{n2} & X_{n3} & \ldots & X_{np} \end{pmatrix}$$

trong đó, mỗi dòng tương ứng là quan sát của 1 đối tượng, và 1 cột là dự liệu của 1 biến trong dữ liệu. Khi đó, ta tính được trung bình và phương sai cho mỗi biến X_j (với $j = 1, \ldots, p$) như sau:

$$\overline{X}_j = \frac{1}{n} \sum_{i=1}^{n} X_{ij},$$

và

$$\mathbb{V}\mathrm{ar}(X_j) = s_j^2 = \frac{1}{n-1} \sum_{i=1}^{n} \left(X_{ij} - \overline{X}_j\right)^2,$$

ngoài ra ta còn tính được hiệp phương sai giữa biến X_j và X_k (với $j \neq k$) là

$$\mathbb{C}\mathrm{ov}(X_j, X_k) = s_{jk} = \frac{1}{n-1} \sum_{i=1}^{n} \left(X_{ij} - \overline{X}_j\right)\left(X_{ik} - \overline{X}_k\right).$$

Hiệp phương sai cho biết mức độ các biến thay đổi cùng nhau:

- nếu hai biến **cùng tăng** hoặc **cùng giảm**, hiệp phương sai **dương**,

- nếu một biến tăng còn biến kia giảm, hiệp phương sai **âm**,
- nếu chúng thay đổi độc lập, hiệp phương sai **gần bằng 0**.

Chú ý rằng, hiệp phương sai có tính đối xứng, tức là $s_{jk} = s_{kj}$.

Định nghĩa 3.1. Ma trận hiệp phương sai (variance - covariance matrix) của dữ liệu có p biến định lượng là ma trận vuông có kích thước $p \times p$, đối xứng và xác định dương, trong đó, thành phần trên đường chéo chính là phương sai của các biến, và các thành phần ngoài đường chéo chính là hiệp phương sai giữa hai biến, cụ thể:

$$\mathbf{S} = \begin{pmatrix} s_1^2 & s_{12} & s_{13} & \dots & s_{1p} \\ s_{12} & s_2^2 & s_{23} & \dots & s_{2p} \\ s_{13} & s_{23} & s_3^2 & \dots & s_{3p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ s_{1p} & s_{2p} & s_{3p} & \dots & s_p^2 \end{pmatrix}.$$

Ta chứng minh được rằng,

$$\mathbf{S} = \frac{1}{n-1}\left(\mathbf{X} - \mathbf{1}\overline{\mathbf{X}}^\top\right)^\top \left(\mathbf{X} - \mathbf{1}\overline{\mathbf{X}}^\top\right),$$

trong đó, $\overline{\mathbf{X}} = \left(\overline{X}_1, \overline{X}_2, \dots, \overline{X}_p\right)$ là vector trung bình của p biến, và là $\mathbf{1}$ vector gồm toàn số 1 có chiều dài n. ■

Như vậy ma trận hiệp phương sai sẽ mang toàn bộ thông tin về sự biến động và sự tương quan của các biến được quan sát trong dữ liệu. Như vậy, nếu ta muốn tìm biến đổi của dữ liệu sao cho có số chiều thấp hơn nhưng vẫn bảo toàn hoặc biểu diễn nhiều nhất sự biến động và sự tương quan của các biến được quan sát trong dữ liệu gốc, thì ta sẽ cần tập trung vào phân tích ma trận hiệp phương sai.

Ví dụ 3.1. Xét lại Ví dụ 2.6 về nghiên cứu thành phần địa hóa của các lớp trầm tích đưới đáy biển. Dữ liệu gồm 646 mẫu, 08 thành phần địa hóa được phân tích bao gồm: SiO_2, TiO_2, Al_2O_3, CaO, MgO, MnO, K_2O và Na_2O. Quá trình tính toán cho ta ma trận hiệp phương sai như sau:

	SiO_2	TiO_2	Al_2O_3	CaO	MgO	MnO	K_2O	Na_2O
SiO_2	**3.922**	−1.117	1.627	0.152	−1.846	−0.049	−0.388	−0.179
TiO_2	−1.117	**0.900**	−1.097	−0.461	0.038	0.049	0.258	0.271
Al_2O_3	1.627	−1.097	**4.473**	0.426	−3.219	−0.040	−0.057	0.102
CaO	0.152	−0.461	0.426	**1.904**	0.012	0.004	−0.376	−0.511
MgO	−1.846	0.038	−3.219	0.012	**6.105**	−0.064	−0.220	−0.585
MnO	−0.049	0.049	−0.040	0.004	−0.064	**0.549**	0.001	−0.003
K_2O	−0.388	0.258	−0.057	−0.376	−0.220	0.001	**0.300**	0.198
Na_2O	−0.179	0.271	0.102	−0.511	−0.585	−0.003	0.198	**0.487**

Trong đó, thành phần phương sai được in đậm. Ta dễ thấy phương sai của các thành phần địa hóa có sự chênh lệch lớn, chẳng hạn, phương sai của MgO, $\mathbb{V}\text{ar}(\text{MgO}) = 6.105$, trong khi đó, phương sai của K_2O, $\mathbb{V}\text{ar}(K_2O) = 0.300$. Bên cạnh đó, ta cũng nhận thấy các mối tương quan nghịch, với hiệp phương sai âm. ■

Trong ví dụ trên, ta nhận thấy rằng, trong thực tế, các biến trong dữ liệu thường có phương sai chênh lệch lớn, và điều này khiến cho việc phân tích ma trận hiệp phương sai bị sai lệch. Do đó, trước khi phân tích, ta thường sẽ **chuẩn hóa dữ liệu** sao cho phương sai của mỗi biến là 1. Cụ thể, phép chuẩn hóa cho biến X_j (với $j = 1, \ldots, p$) được xác định bởi:

$$Z_{ij} = \frac{X_{ij} - \overline{X}_j}{s_j},$$

khi này, ta chứng minh được rằng $\overline{Z}_j = 0$, $\mathbb{V}\mathrm{ar}(Z_j) = 1$ và do đó,

$$\mathbb{C}\mathrm{ov}(Z_j, Z_k) = \frac{1}{n-1}\sum_{i=1}^{n} Z_{ij}Z_{ik} = \frac{1}{n-1}\sum_{i=1}^{n} \frac{\left(X_{ij} - \overline{X}_j\right)\left(X_{ik} - \overline{X}_k\right)}{s_j s_k} = r_{jk},$$

tức là hệ số tương quan Pearson của hai biến X_j và X_k. Ma trận dữ liệu chuẩn hóa được xác định là

$$\mathbf{Z} = \begin{pmatrix} Z_{11} & Z_{12} & Z_{13} & \ldots & Z_{1p} \\ Z_{21} & Z_{22} & Z_{23} & \ldots & Z_{2p} \\ Z_{31} & Z_{32} & Z_{33} & \ldots & Z_{3p} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ Z_{n1} & Z_{n2} & Z_{n3} & \ldots & Z_{np} \end{pmatrix}.$$

Ma trận hiệp phương sai của $\mathbf{Z}$ là

$$\mathbf{R} = \begin{pmatrix} 1 & r_{12} & r_{13} & \ldots & r_{1p} \\ r_{12} & 1 & r_{23} & \ldots & r_{2p} \\ r_{13} & r_{23} & 1 & \ldots & r_{3p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_{1p} & r_{2p} & r_{3p} & \ldots & 1 \end{pmatrix}.$$

Ví dụ 3.2. Xét lại ví dụ 2.6 về nghiên cứu thành phần địa hóa của các lớp trầm tích đưới đáy biển. Ma trận tương quan tuyến tính Pearson của 08 thành phần địa hóa được phân tích: SiO_2, TiO_2, Al_2O_3, CaO, MgO, MnO, K_2O và Na_2O, được trình bày như sau:

	SiO_2	TiO_2	Al_2O_3	CaO	MgO	MnO	K_2O	Na_2O
SiO_2	1.000	**−0.594**	0.389	0.055	−0.377	−0.033	−0.357	−0.130
TiO_2	**−0.594**	1.000	**−0.547**	−0.352	0.016	0.069	**0.496**	0.410
Al_2O_3	0.389	**−0.547**	1.000	0.146	**−0.616**	−0.025	−0.049	0.069
CaO	0.055	−0.352	0.146	1.000	0.003	0.004	**−0.497**	**−0.531**
MgO	−0.377	0.016	**−0.616**	0.003	1.000	−0.035	−0.163	−0.339
MnO	−0.033	0.069	−0.025	0.004	−0.035	1.000	0.003	−0.005
K_2O	−0.357	**0.496**	−0.049	**−0.497**	−0.163	0.003	1.000	**0.518**
Na_2O	−0.130	0.410	0.069	**−0.531**	−0.339	−0.005	**0.518**	1.000

Trong đó, thành phần tương quan tuyến tính có độ lớn xấp xỉ hoặc lớn hơn 0.5 được in đậm, nhằm biểu thị các mối tương quan có độ mạnh tương đối, trong khi dấu "−" biểu thị tương quan nghịch. Có thể kể tới mối tương quan nghịch giữa CaO với K_2O và Na_2O. Hay, TiO_2 có tương quan nghịch với SiO_2 và Al_2O_3, nhưng lại có tương quan thuận với K_2O. ■

3.1.2 Quy trình PCA

Với ma trận dữ liệu đầu vào $\mathbf{X}$ có cỡ $n \times p$, tức là n dòng và p cột, ta có quy trình phân tích thành phần chính được tổng hợp trong 5 bước như sau:

Bước 1. Xác định vector trung bình $\overline{\mathbf{X}} = \left(\overline{X}_1, \ldots, \overline{X}_p\right)^\top$ và phương sai của từng biến $s_1^2, \ldots, s_p^2$.

Bước 2. Xác định ma trận dữ liệu chuẩn hóa $\mathbf{Z}$, với thành phần

$$Z_{ij} = \frac{X_{ij} - \overline{X}_j}{s_j},$$

trong đó $i = 1, \ldots, n$ và $j = 1, \ldots, p$.

Bước 3. Xác định ma trận hiệp phương sai $\mathbf{R}$ của dữ liệu đã chuẩn hóa $\mathbf{Z}$ bởi

$$\mathbf{R} = \frac{1}{n-1}\mathbf{Z}^\top\mathbf{Z}.$$

Bước 4. Phân tích ma trận $\mathbf{R}$ thành

$$\mathbf{R} = \Gamma\Lambda\Gamma^\top,$$

trong đó, Λ là ma trận đường chéo, chứa các trị riêng λ_j, tức là

$$\Lambda = \begin{pmatrix} \lambda_1 & 0 & 0 & \ldots & 0 \\ 0 & \lambda_2 & 0 & \ldots & 0 \\ 0 & 0 & \lambda_3 & \ldots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \ldots & \lambda_p \end{pmatrix}$$

các trị riêng này là lớn hơn 0, và $\lambda_1 > \lambda_2 > \ldots > \lambda_p$; Γ là ma trận vector riêng có cỡ $p \times p$, với cột thứ j là vector riêng ϕ_j của thành phần chính thứ j có p phần tử (tương ứng là p biến), và là tương ứng với trị riêng λ_j:

$$\Gamma = \begin{pmatrix} \phi_{11} & \phi_{21} & \phi_{31} & \ldots & \phi_{p1} \\ \phi_{12} & \phi_{22} & \phi_{32} & \ldots & \phi_{p2} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \phi_{1p} & \phi_{2p} & \phi_{3p} & \ldots & \phi_{pp} \end{pmatrix}$$

sao cho $\sum_{i=1}^{p} \phi_{ji}^2 = 1$ với j cố định, và các vector riêng là trực giao với nhau, tức là $\sum_{i=1}^{p} \phi_{ji}\phi_{ki} = 0$.

Bước 5. Xác định các thành phần chính, PC, thứ j:

$$\mathrm{PC}_{ij} = \phi_{j1}Z_{i1} + \phi_{j2}Z_{i2} \ldots + \phi_{jp}Z_{ip} = \sum_{k=1}^{p} \phi_{jk}Z_{ik},$$

với $i = 1, \ldots, n$ và $j = 1, \ldots, p$, vector $(\mathrm{PC}_{1j}, \mathrm{PC}_{2j}, \ldots, \mathrm{PC}_{nj})$ là giá trị (scores) của thành phần chính PC_j. Các thành phần chính thỏa các tính chất sau:

- $\mathbb{V}\mathrm{ar}(\mathrm{PC}_j) = \lambda_j$;
- $\mathbb{V}\mathrm{ar}(\mathrm{PC}_1) > \mathbb{V}\mathrm{ar}(\mathrm{PC}_2) > \ldots > \mathbb{V}\mathrm{ar}(\mathrm{PC}_p)$;
- $\mathbb{C}\mathrm{ov}(\mathrm{PC}_j, \mathrm{PC}_k) = 0$ tức là PC_j và PC_k là độc lập nhau;
- mức độ biến động của dữ liệu gốc được giải thích bởi PC_j thông qua tỷ số phương sai:

$$\psi_j = \frac{\lambda_j}{\sum\limits_{k=1}^{p} \lambda_k},$$

  ta có tính chất $\psi_1 > \psi_2 > \ldots > \psi_p$;
- mức độ biến động của dữ liệu gốc được giải thích bởi q PC đầu tiên, thông qua tỷ số phương sai tích lũy:

$$\gamma_q = \sum_{j=1}^{q} \psi_j,$$

  do đó ta chọn số lượng q PC đầu tiên ($q < p$), sao cho mức độ biến động của dữ liệu gốc được giải thích cao nhất (hoàn hảo nhất là 100%, hay 1). Thông thường, $q = 2$ thường được ưu tiên sử dụng.

Chú ý rằng, vector riêng $\phi_j = (\phi_{j1}, \ldots, \phi_{jp})^\top$ được gọi là vector tải trọng (**loading vector**) của thành phần chính PC_j.

Ví dụ 3.3. Ta áp dụng phân tích thành phần chính cho dữ liệu về phân tích thành phần địa hóa trong các mẫu trầm tích đại dương, Ví dụ 2.6. Trong nghiên cứu này, 8 thành phần địa hóa: SiO_2, TiO_2, Al_2O_3, CaO, MgO, MnO, K_2O và Na_2O cũng chính là 8 biến mà ta quan tâm, tức là $X_1 = SiO_2$, ..., $X_8 = Na_2O$. Ta muốn sử dụng PCA để giảm số chiều của dữ liệu từ $p = 8$ về 2 hoặc 3. Qua quá trình tính toán, ta xác định được vector trung bình và phương sai thành phần là

	SiO_2	TiO_2	Al_2O_3	CaO	MgO	MnO	K_2O	Na_2O
Trung bình	49.130	1.732	15.680	10.757	7.653	0.204	0.624	2.662
Phương sai	3.922	0.900	4.473	1.904	6.105	0.549	0.300	0.487

Trong Ví dụ 3.2, ta cũng đã xác định được giá trị của ma trận $\mathbf{R}$, tức là ma trận hiệp phương sai của dữ liệu chuẩn hóa. Áp dụng phân tích giá trị riêng cho ma trận $\mathbf{R}$, ta thu được $\mathbf{R} = \Gamma\Lambda\Gamma^\top$, với ma trạn giá trị riêng được xác định là

$$\Lambda = \begin{pmatrix} 2.753 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2.016 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1.016 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0.834 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0.575 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0.418 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0.292 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0.096 \end{pmatrix},$$

và ma trận vector riêng Γ với 8 cột là 8 vector tải trọng của các thành phần chính (PC):

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
SiO_2	0.392	0.298	0.082	−0.524	0.362	−0.311	0.338	−0.366
TiO_2	−0.518	−0.075	−0.108	0.222	0.484	−0.151	−0.254	−0.586
Al_2O_3	0.308	0.499	−0.035	0.258	−0.450	0.167	−0.309	−0.513
CaO	0.379	−0.236	−0.172	0.654	0.176	0.047	0.542	−0.127
MgO	−0.084	−0.597	0.151	−0.312	−0.414	0.228	0.222	−0.494
MnO	−0.029	−0.009	−0.962	−0.244	−0.109	0.029	0.038	−0.001
K_2O	−0.443	0.260	0.026	0.143	−0.444	−0.562	0.449	−0.008
Na_2O	−0.367	0.421	0.045	−0.064	0.146	0.694	0.424	−0.003

Từ các kết quả phân tích giá trị riêng cho ma trận $\mathbf{R}$, ta tổng hợp được độ lệch chuẩn, tỷ số phương sai và tỷ số phương sai tích lũy của 8 thành phần chính như sau:

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
Độ lệch chuẩn	1.659	1.420	1.008	0.913	0.759	0.647	0.540	0.309
Tỷ số phương sai	0.344	0.252	0.127	0.104	0.072	0.052	0.036	0.012
Tỷ số phương sai tích lũy	0.344	0.596	0.723	0.827	0.899	0.952	0.988	1.000

Có thể thấy rằng, ta sẽ cần tới 4 thành phần chính để có thể có được tỷ số phương sai tích lũy đạt tối thiểu 70% (mức chấp nhận được), hoặc 5 thành chính nếu muốn tối thiểu 90% (mức tốt). ■

3.2 Biểu đồ biplot

Sau khi áp dụng phân tích thành phần chính của ma trận dữ liệu $\mathbf{X}$, ta thu được các kết quả:

- giá trị của các thành phần chính, $\mathrm{PC}_1, \ldots, \mathrm{PC}_p$;
- phương sai của các thành phần chính, $\lambda_1, \ldots, \lambda_p$;
- tỷ số phương sai tích lũy, $\gamma_1, \ldots, \gamma_p$;
- vector tải trọng của các thành phần chính $\phi_1, \ldots, \phi_p$.

Từ các kết quả này, ta sẽ thực hiện hai thao tác xử lý để tạo ra kết quả trực quan dữ liệu dựa trên PCA:

1. Xác định số lượng thành phần chính quan trọng.
2. Biểu diễn giá trị của 2 thành phần chính và vector tải trọng tương ứng trên biểu đồ phân tán. Biểu đồ này được gọi là **biểu đồ biplot**.

Trong thao tác 1, ta dùng biểu đồ khuỷu tay (**scree plot**) thể hiện tỷ số phương sai theo từng thành phần chính. Khi số lượng thành phần tăng, lượng tỷ số phương sai thu được là giảm dần và đạt cực tiểu tại 0. Điểm mà mức giảm bắt đầu "chậm lại rõ rệt" tạo thành hình giống một khuỷu tay, gọi là elbow. Đó là vị trí phù hợp để chọn số thành phần chính, vì thêm nhiều thành phần nữa cũng không mang lại thêm nhiều thông tin.

Ví dụ 3.4. Theo phân tích thành phần chính trong Ví dụ 3.3, ta có biểu đồ khuỷu tay như trong hình 10. Thông qua biểu đồ, ta thấy mức giảm của tỷ số phương sai chậm dần từ thành phần chính thứ 3 và 4 (so với mức giảm nhanh từ thành phần chính thứ 1 tới thứ 3). Do đó, ta có thể chọn số lượng thành phần chính quan trọng là $q = 3$.

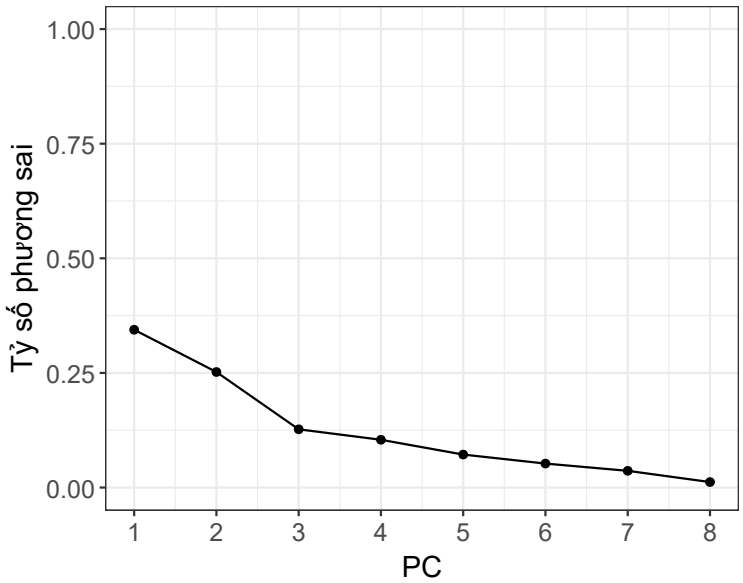

Hình 10 – *Biểu đồ khuỷu tay biểu diễn tỷ số phương sai của 8 thành phần chính trong phân tích thành phần chính cho dữ liệu địa hóa của trầm tích dưới đáy biển.*

■

Biplot là một dạng đồ thị trực quan trong phân tích thành phần chính (PCA), cho phép hiển thị đồng thời các điểm giá trị của 2 thành phần chính và vector tải trọng tương ứng trên cùng một hệ trục hai chiều. Đây là ưu điểm lớn, vì biplot thể hiện được cả cấu trúc của dữ liệu lẫn vai trò của từng biến trong việc tạo ra các trục chính.

Trong biplot, mỗi điểm dữ liệu được biểu diễn như trong biểu đồ phân tán, cho thấy vị trí của nó trong không gian PCA. Những điểm dữ liệu nằm gần nhau thường có tính chất (hóa học hoặc địa chất) tương tự. Các biến trong dữ liệu được biểu diễn dưới dạng các vectơ hướng ra ngoài từ gốc tọa độ. Độ dài vectơ phản ánh mức đóng góp của biến vào 2 thành phần chính đang được biểu diễn, còn hướng của vectơ cho thấy biến đó tăng theo hướng nào. Điểm dữ liệu nào nằm gần hướng của một vectơ thì biến tương ứng có giá trị cao trong dữ liệu đó.

Nhờ kết hợp cả hai loại thông tin, biplot đặc biệt hữu ích trong:

- Giải thích cấu trúc nhóm mẫu, ví dụ nhận diện các loại đá có thành phần hóa học giống nhau.
- Tìm biến quan trọng, xác định các oxit hoặc nguyên tố có ảnh hưởng lớn tới sự phân tách các mẫu.
- Phân tích quan hệ giữa các biến, thông qua góc giữa các vectơ (góc nhọn thì tương ứng với

tương quan thuận, nếu vuông góc thì hai biến gần như không liên quan, góc tù thì tương ứng với tương quan nghịch).

Nói cách khác, biplot là công cụ mạnh giúp vừa nhìn được hướng biến, vừa thấy dữ liệu phân bố ra sao, mang lại cái nhìn toàn diện hơn so với chỉ dùng các biểu đồ tương quan đơn giản.

Ví dụ 3.5. Theo phân tích thành phần chính trong Ví dụ 3.3, và lựa chọn số thành phần chính quan trọng $q = 3$ (thực hiện trong Ví dụ 3.4) ta có 3 vector tải trọng là

	PC1	PC2	PC3
SiO_2	0.392	0.298	0.082
TiO_2	−0.518	−0.075	−0.108
Al_2O_3	0.308	0.499	−0.035
CaO	0.379	−0.236	−0.172
MgO	−0.084	−0.597	0.151
MnO	−0.029	−0.009	−0.962
K_2O	−0.443	0.260	0.026
Na_2O	−0.367	0.421	0.045

Biểu diễn 2 vector này trong đồ thị hai chiều, với trục `x` là PC1 và trục `y` là PC2, các mũi tương ứng là các vector tải trọng của các biến: SiO_2, TiO_2, Al_2O_3, CaO, MgO, MnO, K_2O và Na_2O, chiều dài của chúng tương ứng với đóng góp của từng biến vào trong giá trị điểm của PC1 và PC2. Mỗi vector có điểm đầu là gốc tọa độ, điểm cuối (mũi tên) là độ lớn trong vector. Ví dụ, với SiO_2, vector tải trọng cho PC1 và PC2 là $(0.392, 0.298)$, và ta có biểu diễn vị trí xác định như trong Hình 11.

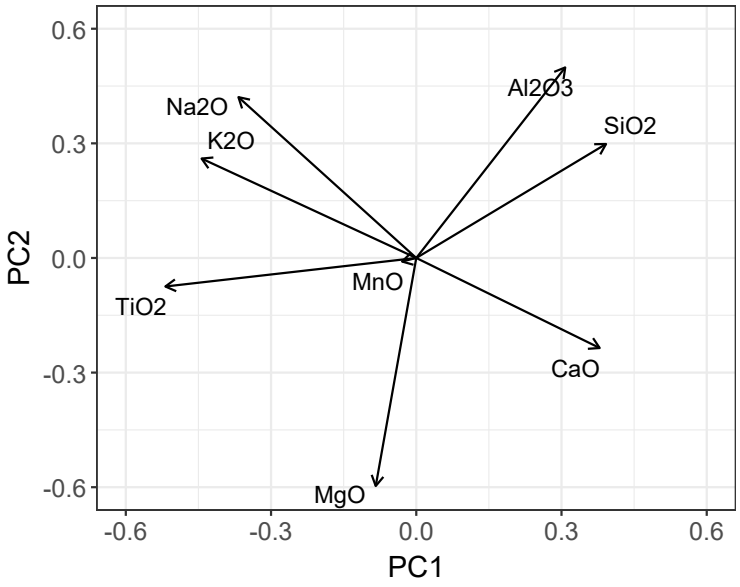

Hình 11 – *Biplot biểu diễn vector tải trọng của PC1 và PC2.*

Theo Hình 11, biến MnO là có sự đóng góp rất nhỏ trong cả PC1 và PC2 (độ dài của vector là rất ngắn, tọa độ `x` và `y` rất gần với 0), biến MgO có đóng góp lớn trong PC2 nhưng lại có đóng góp không đáng kể cho PC1 (tọa độ tương ứng với trục `x` gần với 0).

Xét theo góc giữa các vector, ta có thể rút ra các nhận xét như sau: K_2O và Na_2O có tương quan thuận với nhau (2 vector cùng hướng, và góc giữa chúng là nhỏ hơn 90°); TiO_2 và K_2O có tương quan thuận với nhau, nhưng TiO_2 và Na_2O thì gần như không có tương quan với nhau (góc giữa chúng tuy nhỏ hơn 90° nhưng là tương đối lớn); Al_2O_3 có tương quan nghịch với TiO_2 và MgO (góc đều lớn hơn 90°).

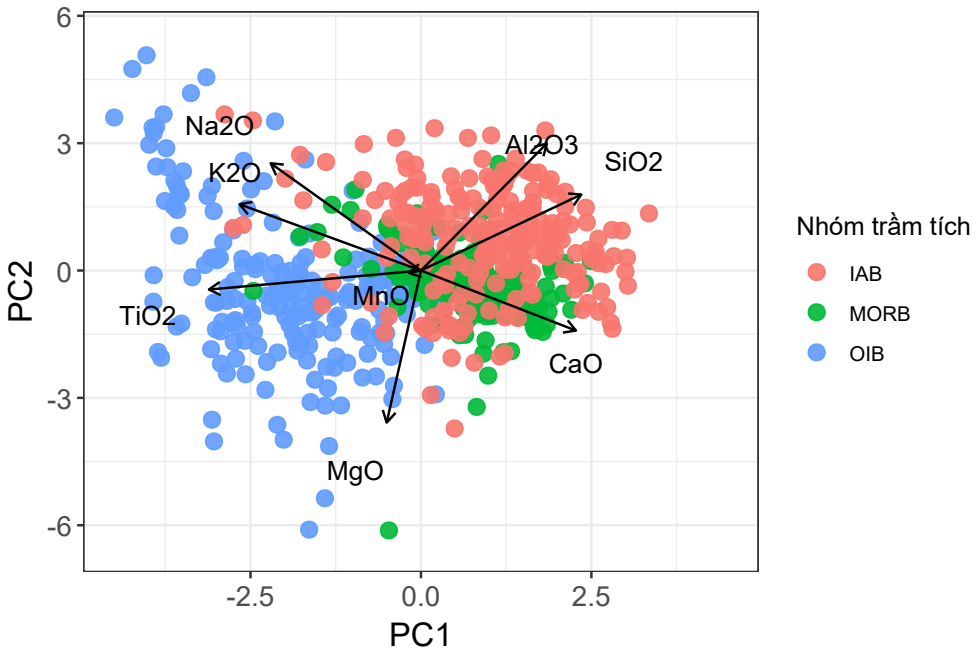

Hình 12 – *Biplot biểu diễn đồng thời các vector tải trọng (đã được nhân thêm hằng số để tương thích kích cỡ hình) và giá trị điểm của PC1 và PC2.*

Hình 12 biểu diễn đồng thời các vector tải trọng (đã được nhân thêm hằng số để tương thích kích cỡ hình) và giá trị điểm của PC1 và PC2. Từ biểu đồ này, ta nhận thấy rằng, lớp trầm tích IAB và MORB có thành phần khá giống nhau, khi, đều có Al_2O_3 và SiO_2, tuy nhiên, lớp MORB có CaO cao hơn. Trong khi đó, lớp OIB có thành phần khác xa so với hai nhóm còn lại, lớp này chủ yếu có TiO_2, một vài mẫu có thể có thêm K_2O và Na_2O (hai thành phần địa hóa này thường đi chung với nhau). ■

Tài liệu tham khảo

Vermeesch, P. (2006). Tectonic discrimination diagrams revisited. *Geochemistry, Geophysics, Geosystems*, 7(6).