Bài giảng 04: Phân cụm cho dữ liệu địa chất

TS. Tô Đức Khánh[1]

[1] *Khoa Toán-Tin học, Trường Đại học Khoa học tự nhiên, ĐHQG-HCM*

Ngày 7 tháng 12 năm 2025

Mục lục

1 Phân cụm dữ liệu **1**

1.1 Phương pháp phân cụm theo tầng 2

1.1.1 Sự tương đồng/bất tương đồng 2

1.1.2 Phân cụm theo cấp bậc – Hierarchical clustering 4

1.2 Phương pháp K-means 10

2 Kết hợp phân cụm và PCA **12**

1 Phân cụm dữ liệu

Phân cụm (**Clustering**) là một thuật ngữ rộng dùng để chỉ các thuật toán trong thống kê và máy học nhằm khám phá các nhóm tự nhiên chưa biết trong dữ liệu dựa trên một số đặc điểm hoặc biến quan sát được.

Nhóm tự nhiên là các nhóm đối tượng mà trong đó mức độ tương đồng giữa các đối tượng trong cùng một nhóm cao hơn so với giữa các nhóm khác nhau. Trong nghiên cứu địa chất, chúng ta thường cần phân nhóm các mẫu đá hoặc mẫu trầm tích dựa trên thành phần hóa học chúng. Ví dụ:

- Tách các mẫu bazan - andesite - rhyolite dựa trên SiO_2.
- Nhận dạng các tập mẫu giống nhau trong cùng môi trường tạo đá.

- Phát hiện mẫu "lạ" (outlier).

Phân cụm dữ liệu giúp tự động tìm các nhóm tương đồng mà không cần nhãn của dữ liệu.

Ví dụ 1.1. Xét bộ dữ liệu về thời gian chờ giữa các lần phun trào (`waiting`, đơn vị phút) và thời gian phun trào (`eruptions`, đơn vị giây) của mạch nước phun Old Faithful. Ta biểu diễn sự phân tán của dữ liệu quan sát của vector ngẫu nhiên $\mathbf{X} = (X_1, X_2)$ cung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó, trong Hình 1. Qua biểu đồ ta thấy rằng dữ liệu có xung hướng phân thành hai cụm (nhóm) rõ rệt, trong đó, một nhóm mạch nước phun có thời gian phun trào dài và thời gian chờ lâu, nhóm còn lại có xu hướng thời gian phun trào thấp và thời gian chờ ngắn. ■

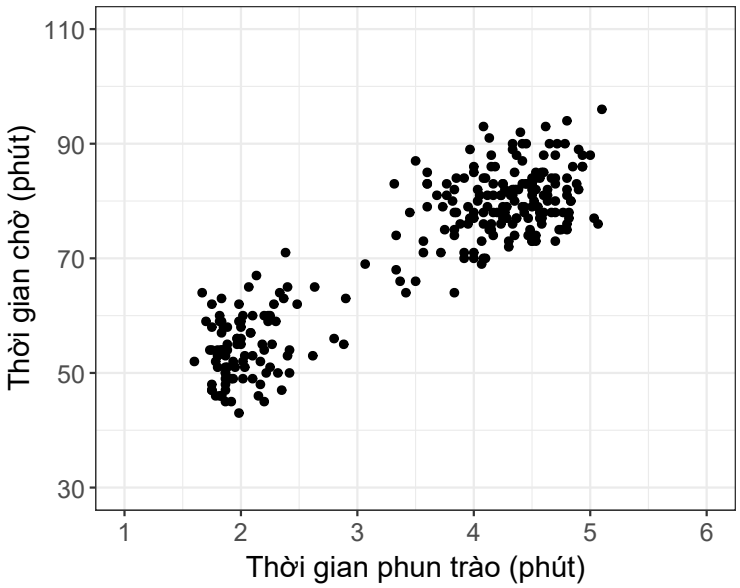

Hình 1 – *Biểu đồ phân tán cho hai biến ngẫu nhiên cung cấp đồng thời thời gian phun trào và thời gian chờ tới lần phun đó.*

1.1 Phương pháp phân cụm theo tầng

1.1.1 Sự tương đồng/bất tương đồng

Sự tương đồng (**Similarity**) là thước đo "sự giống nhau" giữa hai đối tượng được quan tâm, trong khi đó, **sự bất tương đồng** (**Dissimilarity**) là sự trái nghịch lại của sự tương đồng. Về mặt toán học,

- 2 điểm được gọi là **tương đồng** nếu khoảng cách giữa chúng là nhỏ hoặc gần bằng 0;
- 2 điểm được gọi là **bất tương đồng** nếu khoảng cách giữa chúng là lớn (rất lớn).

Trong không gian 2 chiều, một trong những khoảng cách thông dụng nhất là khoảng cách Euclidean:

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2},$$

với $A = (x_1, y_1)$ và $B = (x_2, y_2)$. Khoảng cách $d(A, B)$ vừa đại diện cho sự tương đồng vừa đại diện cho sự bất tương đồng, trong đó, giá trị nhỏ cho thấy rằng hai điểm dữ liệu A và B là tương đồng nhau, trong khi giá trị lớn thì phản ánh điều ngược lại.

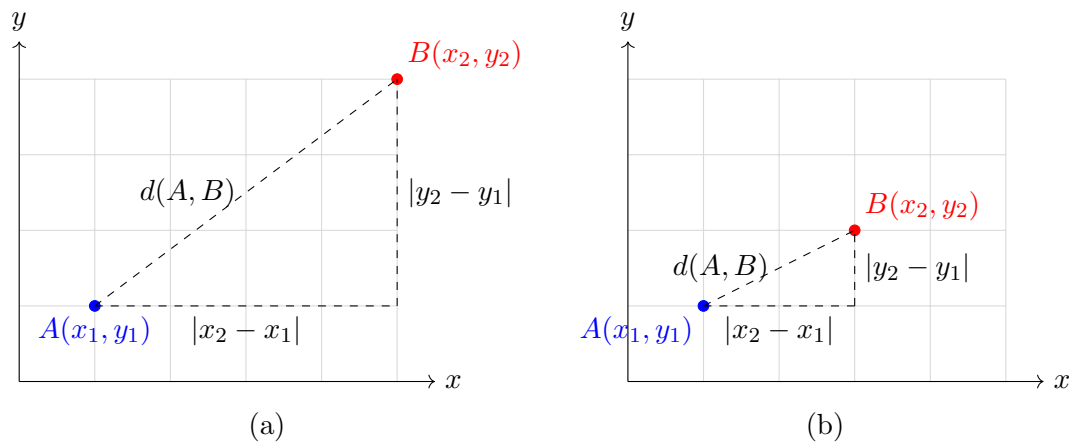

Hình 2 – *Khoảng cách $d(A, B)$ vừa đại diện cho sự tương đồng vừa đại diện cho sự bất tương đồng.*

Khoảng cách Euclidean được mở rộng lên không gian ba chiều, $\mathbb{R}^3$:

$$d(A, B) = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2 + (z_1 - z_2)^2},$$

với $A = (x_1, y_1, z_1)$ và $B = (x_2, y_2, z_2)$. Tổng quát cho không gian $\mathbb{R}^p$:

$$d(A, B) = \sqrt{\sum_{i=1}^{p} (x_i - y_i)^2},$$

với $A = (x_1, x_2, \ldots, x_p)$ và $B = (y_1, y_2, \ldots, y_p)$. Áp dụng cho dữ liệu:

- các biến $X_1, X_2, \ldots, X_p$;
- dữ liệu có n quan sát (đối tượng);
- mỗi đối tượng (điểm dữ liệu) có 1 vector chứa p biến: $\boldsymbol{x}_j = (x_{j1}, x_{j2}, \ldots, x_{jp})$, với $j = 1, 2, \ldots, n$.

Khi đó, khoảng cách Euclidean giữa 2 điểm dữ liệu $\boldsymbol{x}_i$ và $\boldsymbol{x}_k$ là

$$d_{ij} \equiv d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \sqrt{\sum_{k=1}^{p} (x_{ik} - x_{jk})^2}.$$

Tổng hợp các khoảng cách lại, ta thiết lập được ma trận khoảng cách với cỡ $n \times n$:

$$D = \begin{pmatrix} 0 & d_{12} & d_{13} & \dots & d_{1n} \\ d_{12} & 0 & d_{23} & \dots & d_{2n} \\ d_{13} & d_{23} & 0 & \dots & d_{3n} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ d_{1n} & d_{2n} & d_{3n} & \dots & 0 \end{pmatrix}$$

trong đó, thành phần trên đường chéo chính là $d_{ii} = 0$, tức là khoảng cách giữa 1 điểm dữ liệu và chính nó.

Ví dụ 1.2. Xét dữ liệu gồm hai biến X_1 và X_2 với 5 quan sát, ma trận dữ liệu:

$$\mathbf{X} = \begin{pmatrix} 6 & 90 \\ 91 & 43 \\ 17 & 95 \\ 20 & 70 \\ 80 & 6 \end{pmatrix}$$

Áp dụng khoảng cách Euclidean cho điểm dữ liệu thứ nhất và thứ hai ta có

$$d_{12} = \sqrt{(6-91)^2 + (90-43)^2} = 97.1.$$

Tương tự, ta tính được khoảng cách còn lại, và thiết lập được ma trận khoảng cách cho 5 điểm dữ liệu:

$$D = \begin{pmatrix} 0 & 97.1 & 12.1 & 24.4 & 112 \\ 97.1 & 0 & 90.4 & 76.0 & 38.6 \\ 12.1 & 90.4 & 0 & 25.2 & 109 \\ 24.4 & 76.0 & 25.2 & 0 & 87.7 \\ 112 & 38.6 & 109 & 87.7 & 0 \end{pmatrix}.$$

Theo kết quả, ta có điểm số 1 là gần điểm 3 và 4 hơn các điểm số 2 và 5. ■

1.1.2 Phân cụm theo cấp bậc – Hierarchical clustering

Phương pháp này tạo phân cấp giống như cây phả hệ. Có hai dạng:

- dồn nhóm (agglomerative), phương pháp này thường được dùng nhất, ban đầu xét toàn bộ dữ liệu gồm n quan sát là n cụm, sau đó lần lượt gộp các điểm có khoảng cách nhỏ thành các cụm, sau đó là hai cụm gần nhau nhất, kết quả cuối cùng là một đồ thị dạng cây hay một cây dendrogram;
- chia tách (divisive), ban đầu xét toàn bộ dữ liệu là 1 cụm duy nhất, sau đó chia tách dần thành các cụm nhỏ, tuy nhiên, phương pháp này ít được sử dụng trong thực tế.

Thuật toán chung cho phân cụm theo cấp bậc:

Bước 1. Tính toán ma trận khoảng cách (hoặc độ bất tương đồng) cho n đối tượng.

Bước 2. Nối hai đối tượng gần nhất, i và j thành 1 "cụm".

Bước 3. Xóa hàng i và cột j của ma trận khoảng cách; và xác định **ma trận khoảng cách mới** chứa một hàng/cột mới biểu thị độ bất tương đồng của **cụm mới** (i, j) với tất cả các đối tượng (hoặc cụm) khác.

Bước 4. Lặp lại từ bước 2 cho đến khi có một cụm duy nhất.

Nhận xét kỹ thuật: ở bước 3, ta cần xác định khoảng cách (sự tương đồng) giữa

- 1 điểm và 1 cụm điểm, chẳng hạn, điểm C và cụm (A, B);
- 2 cụm điểm, chẳng hạn, cụm (C, D) và cụm (A, B);

tuy nhiên, nó không hề đơn giản như tính khoảng cách giữa hai điểm. Có nhiều phương pháp xác định khoảng cách giữa hai cụm, bao gồm:

Single linkage: Khoảng cách giữa 2 cụm được xác định bằng khoảng cách nhỏ nhất của các khoảng cách giữa 2 phần tử của 2 cụm.

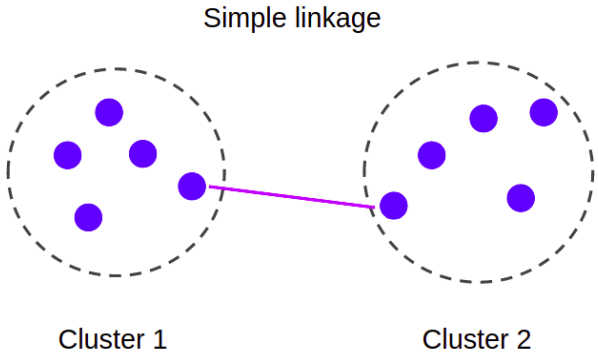

Complete linkage: Khoảng cách giữa 2 cụm được xác định bằng khoảng cách lớn nhất của các khoảng cách giữa 2 phần tử của 2 cụm.

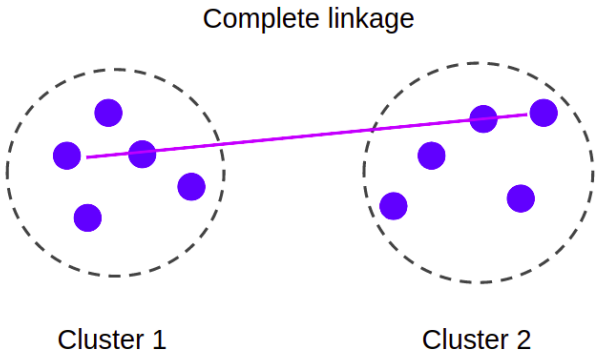

Average linkage: Khoảng cách giữa 2 cụm được xác định bằng trung bình tất cả khoảng cách giữa 2 phần tử của 2 cụm.

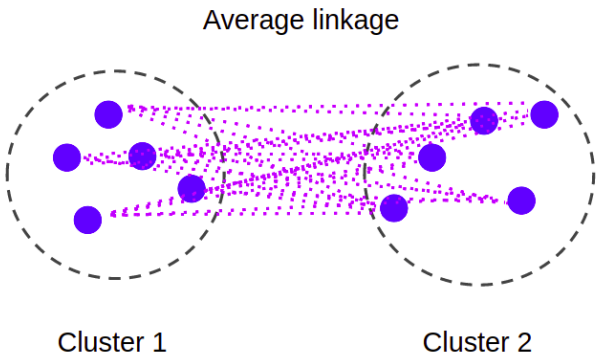

Centroid linkage: Khoảng cách giữa 2 cụm được xác định bằng khoảng cách giữa 2 phần tử trung tâm (centroid) của 2 cụm, trong đó, tâm cụm được xác định bởi giá trị trung bình cộng của tất cả các điểm trong cụm.

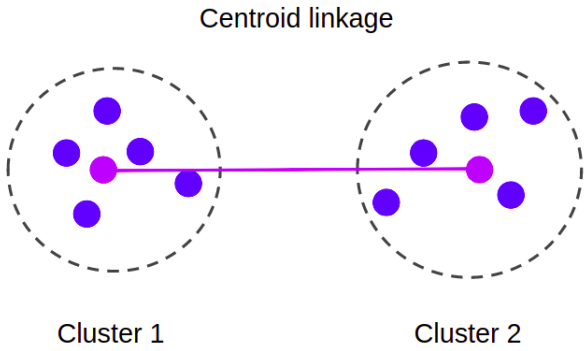

Ví dụ 1.3. Xét dữ liệu gồm hai biến X_1 và X_2 với 5 quan sát, ma trận dữ liệu như trong Ví dụ 1.2:

$$\mathbf{X} = \begin{pmatrix} 6 & 90 \\ 91 & 43 \\ 17 & 95 \\ 20 & 70 \\ 80 & 6 \end{pmatrix}$$

Các bước của thuật toán phân cụm theo cấp bậc được tiến hành như sau:

Bước 1. Tính ma trận khoảng cách Euclidean:

	1	2	3	4	5
1	0				
2	97.1	0			
3	12.1	90.4	0		
4	24.4	76.0	25.2	0	
5	112	38.6	109	87.7	0

Bước 2. Tìm các phần tử gần nhau

	1	2	3	4	5
1	0				
2	97.1	0			
3	12.1	90.4	0		
4	24.4	76.0	25.2	0	
5	112	38.6	109	87.7	0

Bước 3. Ghép điểm 1 và 3 thành cụm (1, 3), cập nhật ma trận khoảng cách với Single linkage.

	(1, 3)	2	4	5
(1, 3)	0			
2	90.4	0		
4	24.4	76.0	0	
5	109	38.6	87.7	0

Khoảng cách từ cụm (1, 3) tới điểm 2, là khoảng cách nhỏ nhất của các khoảng cách từ 1 tới 2 và từ 3 tới 2, kết quả là 90.4. Tiến hành tương tự cho các khoảng cách từ (1, 3) tới 4 và từ (1, 3) tới 5.

Bước 4. Lặp lại bước 2, tìm các phần tử gần nhau trong ma trận khoảng cách mới, được xác định trong bước 3.

	(1, 3)	2	4	5
(1, 3)	0			
2	90.4	0		
4	24.4	76.0	0	
5	109	38.6	87.7	0

Bước 5. Ghép điểm 4 và cụm (1, 3) thành cụm ((1,3), 4), cập nhật ma trận khoảng cách với Single linkage.

	((1, 3), 4)	2	5
((1, 3), 4)	0		
2	76.0	0	
5	87.7	38.6	0

Bước 6. Lặp lại bước 2, tìm các phần tử gần nhau trong ma trận khoảng cách mới, được xác định trong bước 5.

	((1, 3), 4)	2	5
((1, 3), 4)	0		
2	76.0	0	
5	87.7	38.6	0

Bước 7. Ghép điểm 2 và 5 thành cụm (2, 5), cập nhật ma trận khoảng cách với Single linkage.

	((1, 3), 4)	(2, 5)
((1, 3), 4)	0	
(2, 5)	76.0	0

Như vậy, sau 7 bước, ta xác định được 2 cụm, bao gồm: ((1, 3), 4) và (2, 5).

Sau khi đã có kết quả là cây dendrogram, ta sẽ tiến hành cắt cây để tạo ra các cụm. Vị trí bị cắt phụ thuộc vào chiều cao (hay tương ứng là mức không tương đồng cao nhất mà ta mong muốn giữa các cụm). Do đó, nếu ta cắt quá cao thì sẽ có số cụm thấp, trong khi cắt quá thấp thì có quá nhiều cụm. Vì vậy, kết quả phân cụm theo phương pháp hierarchical clustering là tương đối, và kết quả này tạo thành điểm khởi đầu cho việc phát triển một giả thuyết khoa học và nghiên cứu sâu hơn, tốt nhất là trên một tập dữ liệu mới độc lập với dữ liệu cũ.

Ví dụ 1.4. Trong Ví dụ 1.3, ta đã hoàn thành việc phân cụm theo cấp bậc cho dữ liệu gồm hai biến X_1 và X_2 với 5 quan sát, ma trận dữ liệu như trong Ví dụ 1.2:

$$\mathbf{X} = \begin{pmatrix} 6 & 90 \\ 91 & 43 \\ 17 & 95 \\ 20 & 70 \\ 80 & 6 \end{pmatrix}$$

Dựa vào ma trận khoảng cách trong các bước 2, 4, 6 và 7 của 7 bước thực hiện trong Ví dụ 1.3, ta biểu diễn được cây dendrogram như trong Hình 3.

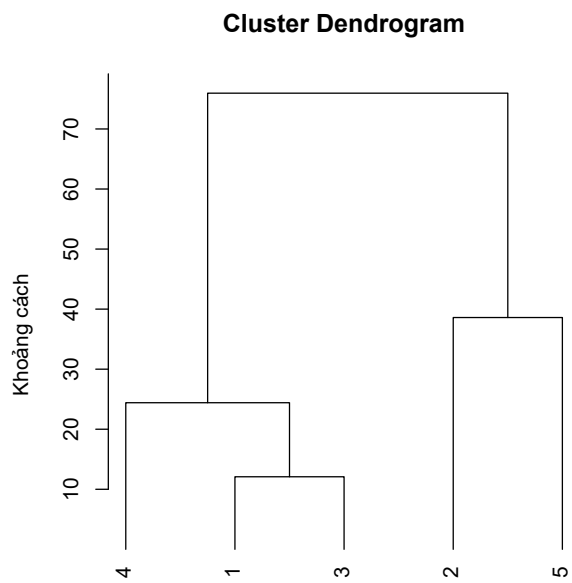

Hình 3 – *Cây dendrogram cho kết quả phân cụm dựa trên khoảng cách Euclidean và Single linkage.*

Khi này, có thể cắt cây tại nhiều vị trí khoảng cách khác nhau, do đó, có thể thu được số lượng cụm khác nhau.

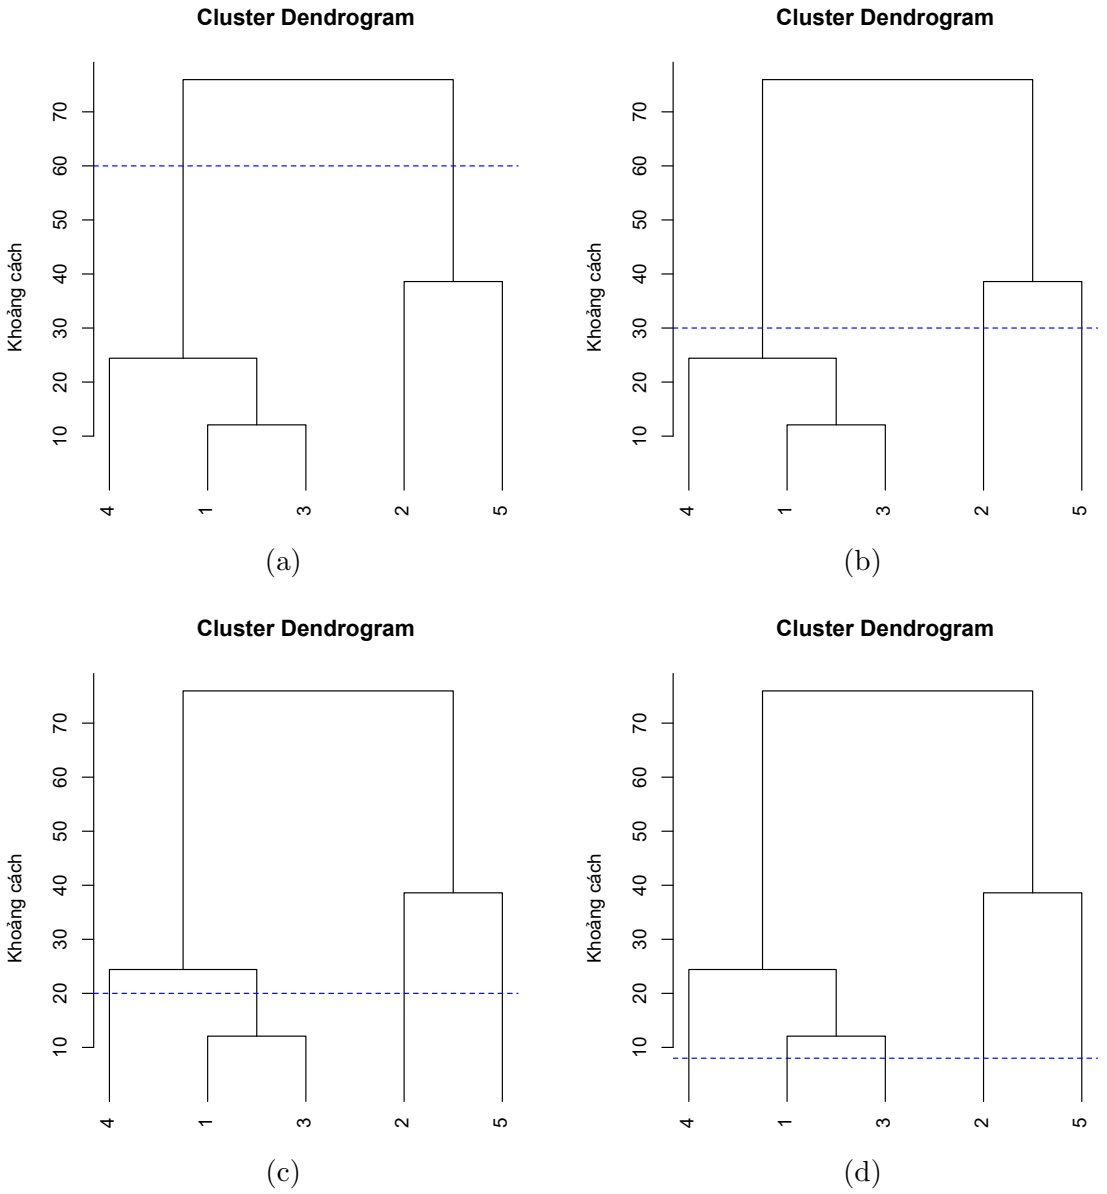

Hình 4 – *Các trường hợp cắt cây dendrogram cho kết quả phân cụm dựa trên khoảng cách Euclidean và Single linkage. (a) Khoảng cách tối đa là 60, (b) Khoảng cách tối đa là 30, (c) Khoảng cách tối đa là 20, (d) Khoảng cách tối đa là 8.*

Xem trong Hình 4, theo đó, ta cắt tại 4 khoảng cách tối đa khác nhau, lần lượt là 60, 30, 20 và 8. Theo đó, nếu ta cắt cây tại khoảng cách (chiều cao) là 60, ta thu được 2 cụm: (1, 3, 4) và (2, 5); và ta đang chấp nhận sự khác biệt tối đa giữa các cụm là 60 đơn vị. Ngược lại, nếu ta khắt khe hơn, chỉ cho phép sự khác biệt tối đa giữa các cụm là 8 đơn vị, thì ta thu được 5 cụm - chính là 5 điểm dữ liệu ban đầu. ■

1.2 Phương pháp K-means

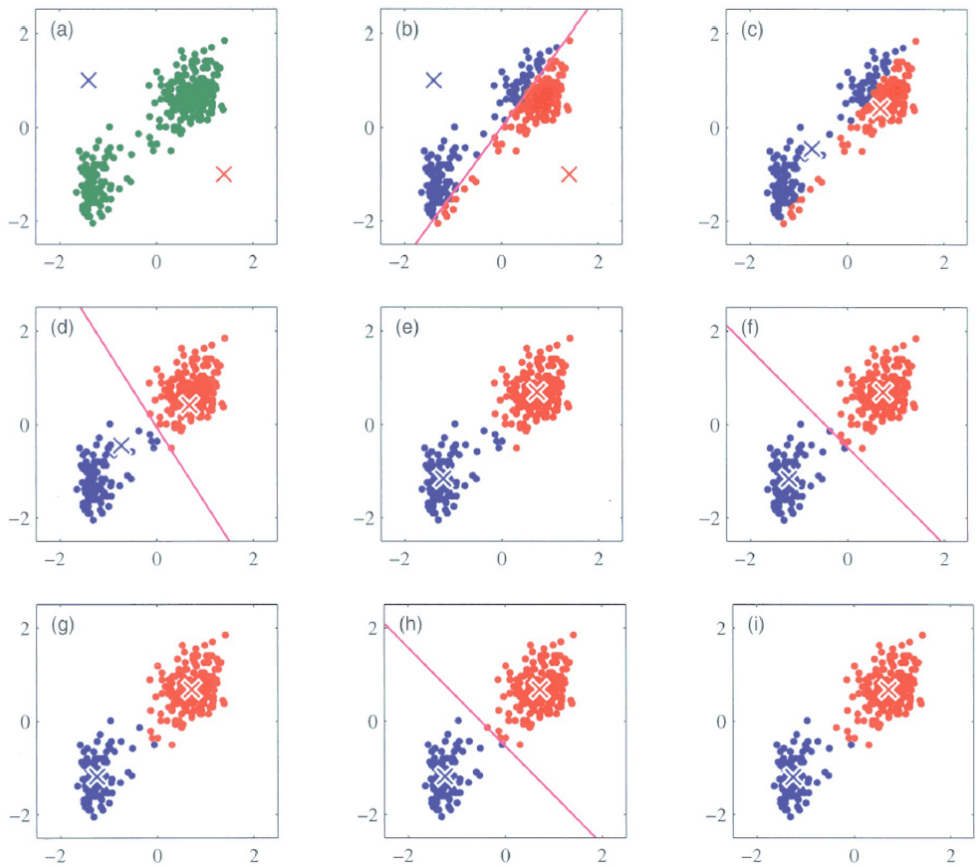

Hình 5 – *Miêu tả quá trình hoạt động của phân cụm K-means.*

K-means là phương pháp phân cụm đơn giản và nhanh, được sử dụng rất phổ biến. Phương pháp này sẽ gán n điểm dữ liệu cho một trong K cụm sao cho tổng bình phương khoảng cách Euclidean từ các điểm đến tâm cụm đã gán là nhỏ nhất, tức là

$$V = \sum_{k=1}^{K} \sum_{i \in g_k} \sum_{j=1}^{p} (x_{ij} - \mu_{kj})^2,$$

với μ_{kj} là tâm của cụm thứ k tương ứng biến X_j và g_k là cụm thứ k. Thuật toán cho phân cụm K-means:

Bước 1. Lựa chọn K, số nhóm mà chúng ta muốn phân cụm dữ liệu.

Bước 2. Chọn ngẫu nhiên K đối tượng để làm tâm của K cụm ban đầu.

Bước 3. Gán từng đối tượng cho nhóm có tâm gần nhất với đối tượng đó.

Bước 4. Tính lại K tâm của các cụm mới, là trung bình cộng của các điểm trong cụm dữ liệu.

Bước 5. Lặp lại từ bước 3 cho đến khi tâm không còn di chuyển nữa.

Lưu ý:

- Thuật toán nhạy cảm với việc lựa chọn tâm cụm ban đầu;
- K-means thường được chạy nhiều lần với các tâm ban đầu khác nhau để đảm bảo các cụm suy ra là "chắc chắn".

Quy trình hoạt động của thuật toán cho K-means, với $K = 2$, được miêu tả như trong Hình 5, trong đó, hình (a) cho thấy giai đoạn ban đầu khi ta chọn ngẫu nhiên hai điểm bất kỳ làm tâm cụm; sau đó, các điểm dữ liệu có bình phương khoảng cách Euclidean tới một trong hai tâm cụm là ngắn nhất sẽ được phân vào 1 cụm, như trong hình (b); tiếp đó, trung bình cộng của các điểm trong mỗi cụm được xác định là tâm cụm mới, như trong hình (c); quá trình xác định cụm tiếp tục cho tới hình (i) khi mà V là nhỏ nhất, và tâm cụm không còn di chuyển.

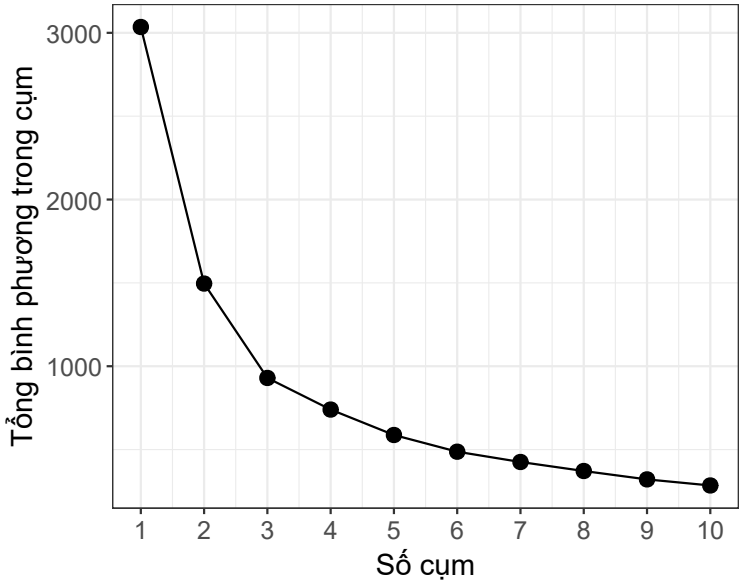

Hình 6 – *Biểu đồ khuỷu tay tìm số cụm phù hợp cho dữ liệu địa hóa gồm SiO_2 và Al_2O_3.*

Trong thực tế, việc chọn số cụm K là không đơn giản, mặc dù ta thường có xu hướng chọn $K = 2, 3$ hoặc 4, nhưng có thể có những trường hợp cho số cụm nhiều hơn 4. Do đó, để xác định K phù hợp nhất với dữ liệu, ta thường sử dụng biểu đồ khuỷu tay (**Elbow plot**), trong đó, giá trị $V_1, V_2, \ldots, V_K$ (tức là tổng bình phương trong cụm) được biểu diễn theo chiều tăng của số cụm, từ 1 tới K. Khi tăng số cụm K, đường cong giảm mạnh lúc đầu rồi sau đó giảm chậm lại. Điểm "gãy" (giống khuỷu tay) là lựa chọn tốt cho K.

Ví dụ 1.5. Xét bài toán phân cụm mẫu địa chất dựa vào đặc điểm hóa học, bao gồm: SiO_2 và Al_2O_3. Áp dụng kỹ thuật K-means, bước đầu ta sử dụng biểu đồ khuỷu tay để tìm ra số cụm phù hợp nhất với dữ liệu. Dò tìm với $k = 1, \ldots, 10$, ta có kết quả như trong Hình 6. Theo đó, số cụm phù hợp sẽ là 3, bởi vì tổng bình phương trong cụm sau khi giảm nhanh từ $K = 1$, xuống tới $K = 3$ thì bắt đầu giảm chậm từ $K = 4$ trở đi. Áp dụng thuật toán K-means cho $K = 3$, ta thu được kết quả phân loại như trong Hình 7, trong đó, các cụm kết quả được xác định bởi các màu khác nhau, các tâm cụm cũng được hiện thị bởi các dấu "*".

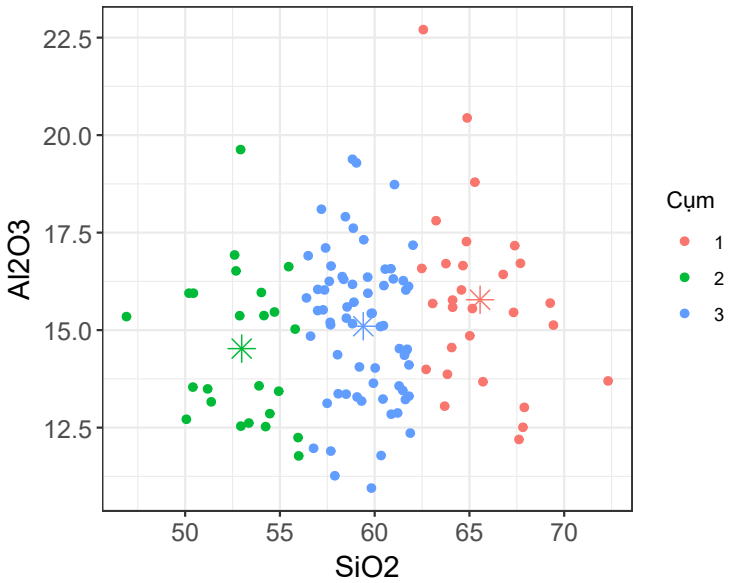

Hình 7 – *Kết quả phân cụm cho dữ liệu địa hóa gồm SiO_2 và Al_2O_3. Các dấu "*" tương ứng là tâm cụm.*

Dựa vào kết quả này, ta có thể tiến hành một số phân tích thống kê tổng hợp giá trị của SiO_2 và Al_2O_3 của các mẫu địa chất theo các cụm, nhằm hiểu hơn về dữ liệu, cụ thể, ta có, trung bình SiO_2 và Al_2O_3 như sau:

Cụm	SiO_2	Al_2O_3
1	65.562	15.779
2	52.983	14.525
3	59.397	15.099

Có thể thấy các đối tượng trong các cụm có hàm lượng SiO_2 khác nhau. ■

2 Kết hợp phân cụm và PCA

Như đã giới thiệu trong các phần trước, dữ liệu địa chất thường có nhiều biến, và các biến có đơn vị cũng như khoảng giá trị xác định khác nhau, ví dụ, biến nồng độ PH và biến nồng độ % của

Al_2O_3, thêm vào đó, các biến có thể có sự tương quan lớn. Điều này khiến cho kết quả phân cụm dễ bị "nhiễu", dẫn tới khó tạo nhóm ổn định.

Để khắc phục nhược điểm này ta có thể kết hợp phân tích thành phần chính (PCA) và thuật toán phân cụm. Trong đó, PCA được thực hiện ở bước đầu nhằm giúp giảm số chiều của dữ liệu mà vẫn giữ lại cấu trúc chính (sự biến động là tương đương), làm dữ liệu "gọn" hơn. Sau đó, các thuật toán phân cụm được áp dụng trên dự liệu mới, có số chiều nhỏ hơn, các biến có cùng khoảng giá trị xác định và độc lập.

Quy trình kết hợp PCA và thuật toán phân cụm được trình bày như sau:

Bước 1. Chuẩn hoá dữ liệu.

Bước 2. Áp dụng PCA cho dữ liệu đã chuẩn hóa. Sau đó, giữ lại từ 2 tới 4 thành phần chính mà giải thích phần lớn sự biến động của dữ liệu gốc (50% tới 80%).

Bước 3. Tiến hành phân cụm trên dữ liệu của các thành phần chính được xác định trong Bước 2.

Bước 4. Hiển thị kết quả trên biểu đồ biplot, trong đó, các điểm dữ liệu được tô màu theo cụm đã được xác định trong Bước 3, và các loading vector được xác định trong Bước 2. Điều này cho phép ta nhìn thấy mỗi cụm khác nhau ở hướng nào, biến nào quyết định sự khác biệt giữa các cụm.

Chú ý rằng, PCA chỉ hoạt động tốt khi dữ liệu có cấu trúc tương quan tuyến tính. Tuy nhiên, khi dữ liệu có cấu trúc tương quan phi tuyến mạnh thì việc sử dụng PCA sẽ phá bỏ đi cấu trúc này, khiến cho việc phân tích không còn giá trị. Trong những trường hợp như vậy, ta không nên sử dụng PCA.

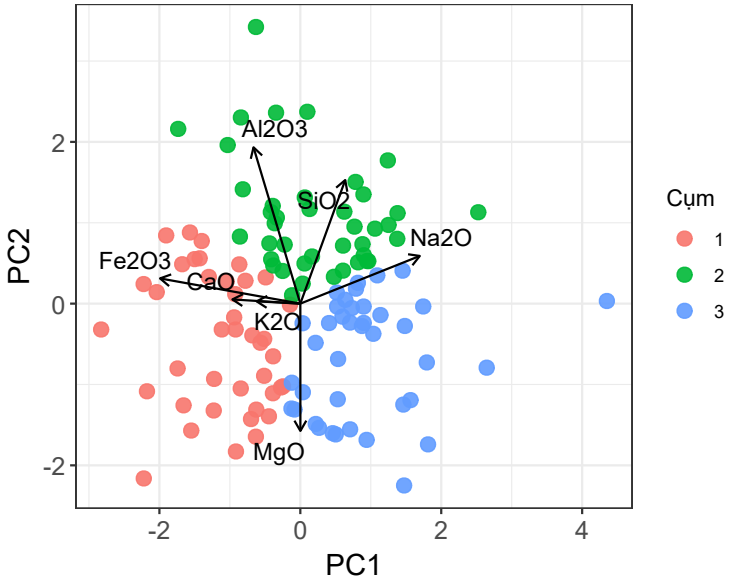

Hình 8 – *Kết quả PCA kết hợp phân cụm K-means cho dữ liệu địa hóa gồm: SiO_2, Al_2O_3, Fe_2O_3, MgO, CaO, Na_2O và K_2O.*

Ví dụ 2.1. Xét bài toán phân cụm mẫu địa chất dựa vào đặc điểm hóa học, bao gồm: SiO_2, Al_2O_3, Fe_2O_3, MgO, CaO, Na_2O và K_2O. Quá trình kết hợp PCA và phân cụm được thực hiện như sau. Đầu tiên, thực hiện PCA giúp ta chọn ra được 2 thành phần chính, PC1 và PC2. Sử dụng giá trị quan sát của các PC này, ta sẽ phân cụm dữ liệu bởi K-means (chú ý, ta cũng có thể sử dụng phân cụm theo thứ bậc). Áp dụng $K = 3$, ta có kết quả được minh họa trong Hình 8.

Kết quả cho thấy các mẫu địa chất trong cụm số 2 có xu hướng chứa nhiều SiO_2, Al_2O_3 và Na_2O, tuy nhiên, Al_2O_3 dường như không có tương quan với Na_2O (hai vector loading gần như vuông góc), trong khi đó, SiO_2 và Al_2O_3 là có tương quan tuyến tính thuận với nhau. ■

Tài liệu tham khảo