Bài tập ôn cuối kỳ

TS. Tô Đức Khánh[1]

[1] *Khoa Toán-Tin học, Trường Đại học Khoa học tự nhiên, ĐHQG-HCM*

Ngày 23 tháng 12 năm 2025

Bài tập 1. Xác định các dạng của các biến được liệt kê dưới đây, kèm theo đó là các cách để mô tả tổng hợp dữ liệu:

(a) Niên đại của các mẫu đá;

(b) Thời gian phun trào của các mạch nước nóng.

(c) Hàm lượng của Al_2O_3 trong mẫu trầm tích.

(d) Hướng di chuyển của các vết rạn băng hà.

(e) Hàm lượng (%) của Al_2O_3, $CaO + Na_2O$ và K_2O trong mẫu trầm tích.

Bài tập 2. Xét dữ liệu về thành phần oxit chính (major oxides) của vật liệu địa chất (đá, đất, trầm tích), được chuẩn hóa theo phần trăm mol (% mol) để so sánh quá trình phong hóa hóa học.

(a) Đây là dạng dữ liệu gì? Nó có tính chất gì?

(b) Vẽ biểu đồ phù hợp để trực quan các giá trị quan sát được của dữ liệu.

(c) Dựa vào biểu đồ đã vẽ trong ý (b), bạn có thể nhận xét được điều gì về quá trình phong hóa hóa học của các mẫu địa chất này.

Bài tập 3. Xét dữ liệu về hướng (theo độ góc) của 30 vết rạn băng hà (glacial striation được đo đạc tại quốc đảo Madagascar.

44	51	79	65	27	31	4	355	22	352	287	7	287	339	0
276	342	355	334	296	7	17	351	349	37	339	40	324	325	334

Sử dụng biểu đồ hoa hồng, ta biểu diễn được xu hướng tập trung của dữ liệu theo phương địa lý như trong Hình 1.

(a) Tính giá trị trung bình của dữ liệu. Sau đó biểu diễn giá trị đó trên biểu đồ hoa hồng. Bạn rút ra được nhận xét gì về biểu đồ hoa hồng và điểm trung bình.

(b) Cách tính giá trị trung bình thông thường có hợp lý với dạng dữ liệu này không? Tại sao hoặc tại sao không?

id	Al_2O_3	$CaO + Na_2O$	K_2O
1	0.796	0.057	0.147
2	0.494	0.496	0.010
3	0.627	0.366	0.007
4	0.838	0.024	0.138
5	0.711	0.271	0.018
6	0.762	0.018	0.220
7	0.722	0.013	0.265
8	0.672	0.012	0.317
9	0.772	0.150	0.078
10	0.611	0.381	0.008
11	0.815	0.150	0.035
12	0.836	0.138	0.027
13	0.816	0.087	0.097
14	0.856	0.013	0.131
15	0.828	0.156	0.016
16	0.824	0.077	0.099
17	0.809	0.169	0.023
18	0.850	0.035	0.115
19	0.808	0.013	0.179
20	0.739	0.241	0.019

Bảng 1 – *Dữ liệu phân tích A-CN-K của 20 mẫu địa chất.*

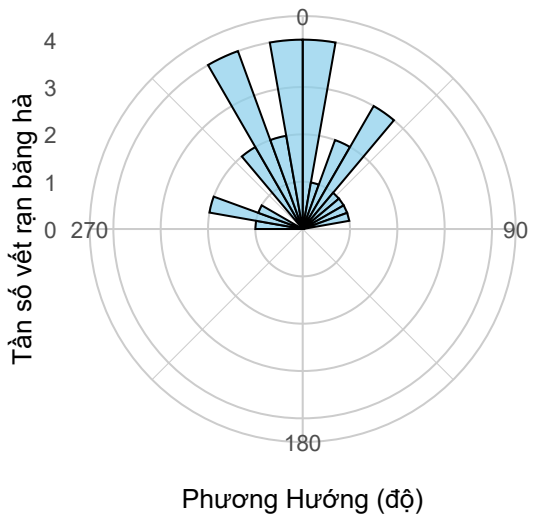

Hình 1 – *Biểu đồ hoa hồng biểu diễn phân bố vết rạn băng hà tại Madagascar theo các phương hướng địa lý.*

(c) Một định nghĩa hợp lý hơn về "hướng trung bình" được xác định bằng cách sử dụng lượng giác, thông qua việc lấy tổng vectơ của tất cả các hướng thành phần. Cụ thể, gọi $\theta_1, \ldots, \theta_n$ là góc của n điểm dữ liệu, khi đó hướng trung bình $\overline{\theta}$ được xác định theo công thức

$$\overline{\theta} = \operatorname{arctan2}\left(\sum_{i=1}^{n} \sin(\theta_i), \sum_{i=1}^{n} \cos(\theta_i)\right),$$

trong đó, hàm $\operatorname{arctan2}(y, x)$ được xác định bởi

$$\operatorname{arctan2}(y,x) = \begin{cases} \arctan(y/x) & \text{nếu } x > 0, \\ \arctan(y/x) + \pi & \text{nếu } x < 0, y \geq 0, \\ \arctan(y/x) - \pi & \text{nếu } x < 0, y < 0, \\ +\dfrac{\pi}{2} & \text{nếu } x = 0, y > 0, \\ -\dfrac{\pi}{2} & \text{nếu } x = 0, y < 0, \\ \text{không xác định} & \text{nếu } x = 0, y = 0, \end{cases}$$

Nếu $\overline{\theta}$ là âm, thì kết quả sẽ là $\overline{\theta} + 360°$, để đảm bảo $\overline{\theta}$ luôn nằm từ $0°$ đến $360°$. Áp dụng công thức này để xác định hướng trung bình của dữ liệu về hướng (theo độ góc) của 30 vết rạn băng hà, sau đó, biểu diễn lên biểu đồ hoa hồng trong Hình 1.

Bài tập 4. Trong phương pháp phân cụm theo cấp bậc, hãy nêu định nghĩa của các phương pháp xác định khoảng cách giữa hai cụm dưới đây, và minh họa bằng hình vẽ:

(a) Single linkage.

(b) Complete linkage.

(c) Average linkage.

(d) Centroid linkage.

Bài tập 5. Xét dữ liệu gồm hai biến X_1 và X_2 với 5 quan sát, ma trận dữ liệu:

$$\mathbf{X} = \begin{pmatrix} 6 & 90 \\ 91 & 40 \\ 17 & 105 \\ 20 & 65 \\ 80 & 10 \end{pmatrix}$$

(a) Xác định ma trận khoảng cách Euclidean giữa 5 quan sát.

(b) Phân cụm 5 quan sát trên bằng phương pháp phân cụm theo cấp bậc với Single linkage.

(c) Phân cụm 5 quan sát trên bằng phương pháp phân cụm theo cấp bậc với Complete linkage.

(d) Phân cụm 5 quan sát trên bằng phương pháp phân cụm theo cấp bậc với Average linkage.

(e) Phân cụm 5 quan sát trên bằng phương pháp phân cụm theo cấp bậc với Centroid linkage.

So sánh các kết quả thu được trong các ý (b) - (e).

Bài tập 6. Trong phương pháp phân tích thành phần chính (PCA), tại sao ta thường phải chuẩn hóa dữ liệu?

Bài tập 7. Trong các phát biểu sau, phát biểu nào là đúng hoặc sai. Nếu phát biểu là sai, hãy giải thích tại sao.

(a) Trong phân tích thành phần chính, phương sai của các thành phần chính (PC) bằng phương sai của các biến ngẫu nhiên.

(b) Trong phân tích thành phần chính, phương sai của các thành phần chính (PC) có độ lớn tăng dần theo thứ tự của PC.

(c) Trong phân tích thành phần chính, ta luôn thu được 2 thành phần chính (PC1 và PC2) bất kể số biến (số chiều của dữ liệu) là bao nhiêu.

(d) Các thành phần chính là luôn độc lập với nhau.

(e) Mức độ biến động của dữ liệu gốc được giải thích bởi q thành phần đầu tiên thông qua tỷ số phương sai tích lũy.

Bài tập 8. Kết quả phân tích thành phần chính của dữ liệu thành phần địa hóa của các mẫu trầm tích đại dương cho 3 vector tải trọng tương ứng của 3 PC, như sau:

	PC1	PC2	PC3
SiO_2	0.39	0.30	0.08
TiO_2	−0.52	−0.08	−0.11
Al_2O_3	0.31	0.50	−0.04
CaO	0.38	−0.24	−0.17
MgO	−0.08	−0.60	0.15
MnO	−0.03	−0.01	−0.96
K_2O	−0.44	0.26	0.03
Na_2O	−0.37	0.42	0.05

(a) Hãy biểu diễn các thành phân của vector tải trọng của PC1 và PC2 trong biểu đồ hai chiều.

(b) Hãy biểu diễn các thành phân của vector tải trọng của PC2 và PC3 trong biểu đồ hai chiều.

(c) Hãy biểu diễn các thành phân của vector tải trọng của PC1 và PC3 trong biểu đồ hai chiều.

Trong mỗi biểu đồ hãy nhận xét về mối tương quan giữa các biến thành phần dựa vào hướng và góc giữa các vector.

Bài tập 9. Giả sử ta có dữ liệu với 4 quan sát, và ma trận khoảng cách Euclidean như sau:

$$D = \begin{pmatrix} 0 & 0.3 & 0.4 & 0.7 \\ 0.3 & 0 & 0.5 & 0.8 \\ 0.4 & 0.5 & 0 & 0.45 \\ 0.7 & 0.8 & 0.45 & 0 \end{pmatrix}.$$

(a) Dựa trên ma trận khoảng cách này, hãy phác thảo biểu đồ cây (dendrogram) thu được từ việc phân cụm bốn quan sát này bằng phương pháp phân cụm theo cấp bậc với Complete linkage. Hãy chỉ ra trên biểu đồ chiều cao mà tại đó mỗi sự hợp nhất xảy ra, cũng như các quan sát tương ứng với mỗi nhánh trong biểu đồ cây.

(b) Lặp lại phần việc trong ý (a) nhưng với phương pháp phân cụm theo cấp bậc với Single linkage.

(c) Giả sử ta cắt biểu đồ cây thu được trong (a) sao cho tạo ra hai cụm. Những quan sát nào nằm trong mỗi cụm?

(d) Giả sử ta cắt biểu đồ cây thu được trong (b) sao cho tạo ra hai cụm. Những quan sát nào nằm trong mỗi cụm?

(e) Theo tính chất biểu đồ cây thì tại mỗi sự hợp nhất trong biểu đồ cây, vị trí của hai cụm được hợp nhất có thể được hoán đổi mà không làm thay đổi ý nghĩa của biểu đồ cây. Hãy vẽ một biểu đồ cây tương đương với biểu đồ cây trong (a), trong đó hai hoặc nhiều nhánh được định vị lại, nhưng ý nghĩa của biểu đồ cây vẫn giữ nguyên.

Bài tập 10. Trong phương pháp phân cụm K-means, ta chọn sẽ chọn số cụm tối ưu K dựa vào phương pháp nào? Hãy miêu tả cách lựa chọn.

Bài tập 11. Xét dữ liệu khảo sát địa chất tại 20 lưu vực sông. Phân tích thành phần chính cho bộ dữ liệu sau khi chuẩn hóa, gồm 4 biến, lần lượt là: Springs (số dòng suối), pH (độ pH trong mẫu đất), CaMg (tỷ số hàm lượng Ca và Mg trong mẫu), Vegetation (tỷ lệ % diện tích có thảm thực vật bao phủ). Kết quả thu được

$$\mathbf{R} = \begin{pmatrix} 0.52 & -0.42 & -0.64 & 0.40 \\ 0.04 & 0.85 & -0.22 & 0.48 \\ -0.62 & -0.32 & 0.14 & 0.70 \\ 0.59 & -0.04 & 0.72 & 0.36 \end{pmatrix} \begin{pmatrix} 1.48 & 0 & 0 & 0 \\ 0 & 1.14 & 0 & 0 \\ 0 & 0 & 0.78 & 0 \\ 0 & 0 & 0 & 0.60 \end{pmatrix} \begin{pmatrix} 0.52 & 0.04 & -0.62 & 0.59 \\ -0.42 & 0.85 & -0.32 & -0.04 \\ -0.64 & -0.22 & 0.14 & 0.72 \\ 0.40 & 0.48 & 0.70 & 0.36 \end{pmatrix}.$$

(a) Có bao nhiêu thành phần chính đã được xác định, phương sai của chúng là bao nhiêu?

(b) Xác định tỷ phương sai của từng thành phần, qua đó tính tỷ lệ phương sai tích lũy.

(c) Vẽ biểu đồ khủy tay (scree plot).

(d) Ta cần sử dụng bao nhiêu thành phần chính để có thể biểu diễn được ít nhất 80% độ biến động của dữ liệu gốc?

Bài tập 12. Xét lại phân tích thành phần chính trong Bài tập 11.

(a) Hãy biểu diễn các vector tải trọng của PC1 và PC2 trên biểu đồ hai chiều.

(b) Bạn có nhận xét gì về sự tương quan giữa các biến cũng như mức độ đó góp của chúng trong PC1 và PC2.

Bài tập 13. Xét lại dữ liệu khảo sát địa chất tại 20 lưu vực sông trong Bài tập 11. Thực hiện phân tích thành phần chính cho bộ dữ liệu không chuẩn hóa, gồm 4 biến, lần lượt là: Springs (số dòng suối), pH (độ pH trong mẫu đất), CaMg (tỷ số hàm lượng Ca và Mg trong mẫu), Vegetation (tỷ lệ % diện tích có thảm thực vật bao phủ). Kết quả thu được

$$\mathbf{S} = \begin{pmatrix} -0.02 & -0.11 & 0.52 & 0.85 \\ -0.07 & -0.56 & 0.67 & -0.48 \\ -0.03 & -0.82 & -0.53 & 0.22 \\ -1.00 & 0.07 & -0.04 & 0.00 \end{pmatrix} \begin{pmatrix} 4073.70 & 0 & 0 & 0 \\ 0 & 20.02 & 0 & 0 \\ 0 & 0 & 4.80 & 0 \\ 0 & 0 & 0 & 2.51 \end{pmatrix} \begin{pmatrix} -0.02 & -0.07 & -0.03 & -1.00 \\ -0.11 & -0.56 & -0.82 & 0.07 \\ 0.52 & 0.67 & -0.53 & -0.04 \\ 0.85 & -0.48 & 0.22 & 0.00 \end{pmatrix}$$

(a) Xác định tỷ phương sai của từng thành phần, qua đó tính tỷ lệ phương sai tích lũy.

(b) Vẽ biểu đồ khủy tay (scree plot).

(c) Hãy biểu diễn các vector tải trọng của PC1 và PC2 trên biểu đồ hai chiều. So sánh với kết quả trong Bài tập 11 và Bài tập 12. Bạn rút ra được nhận xét gì?

Bài tập 14. Trong các biểu đồ ước lượng mật độ sau đây, biểu đồ nào cần phải áp dụng công thức đổi biến, và tại sao?

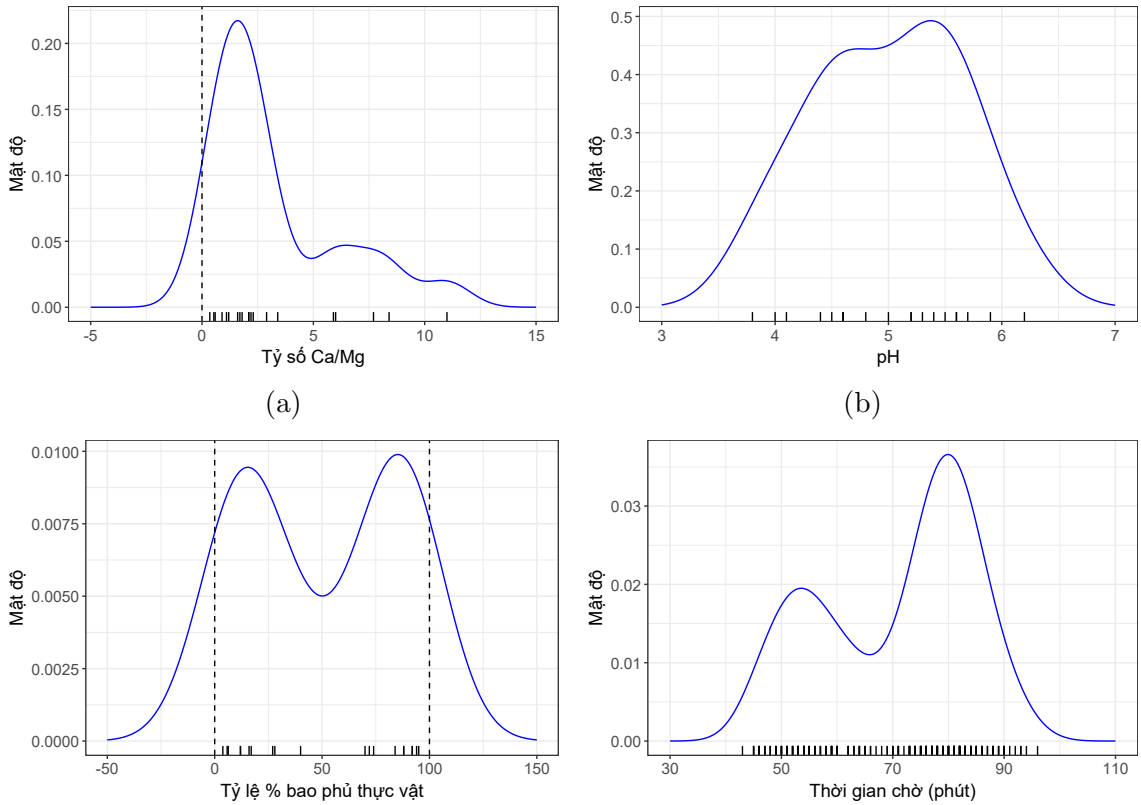

(a) (b) (c) (d)

Bài tập 15. Phân biệt đại lượng Descartes và đại lượng Jeffreys của dữ liệu địa chất. Cung cấp các ví dụ minh họa.

Bài tập 16. Xét dữ liệu thành phần địa hóa của các mẫu trầm tích đại dương trong ba nhóm: IAB (basalts vòng cung đảo - island arc basalts), MORB (basalts sống núi giữa đại dương - mid oceanic ridge basalts), OIB (basalts đảo đại dương - ocean island basalts). Các biểu đồ dưới đây là biểu đồ gì? Chúng mang lại các thông tin gì cho dữ liệu? Hãy viết các nhận xét và giải thích tương ứng.

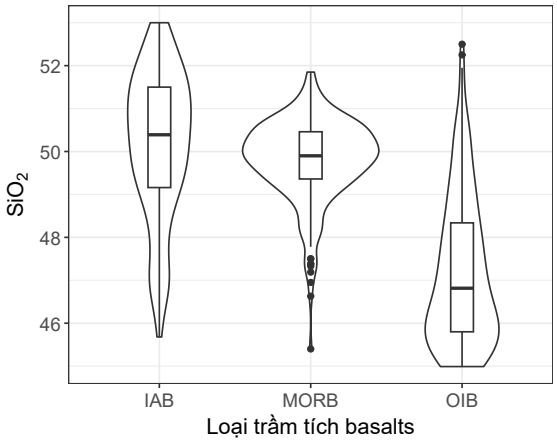

(a)

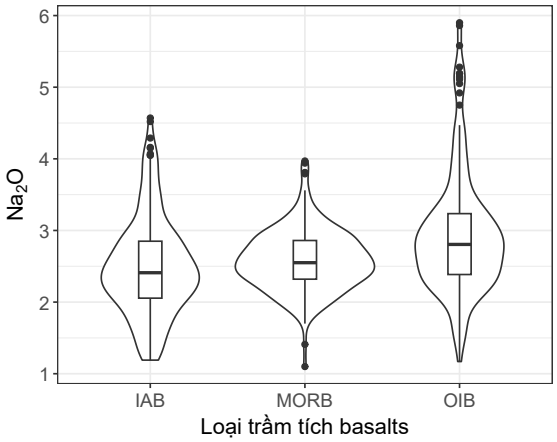

(b)
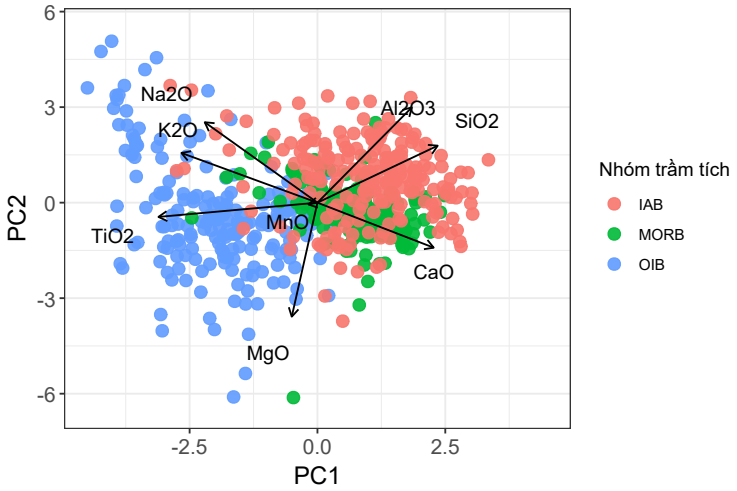
Bài tập 17. Xét dữ liệu thành phần địa hóa của các mẫu trầm tích đại dương trong ba nhóm: IAB (basalts vòng cung đảo - island arc basalts), MORB (basalts sống núi giữa đại dương - mid oceanic ridge basalts), OIB (basalts đảo đại dương - ocean island basalts). Kết quả phân tích thành phần chính cho ta kết quả như trong biplot dưới đây. Hãy viết các nhận xét và diễn giải về tính chất của dữ liệu có thể rút ra được từ biểu đồ.